

# MoonViT-V2 接入 DeepSeek-V4-Flash-0731

## 训练前架构审计、胶水原型与硬件计划

版本 0.3 · 2026-08-04

### Contents

|        |                                                                         |    |
|--------|-------------------------------------------------------------------------|----|
| 1      | 执行摘要                                                                    | 2  |
| 2      | 来源与可复现边界                                                                | 2  |
| 3      | 权重与张量合同                                                                 | 2  |
| 4      | DeepSeek-V4 特殊适配                                                        | 2  |
| 5      | 已完成验证                                                                   | 3  |
| 6      | MoonViT-V2 尺寸与适配性                                                       | 3  |
| 7      | MoonViT-V2 (Kimi K3 视觉塔) 移植                                             | 3  |
| 8      | 本地与云端硬件计划                                                               | 4  |
| 9      | 分阶段门槛                                                                   | 4  |
| 9.1    | Gate A: 无需大权重                                                           | 4  |
| 9.2    | Gate B: V100 工作站                                                        | 5  |
| 9.3    | Gate B 实测: projector overfit 实验 (2026-08-02)                            | 5  |
| 9.4    | Gate B+: 租前全链路彩排 (2026-08-03, 正式训练的对照组)                                 | 6  |
| 9.5    | Gate B 全量 mix early-alignment (2026-08-04, V100, 工程/信号闸门)               | 7  |
| 9.5.1  | 五基准评测终表 (selection 半侧, 1024px, 逐条原始输出已公开于 HF eval/v100-fullmix-qwen05/) | 8  |
| 9.5.2  | 0.5B 主干的容量混杂                                                            | 8  |
| 9.5.3  | 证据边界: 原生 VLM 不是 DeepSeek 代理                                             | 8  |
| 9.5.4  | 误判审计 (应用户要求: 先怀疑判别器, 再怀疑模型)                                             | 9  |
| 10     | 冻结语言主干中的视觉感知涌现: V100 方向筛选实验                                             | 9  |
| 10.1   | 实验基础设施与真实计量 (包 1, 2026-08-04)                                           | 10 |
| 10.2   | Gate C: Vast 只读调研                                                       | 10 |
| 10.2.1 | 最终账单 (含下载时间、网络、存储、装机余量)                                                 | 11 |
| 10.3   | 训练显存算术 (每卡, 权重张量并行切分, 视觉塔/projector 每卡复制)                               | 12 |
| 10.4   | Gate D 风险清单 (租卡前预演)                                                     | 12 |
| 10.5   | Gate D: 正式租卡前                                                           | 13 |
| 10.6   | 租期闭环排程 (2026-08-02 定价)                                                  | 14 |
| 11     | 评测与验收计划                                                                 | 15 |
| 12     | 数据集挑选过程与构建管线                                                            | 16 |
| 12.1   | 挑选原则                                                                    | 16 |
| 12.2   | 评测集 (1,400 行)                                                           | 16 |
| 12.3   | 训练集 (四类短答案监督)                                                           | 16 |
| 12.4   | 排除项与理由                                                                  | 17 |
| 12.5   | 下载与校验通道 (现行做法)                                                          | 17 |
| 12.6   | 组装、去重与打包                                                                | 17 |
| 12.7   | 当前状态 (2026-08-04)                                                       | 17 |
| 13     | 变更日志                                                                    | 18 |
| 14     | 下一位执行者的最短路径                                                             | 20 |

1 执行摘要

本项目目标是给纯文本的 DeepSeek-V4-Flash-0731 接入从 Kimi K3 抽取的 MoonViT-V2 (MoonViT3d) 视觉编码器。第一阶段不训练视觉塔和语言模型，只训练一个 Kimi 风格 PatchMerger projector；独立发布的 MoonViT-SO-400M (V1) 只保留作历史对照。当前结论是：V2 的真实权重、预处理和 [tokens, 4, 1024] 合同均已在 V100 验证，projector-only 全量数据训练已得到明确视觉对齐信号；正式 0731 大权重的 FP4/FP8 可微 kernel 是尚未消除的主要风险。

MoonViT-V2 有 401.2M 参数，抽取后的 BF16 权重约 802 MB，相对于约 160 GB 级的 DeepSeek 混合精度权重很小。更大的资源变量是图像分辨率带来的视觉 token 数和冻结 LLM 反向所保留的激活，而不是视觉塔权重。

2 来源与可复现边界

- 社区 projector checkpoint: 0xSero/glm-local-vision-checkpoint。它证明了 projector-only 路线能把视觉信号接到 GLM-5.2，但公开 grounding 指标仍弱，不能等同于成熟 VLM。
- 社区复现记录: Giving a 753B Model Eyes。
- DeepSeek 权重: deepseek-ai/DeepSeek-V4-Flash-0731, MIT。
- 当前视觉塔: 从 Kimi K3 的 MoonViT3d 权重分片抽取的 MoonViT-V2；抽取权重、配置、代码快照与哈希清单发布在项目模型仓 vision\_tower\_k3/。
- 历史对照视觉塔: moonshotai/MoonViT-SO-400M, MIT。
- Kimi-K2.5 技术报告: Kimi K2.5: Visual Agentic Intelligence。
- Vast offer 搜索接口: Vast.ai Search Offers API。本文只调用搜索接口，不调用创建实例接口。

独立 MoonViT-SO-400M 来自 Kimi-VL；当前主线使用 Kimi K3 的 MoonViT3d/MoonViT-V2。两者输出合同同构不代表特征分布或通道宽度相同。视觉塔 revision 与权重哈希是训练 provenance 的组成部分；更换视觉塔必须重训 projector。

3 权重与张量合同

| 组件                 | 合同                                      | 状态   |
|--------------------|-----------------------------------------|------|
| MoonViT-V2         | [tokens, 4, 1024]                       | 冻结   |
| PatchMerger        | LN(1024) → flatten → 4096 → GELU → 4096 | 训练   |
| DeepSeek embedding | vocab → 4096                            | 冻结   |
| Placeholder        | <   image   > / ID 129279               | 现有词表 |
| Hash-MoE routing   | 扩展后的 placeholder IDs                    | 冻结   |

V2 projector 精确参数量是 33,564,672 (fp32 约 134 MB, bf16 约 67 MB；配置见 configs/deepseek-v4-flash-0731-projector-moonvit-v2.json)。备选的 V1 塔 (MoonViT-SO-400M, 1152 维) projector 为 40,119,040 参数，两条配置不得混用。保存格式由 projector\_config.json 与 projector.safetensors 组成，加载时使用 strict state-dict 校验。MoonViT、DeepSeek 与 projector 始终保留为三个可独立哈希和升级的来源，不把大权重复制到自有仓库。

4 DeepSeek-V4 特殊适配

DeepSeek-V4 的早期 Hash-MoE 通过 tid2eid[input\_ids] 选 expert。只给 inputs\_embeds 会丢失路由 IDs，而当前公共 forward 不允许同时给 input\_ids 和 inputs\_embeds。

原型保留扩展后的 placeholder IDs，并用仅在一次 forward 内生效的 embedding forward hook 替换查表输出。这样 Hash-MoE 看到合法 token IDs，Transformer 隐藏状态看到 projector embeddings，loss 仍可反向到 projector。hook 在 forward 结束后自动移除，不修改 Transformers 源码。

不得向 0731 tokenizer 增加 <image>: 扩词表会同时要求修改输入 embedding、LM head 和 Hash-MoE 的 tid2eid 表。0731 已含多个视觉相关 token，因此没有必要承担该风险。

5 已完成验证

| 测试                                     | 结果    | 意义                         |
|----------------------------------------|-------|----------------------------|
| Placeholder 可变长度扩展和 label mask         | 通过    | 序列/监督合同                    |
| Projector Safetensors round-trip       | 通过    | 权重可恢复                      |
| 冻结普通 GPT-2 的 backward                  | 通过    | 通用文本主干                     |
| 真实 DeepseekV4ForCausalLM 1 层 Hash-MoE  | 通过    | DeepSeek 路由合同              |
| MoonViT-V2 输出 shape/freeze 合同          | 通过    | 真实 K3 视觉权重                 |
| 真实 MoonViT-V2 + 小 LM 前向/反向             | 通过    | V100 CUDA eager/sdpa       |
| eval_vlm 生成/blind/shuffle-loss 干跑      | 通过    | 评测管线端到端                    |
| generate(): generic 与 deepseek_v4 两种路径 | 通过    | 评测/推理前置                    |
| 指标库 (VQA/ANLS/token-F1/grounding)      | 通过    | 纯 Python, 无 torch          |
| 完整测试集                                  | 96/96 | Linux + torch 2.10.0+cu128 |

V100 实测：真实 K3 MoonViT-V2 在 1024×1024 输入下输出 [1369,4,1024]，特征全部 finite、逐位确定，eager 与 sdpa 最大绝对差 3.1e-05；真实权重 strict-load、预处理与 loss/backward 合同均正常。旧 V1 路径也保留了 448px 和原生分辨率回归，但不再代表当前训练主线。评测管线的生成、blind 基线与 shuffle-loss 全部端到端通过；训练后 shuffle-loss 差值应当变正，这是对齐信号最便宜的读数。

离线 smoke 结果：输入 6 token 扩展为 8 token；projector 六组参数均获得梯度；语言模型参数梯度数为 0。同一结果在 doesworkstation (V100) 上复现。

版本审计发现，公开 PyPI Transformers 4.57.6 不含 deepseek\_v4 模块；真实 DeepSeek 类测试使用 Transformers 5.14.1。因此统一环境暂定 transformers>=5.12,<6，不能盲从 checkpoint config 中的历史版本字符串。

6 MoonViT-V2 尺寸与适配性

MoonViT-V2 适合该任务：27 层、hidden size 1024、12 heads、401.2M 参数，原生分辨率和 NaViT packing 对 GUI、文档、截图有价值。它不会显著改变完整 0731 的权重门槛；V1 的 1152 维/16 头规格只作为对照记录。

风险来自 token 数。patch size 为 14, 随后 2×2 合并。392×392 图像产生约 196 个合并 token；896×896 产生约 1024 个。第一阶段应把每图上限锁在 1024；更高分辨率必须以梯度激活显存实测决定。

7 MoonViT-V2 (Kimi K3 视觉塔) 移植

按项目决策，视觉塔改为从 Kimi 直接抽取 (K3 优先, K2.6 备选)，与社区 GLM-5.2V 实验同源（他们从 K2.6 抽）。Kimi-K3 仓库全量约 1.56 TB，但其 safetensors index 显示全部 165 个 vision\_tower.\* 张量集中在单个分片 model-00096-of-000096.safetensors (约 802 MB)。抽取与验证全部在自有工作站完成，不依赖租用机器；租服务器时使用抽取后的独立视觉塔产物，不触碰完整 K3 仓库。

K3 的 MoonViT3d(下称 MoonViT-V2)与 MoonViT-SO-400M 的合同差异: vision width 1152 → **1024** (27 层、12 头、qkv 1536、rmsnorm、无 attn bias、divided-fixed 位置插值)；merge 方式 sd2\_tpool, 单图 (t=1) 时时域池化为恒等，输出仍是每图 [tokens, 4, 1024] 的特征组——与既有 PatchMerger 的

[G,4,C] 合同同构，胶水层零改动，仅 projector 的 vision\_width 换为 1024 (flatten 维度 4096)。输入格式为 NaViT packing 的 [total\_patches, 3, 14, 14] + grid\_thws，与 V1 的 flatten 格式不同，由 processor 适配器统一。

移植方式：将 K3 仓库中视觉塔所需的最小代码集 vendor 进本仓库 (src/moonvit\_glue/vendor/kimi\_k3/, Apache-2.0 + Kimi K3 License, 已附 LICENSE)，删除文本模型依赖 (modeling\_kimi\_linear 要求更新版 Transformers 的 OutputRecorder, 与本项目 5.12 基线冲突) 与条件生成类；加载不再需要 trust\_remote\_code, 也不再需要下载完整 K3 仓库。moonvit\_glue.moonvit\_v2 复用既有 MoonViTEncoder 契约 (freeze、形状校验、preprocess)，新增 sdpa varlen attention (K3 代码只注册 flash-attention-2 与 eager；V100 等无 flash-attn 硬件用 eager/sdpa, 数值一致性有测试)。

已验证 (工作站)：vision-only 模块独立实例化 (真实配置 401.2M 参数)；前向输出 [G,4,1024] 符合合同；eager 与 sdpa 注意力数值一致；带/不带 vision\_tower. 前缀的 state-dict 均 strict 加载；processor 适配器产出 pixel\_values/image\_grid\_hws 合同键；完整测试集 34/34 通过。真实 shard 的 header 元数据与模型 state\_dict 逐项比对：165/165 key、形状、dtype (全 BF16) 完全一致，且该 shard 不含任何非视觉权重。**服务器端同样只需部分下载**：干净房间测试 (PYTHONPATH 仅含本仓库、无 K3 staging) 确认 vendored 代码只依赖 stdlib/torch/transformers/numpy/PIL，租机时视觉塔侧只需 git 仓库 + 抽取产物 (约 800 MB, 附 sha256 MANIFEST 供下载校验)，完整 K3 仓库不进入训练链路。

**真实权重回归 (2026-08-03)**：shard 下载完成 (802,448,352 B, sha256 9d10c74f...)，tools/extract\_moonvit\_v2.py 抽取 165 张量 / 401.2M 参数并 strict-load 通过，产物 moonvit\_v2.safetensors (BF16, sha256 01436a95...) + MANIFEST (双哈希)。V100 上真实权重前向：1024×1024 图像 → 5476 patches (74×74 grid) → [1369,4,1024]，全部 finite，特征统计健康 (mean 0.0003 / std 0.0511 / absmax 0.60, RMSNorm 后典型量级)；两次前向逐位一致 (确定性)；eager 与 sdpa 在真实权重上最大绝对差 3.1e-05 (fp32 累加顺序的正常量级)。抽取产物上传至项目 HF 仓库 vision\_tower\_k3/ 子目录，训练与评测经 --vision-tower v2 --moonvit-v2-weights 使用。

8 本地与云端硬件计划

| 目标                      | 建议硬件             | 判断                            |
|-------------------------|------------------|-------------------------------|
| 胶水/单元测试                 | CPU 或任意 8 GB GPU | 已完成                           |
| MoonViT-V2 + 0.5B–3B LM | 12–24 GB GPU     | 适合本地开发                        |
| V100 32 GB              | SM70、32 GB       | 可跑 MoonViT-V2/小 LM；不能装完整 0731 |
| 完整 0731 推理验证            | 同机 4×48 GB 起步    | 上下文和 kernel 受限                |
| projector-only 正式训练     | 4×H100 80 GB 或更高 | 先过单 batch backward            |
| 低风险首跑                   | 4×H200/B200      | 更大激活余量                        |

消费级单卡不能纯 GPU 运行完整 0731。110–192 GB 主机内存配合 3/4-bit CPU offload 可能极慢推理，但 GGUF/llama.cpp 不能作为当前 projector 训练路径。MoonViT 单独可在普通本地机器运行；完成后的完整组合能否“本地跑”，取决于本地是否具备多卡或大内存 offload 条件。

9 分阶段门槛

9.1 Gate A: 无需大权重

- 1. 固定 tokenizer/image token 合同。
- 2. 固定 MoonViT revision、processor 和输出 shape。
- 3. 小型纯文本 LM 完成 overfit 与保存/恢复。
- 4. 真实 DeepSeek-V4 缩小配置完成 Hash-MoE backward。

9.2 Gate B: V100 工作站

- 1. 在不占用现有 Qwen 优化任务的情况下盘点 CUDA/PyTorch/磁盘。✓ 已完成，并经 tmux 向 fastllm 任务留言协调。
- 2. 大文件仅写入 /run/media/ezra/13D010B6FDBC1A06/。✓ 已确认 /home 89% 占用，机械盘约 3.7 TB 可用。
- 3. 跑 MoonViT standalone 与小 LM；记录 SM70 fallback。✓ 真实 MoonViT-SO-400M 前向/反向与评测管线干跑均通过。torch 2.10.0+cu128 wheel 自带 sm\_70，V100 matmul 与 26/26 测试通过，不需要旧版 PyTorch。
- 4. 不尝试加载完整 0731。✓ 保持该约束。
- 5. 小规模 overfit 训练验证信号。✓ 通过（见下节）。

9.3 Gate B 实测：projector overfit 实验 (2026-08-02)

数据：109 条 ComfyUI 产出图的英文描述性 caption (data/comfy\_captions.jsonl，零下载，93 训练 + 16 评测)。设置：冻结 MoonViT-SO-400M (fp32) 与 SmolLM2-135M-Instruct (fp32)，只训 40.1M 参数 PatchMerger projector；placeholder 用现有 token <|endoftext|> (id 0)，不扩 vocab；--max-image-side 448 (每图 192 token)；batch 4，AdamW。

第一次跑 (200 步，lr 1e-3，约 8.6 epoch)：训练 loss 4.25 → 3.74，但 shuffle\_delta 仅 +0.007，在噪声内——模型主要学到 caption 文体先验。第二次跑 (1000 步，lr 2e-3，约 43 epoch) 信号确立：

| 指标                       | 数值             |
|--------------------------|----------------|
| 训练 loss (首窗 → 末窗)        | 4.303 → 3.338  |
| 评测真图 loss                | 3.300          |
| 评测打乱图 loss (16 样本 × 5 轮) | 3.642          |
| shuffle_delta            | +0.343         |
| 训练耗时 (V100)              | 951 秒 (1000 步) |

生成对照 (8 条评测样本，greedy 48 token)：有图输出随图变化且出现内容词 (“Korean dress”、“3D model”、“beard, pastel houses”，token-F1 0.112)；同一模型的 blind 无图输出 8 条逐字节相同 (“beautiful, serene landscape...” ， token-F1 0.082)。三项证据一致：loss 下降、shuffle\_delta 显著为正、生成随图变化且 blind 恒定——projector 确实把图像信息送进了冻结 LM，训练合同在真实权重上成立。checkpoint 在 checkpoints/overfit-smolllm135-1k。

注意：评测集 loss (3.30) 低于训练集末窗 (3.34)，且 43 epoch 已过拟合，shuffle\_delta 部分来自对 93 张训练图的记忆；这一 gate 的目的是验证信号通路，不是产出可用 captioner。

第二个 backbone 复测 (同一数据与超参，placeholder 自动解析为 <|image\_pad|>)：Qwen2.5-0.5B-Instruct 1000 步后训练 loss 3.898 → 3.160，评测真图 3.310 vs 打乱图 3.592，shuffle\_delta = +0.282，耗时 1194 秒，checkpoint 在 checkpoints/overfit-qwen05-1k。两条 backbone 轨给出同量级正 delta，说明该信号来自胶水层与 projector 通路本身，与文本主干选型无关。

第三轨在更大更干净的数据上复测：flickr8k 训练分片 1100 条 (1036 训练 + 64 评测；jxie/flickr8k 镜像，nlphuji 原仓为 gated；因代理网络反复断流，最终直接从 HF 缓存的 train parquet 离线解出，MANIFEST 记录 resolved revision)。Qwen2.5-0.5B，1500 步、batch 8、lr 2e-3 (约 11.6 epoch，记忆成分远小于 comfy 小集)：训练 loss 3.091 → 2.435，评测真图 2.574 vs 打乱图 2.722 (64 样本 × 5 轮)，shuffle\_delta = +0.148，耗时 2102 秒，checkpoint 在 checkpoints/overfit-qwen05-flickr8k。在 10 倍数据、1/4 epoch 数下 delta 仍显著为正——信号不依赖小集记忆。

该 checkpoint 的生成对照同样干净：8 条评测样本有图输出为正常 flickr8k 风格 caption ( “A boy in a red shirt and blue shorts is holding a toy”， token-F1 0.284)；blind 无图输出全部退化为同一句拒绝话术 (“I’ m sorry, but you haven’ t provided an image...” ， token-F1 0.0)。

三轨汇总 (判据均为真图 vs 打乱图 teacher-forced loss 差):

| 数据              | 文本主干         | 步数/epoch    | delta  | 结论 |
|-----------------|--------------|-------------|--------|----|
| comfy 109 条     | SmolLM2-135M | 1000 / 43   | +0.343 | 通过 |
| comfy 109 条     | Qwen2.5-0.5B | 1000 / 43   | +0.282 | 通过 |
| flickr8k 1100 条 | Qwen2.5-0.5B | 1500 / 11.6 | +0.148 | 通过 |

Gate B 结论: 胶水层 + projector 训练合同在真实权重、两个文本主干、两个数据集上全部成立, 可以进入 Gate D (租卡验证 0731 大权重的 Dgrad 通路)。

工作站实测注意项:

- NVML 版本不匹配 (内核模块 580.159.04 vs 用户态库 580.173): `nvidia-smi` 不可用, 但 CUDA 初始化与 kernel 运行正常。不要为修复它而重载驱动或重启——同机其他任务正在使用 GPU。
- MoonViT remote code 与 Transformers 5.x 有两处不兼容: 缺 `all_tied_weights_keys` (已在 `moonvit.py` shim, ViT 无 tied weights, 空映射语义正确); bf16 下 remote code 内部存在 float32/bf16 混用的 `layer_norm` 调用, V100 上 MoonViT 以 fp32 运行 (约 1.6 GB, 可接受)。
- 小上下文文本模型装不下原生分辨率视觉 token: 640×480 照片产生 1064 个合并 token, 加 prompt 后超过 tiny-gpt2 的 1024 positions, 表现为 scatter-gather device assert (异步报错会漂移到无关位置, 需 `CUDA_LAUNCH_BLOCKING=1` 定位)。--max-image-side 控制 token 数; 正式 0731 的 128k 上下文无此问题。
- HF 下载须走本机代理 127.0.0.1:7890 (约 0.4–0.5 MB/s), 且该仓库默认 Xet 传输在代理下会挂起, 必须设 `HF_HUB_DISABLE_XET=1`。
- 复用现有 venv (torch 2.10.0+cu128 + transformers 5.12.1); pytest 用 `pip --target` 装在独立目录, 不改对方环境。
- 工作站负载高 (其他 agent 编译/跑 inference server) 时, 机械盘上的 torch import 可达 90 秒以上; 批处理脚本超时预算要放宽。

9.4 Gate B+: 租前全链路彩排 (2026-08-03, 正式训练的对照组)

目的不是能力验证, 而是把租期闭环的每一个环节在 V100 上先炸一遍: 离线取数 → 切分 → 训练 (checkpoint 流式传 HF) → trained/blind/random 三组评测 → 聚合 → 全部产物落 HF。设置: SmolLM2-135M-Instruct + 真实 K3 MoonViT-V2 权重 (eager), flickr8k 1200 条 (train parquet 本地直读, 零下载; 该数据集每行一图、只用 caption\_0, 行切分即图切分, 无泄露), 1000 训练 / 200 评测, 400 步、batch 4、lr 5e-4 (Baseten 配方默认值), placeholder 为现有 token `<|endoftext|>`, --max-image-side 448。

| 组别                    | vision token-F1 | blind token-F1 | gap    |
|-----------------------|-----------------|----------------|--------|
| 训练后 projector (400 步) | 0.1565          | 0.0391         | +0.117 |
| 随机 projector (管线对照)   | 0.0584          | 0.0391         | +0.019 |

训练 loss 4.30 → 3.06 (前 200 步)。三点结论: (1) 训练组 gap 是对照组的 6 倍, 管线对 “是否训练过” 可判别——评测不是摆设; (2) checkpoint 流式上传经代理真实落地 (HF 上 step-000200/000400 含 projector fp32+bf16、training\_state、history.json), 租期中断不丢训练; (3) 全部评测原始输出 (逐条预测 + 元数据) 与 SUMMARY 已公开在 `eval/v100-smoke-smolLM135/`。注意: 400 步远低于 grokking 区间 (约 900 步起), 135M 主干 + caption 任务的绝对 F1 不代表正式结果; 此表是正式训练的**对照组基线**。

本轮同时打通了下载通道的完整答案 (此前三种路径全部失败): hf\_transfer 在代理下 0 字节挂起、hf-mirror 限流、工作站的 datasets+dill 无法 pickle pyarrow 的 MonthDayNano (任何本地 parquet 都炸 load\_dataset)。最终方案: `aria2 -x8 -c --max-tries=0` 预取 parquet 分片 (xet-bridge CDN 随机 TLS 重

置/403, 无限重试磨过去) + fetch 全程离线读本地 parquet (raw pyarrow, 跳过 datasets 指纹层), 新增 tools/prefetch\_parquet.py 与 tools/fetch\_art\_data.py (0xSero art 数据集的离线复刻, schema 与 build\_train\_mix 兼容, 有测试)。另修正一处数据规格错误: MMMU-Pro 仓库不存在裸 standard config, 已固定为 standard (10 options)。

同日下午的带宽攻防补充了一课: (1) ModelScope 存在与 HF 逐字节一致的镜像 (lmms-lab/textvqa、lmms-lab/DocVQA、AI-ModelScope/MMMU\_Pro、showlab/ShowUI-desktop), 境内直连可达 8.8 MB/s, 但工作站 IP 在约 1.5 小时高强度拉取后被 CDN 边缘渐进限速至 0 B/s (按 IP 不按账号, token 与 IPv6 均无效; 本机家庭 IP 同文件仍有 5.3 MB/s); (2) 随即搭建的“本机 ModelScope → scp 回传工作站”中继受 Tailscale 链路限制 (3.7 s RTT, 多流聚合仅约 250–400 KB/s), 与代理通道同速且挤占家庭带宽, 应用户要求退役; (3) 最终全部十个数据源统一由工作站经 Clash 代理直下 (moondata 八个评测/训练集 + moonart 的 WikiArt/fashion), 代理总带宽封顶约 250 KB/s (并行不扩展, 单连接约 50 KB/s 即节点拥塞), 剩余约 15 GB 预计 16 小时; mihomo 核心未开 external-controller, 换节点只能由用户在 GUI 操作, 这是当前唯一可能提速一个数量级的杠杆。也曾评估 \$0.056/h 的香港数据盒 (2–3 小时收工、总成本 < \$0.5) 作为替代, 用户选择免费慢磨方案。

9.5 Gate B 全量 mix early-alignment (2026-08-04, V100, 工程/信号闸门)

目的: 在正式 train\_v1 mix (59,198 行 packed parquet) 上验证“parquet 消费路径 + 全量数据 + early alignment + 全套评测 + 上传”的租期闭环, 同时作为正式 0731 训练的本地对照组。设置: Qwen2.5-0.5B-Instruct(冻结) + K3 MoonViT-V2(冻结, eager), 只训 projector(33.6M 参数), 2000 个 optimizer step、恒定 lr 5e-4、--max-image-side 448。历史参数 batch 8 实际不是一次 8 样本 forward, 而是 micro\_batch\_size=1 下串行 8 次 forward/backward 后更新, 因此本轮只见过 16,000 样本, 即 59,198 条 mix 的约 0.27 epoch; 历史 answer-token 数未记录, 不能精确补齐。占位 token 自动解析为 Qwen 词表已有的 <|image\_pad|> (ID 151643, 不扩词表)。

训练结果 (train.log 实测):

| 指标                      | 数值                                                    |
|-------------------------|-------------------------------------------------------|
| loss (首窗口 → 末窗口)        | 6.413 → 3.006 (单步 10.19 → 3.01, 最低 2.718 @ step 1750) |
| held-out 真实 loss (32 条) | 3.175                                                 |
| held-out 打乱图像 loss      | 3.902                                                 |
| shuffle_delta           | +0.727                                                |

历史口径下 shuffle\_delta +0.727 是此前三条 smoke 轨 (+0.343 / +0.282 / +0.148) 的两倍以上: 正确图片已经影响答案 loss, 视觉接口可学习性成立。但留出集只是 shuffle 后末尾 32 条, 乱配使用循环平移而非多组随机 derangement; 加上训练量仅 0.27 epoch, 该数字不能证明充分收敛, 五项低分也不能写成架构能力上限。本轮同时炸出两个租前必须暴露的问题, 均已定位:

- 1. **checkpoint 流式上传全部失败** (step 500/1000/1500/2000 共 4 次): 训练期间代理 SSL 持续重置 (UNEXPECTED\_EOF\_WHILE\_READING 于 S3 multipart PUT), 重试 5 次仍败。训练本身无损, 4 个 checkpoint 本地完好; 按“上传下载串行”纪律, 等评测结束带宽空出后手动一次性补传。教训: 租机上 checkpoint 上传同样要与数据集预取错开。
- 2. **10 个评测进程全部启动即崩**: 训练器默认占位 token 是 Qwen 的 <|image\_pad|>, 而评测器默认是 DeepSeek 的 <|image|>——两者默认值不一致, Qwen tokenizer 里没有后者, resolve\_placeholder\_token\_id 按设计拒绝扩词表而报错。修复为候选自动探测 (DeepSeek token 优先、Qwen token 兜底; 显式指定仍严格报错), 85/85 测试通过 (commit 034be8b)。此 bug 若不在本地炸出, 租机首跑 DeepSeek 时训练器会以旧默认 <|image\_pad|> 直接崩在 0731 tokenizer 上——本地彩排的价值正在于此。

9.5.1 五基准评测终表(selection 半侧, 1024px, 逐条原始输出已公开于 HF eval/v100-fullmix-qwen05/)

| 基准                   | 指标           | trained     | random | blind | 读法                                |
|----------------------|--------------|-------------|--------|-------|-----------------------------------|
| TextVQA (250)        | soft-VQA     | 0.081       | 0.000  | 0.000 | 真实对齐, 距成熟 VLM 远                   |
| DocVQA (100)         | ANLS         | 0.039       | 0.000  | 0.000 | 同上, 实体级读错居多                       |
| OCRBench (100)       | exact        | 0.000       | 0.000  | 0.000 | 地板; 小字 OCR 超出 0.5B 能力             |
| ScreenSpot (100), 域内 | 解析率 / 精度 @50 | 0.51 / 0.01 | 0 / 0  | 0 / 0 | 格式学会一半, 点位退化 (常数坐标, 中位误差 729/999) |
| MMMU-Pro (150)       | exact        | 0.073       | 0.000  | 0.000 | 修 复 输 入 后 2.0%→7.3%; 宽松提取 18%     |

判别力三条全部成立: vision 严格大于 blind; trained 严格大于 random (随机 projector 臂五项全零——冻结 LLM 收到噪声视觉 embedding 时输出不了任何切题内容); shuffle\_delta +0.727。Gate B 的最小结论是: **信号真实、接口可学习、评测可判别、checkpoint/上传管线可用 (但易受代理抖动影响, 需错峰)**。它不是充分训练后的能力评测。0.5B 冻结主干 + 33.6M projector + 仅 1.6 万样本见过的训练量只承担 early-alignment 对照角色; 下一步先用等 examples-seen 的 0.5B/1.5B/3B 纯文本主干、projector/LoRA、分辨率与因果控制消融定位瓶颈, 再估算 0731 Hash-MoE 实验。

9.5.2 0.5B 主干的容量混杂

Qwen2.5-0.5B-Instruct 是纯文本 Qwen2ForCausalLM, 没有继承原生视觉能力, 但它的容量本身显著影响实验。OCR、复杂视觉推理、指令/输出格式遵从均受 0.5B 语言主干的能力上限约束, 所以 Gate B 的低绝对分数更接近能力下界, 不能外推完整 0731 的最终分数。反过来, 小型 dense Qwen 与 DeepSeek-V4 Hash-MoE 的表示空间和优化曲面不同; 它可能更易对齐, 也可能因容量不足更难对齐, 因此 +0.727 的收敛速度同样不能预测 0731 的训练速度。

不受这一混杂影响的最小结论只有: 在一个确实纯文本的冻结 LM 上, 训练后的 MoonViT-V2 projector 相对 random/blind 产生了可重复的图像依赖信号。故 Gate B 的正式定位降格为“工程与信号闸门”, 不是能力代理。若在租机前追加中间尺度对照, 应优先使用配置明确为 ForCausalLM 且无 vision\_config 的约 3B 纯文本主干 (7B 可选), 保持相同 train mix、seen-record 数、分辨率、scratch 初始化和 selection benchmark; 比较 loss、shuffle 统计及五项 vision-blind。该实验能量化容量敏感性, 但仍不能替代完整 DeepSeek Gate D。当前工作站未缓存 3B/7B 纯文本权重, 尚未运行此对照。

9.5.3 证据边界: 原生 VLM 不是 DeepSeek 代理

必须区分两个名字相近但因果意义完全不同的 Qwen 实验。Gate B 的冻结文本主干配置是 Qwen2ForCausalLM, 且 vision\_config 为空; 它本身没有图像输入路径, 视觉信号只能来自外接 K3 MoonViT-V2 与本项目训练的 projector。因此 shuffle\_delta 和 trained/random/blind 差异可以证明“纯文本 LM 接口可学习”。训练器现已加入硬防线: --text-model 若暴露 vision\_config 会直接拒绝, 原生 VLM 只能进入独立的 stock-eval 路径。

另一方面, Qwen3.5-4B 对照的配置是 Qwen3\_5ForConditionalGeneration 且自带 vision\_config; 它使用官方视觉塔、processor、chat template 和既有多模态对齐, 完全不经过 MoonViT-V2 或本项目 projector。它的高分只校验评测数据、图像读取、输出约束和评分器, 并给出成熟小型 VLM 的参照上界; **不得据此推断 projector 能快速映射到 DeepSeek**。证据链严格分为: (1) 原生 VLM 阳性对照 = 评测有效; (2) 纯文本小主干 Gate B = 接口可学; (3) tiny DeepSeek-V4 Hash-MoE = 路由与梯度合同; (4) 完整 0731 Gate D/正式训练 = 目标可行性与能力, 前三项均不能替代第四项。



原生 Qwen3.5-4B 的修复后阳性对照如下。它与 Gate B 使用相同的 selection 半侧、1024px 上限和 strict scorer；“vision” 列是 Qwen 自带视觉塔的结果，不是本项目 projector 的结果。

| 基准               | 指标             | Gate trained | B Gate blind | 原生 Qwen vision | Qwen blind  |
|------------------|----------------|--------------|--------------|----------------|-------------|
| TextVQA (250)    | soft-VQA       | 0.081        | 0.000        | 0.820          | 0.031       |
| DocVQA (100)     | ANLS           | 0.039        | 0.000        | 0.926          | 0.071       |
| OCRBench (100)   | exact          | 0.000        | 0.000        | 0.900          | 0.000       |
| ScreenSpot (100) | parse / acc@50 | 0.51 / 0.01  | 0 / 0        | 0.86 / 0.76    | 0.99 / 0.01 |
| MMMU-Pro (150)   | exact          | 0.073        | 0.000        | 0.300          | 0.280       |

前三个感知/OCR 基准与 ScreenSpot 的 vision-blind 差距很大，证明图像读取与评分管线已恢复健康；MMMU-Pro 只有 +0.020，30% 中绝大部分来自题干、选项与语言知识先验，不能全部计作视觉能力。这正是强制报告 blind 的价值，也再次说明原生 VLM 总分不能成为 DeepSeek 映射证据。

该对照还产生了一次必须保留的完整性事故记录：首次运行中，第二个 3.99 GB safetensors 分片虽字节数正确，SHA-256 却为 547d2f...8627（官方 cb544b...e188），而模型索引恰把全部视觉塔权重放在该分片，导致模型把真实图片一致描述成空白。高分辨率样本又触发 OOM，并被工作站的 NVML 驱动/库版本不一致掩盖成 allocator assert；开放式长回答则会被严格短答案指标计零。修复措施为：逐分片 SHA-256 manifest、--max-image-side 1024、按指标约束短答案/选项字母/归一化坐标。损坏运行的产物从未上传；修复套件在一次完整哈希验证后运行，原始逐条输出与 suite provenance 单独发布。

9.5.4 误判审计（应用户要求：先怀疑判别器，再怀疑模型）

对五个基准逐条重打分，用逐级放宽的提取器量化“判错”成分。结论：判别器基本清白，最宽提取也最多 1-2 分——textvqa 单复数漏判 0 条、子串漏判 4 条（+1.6% 封顶）；screenspot 不可解析的 49% 中 48 条是纯散文无坐标（模型在描述而非点击），仅 1 条格式边缘漏判；ocrbench 用官方 contains 式口径依然全零；docvqa 无 32-token 截断。但审计抓到两个真输入侧 bug：(1) MMMU-Pro 的 options 列在 parquet 里是字符串装的 Python 列表字面量，旧代码直接 join 字符串导致选项被逐字符拆行，prompt 不可读；(2) 渲染选项缺字母标签，而参考答案是字母（“B”），模型无从对应。修复（解析字面量 + A./B./C. 标签，commit bf3413b/f9b94a5，含测试）后离线重建 300 条数据并重测：2.0% → 7.3%（严格），宽松“字母出现即算”18%——0.5B 输出多为推理散文、没有落字母的习惯，严格 exact-match 只承认单字母输出。此基准的 2.0% 旧读数作废，以修复版为准。

评测补跑（5 基准 × trained/random × vision/blind）已全部完成并聚合；仓库归置（Qwen 对照产物归入 gate\_b\_qwen05\_v100/、smoke 产物归入 gate\_b\_smoke\_smollm135\_v100/、README 标注与 DeepSeek 目标无关）与 4 个 checkpoint 补传按串行纪律排在 4B 下载之后。

10 冻结语言主干中的视觉感知涌现：V100 方向筛选实验

本章对应新的租前方向筛选阶段；约束是只使用现有 V100 32 GB，不查看 final evaluation half、不租服务器、不启动完整 DeepSeek-V4。研究问题是：(1) frozen text LM 何时开始在可测指标上依赖正确图片；(2) MoonViT 可线性解码的信息经过 projector 后保留/丢失什么；(3) 视觉属性在哪些 LM 层与 token 位置可解码并影响答案；(4) 下一轮应优先归因于训练量、projector、空间/OCR、语言容量还是冻结主干。

可证伪假设预注册如下：若 MoonViT probe 高而 projector 输出骤降，则支持 projector 信息瓶颈；若 projector/LM residual probe 高而生成与干预恢复低，则支持语言适应/解码瓶颈；若所有 checkpoint 曲线仍持续上升，则先支持训练量不足；若 0.5B 在等 examples-seen 下被 1.5B 清晰超过，才提高语言容量

瓶颈证据; 这些 probe/相似度只作相关性读数, 因果结论必须来自 blank/wrong-image、mask、feature/activation patching 的答案 logit 变化。

10.1 实验基础设施与真实计量 (包 1, 2026-08-04)

环境快照 run v100-perception-infra-20260804-a: 起始 commit 20c2556; Tesla V100-PCIe-32GB (34,072,559,616 B, sm\_70); Python 3.12.11; torch 2.10.0+cu128; CUDA build 12.8; cuDNN 91002; Transformers 5.12.1; safetensors 0.8.0。nvidia-smi 仍因已知 NVML 用户态/内核不匹配失败, 但 PyTorch CUDA 分配与计算正常。环境 JSON、pip freeze、GPU device users 和 git dirty state 均提交于 experiments/v100\_perception\_20260804/infra/environment/。

冻结 MoonViT-V2 特征缓存采用分片 safetensors + MANIFEST: 逐样本记录 ID、原图 SHA-256、原图尺寸、feature shape/dtype、shard offset; 全局记录 MoonViT config/weights hash、分辨率、数据 logical-row hash、cache format version; 每个 shard 自带 bytes 与 SHA-256。有效 run v100-perception-cache-20260804-retry1 在 448px 缓存 64/64、0 失败、14.274s、峰值 1,948,235,264 B; 4 个 shard 全部二次 hash 和逐 ID 读回通过, records hash 98f81a46...55d2a, MoonViT 权重 hash 01436a95...ced24。第一次 foreground SSH 尝试因 stdout 断开触发 BrokenPipe, 只有 3 条临时行且无 manifest, 明确标记 invalid 并保留, 不参与任何结论。

真实 step-time 使用同一 64 条、同一 scratch projector、相同 448px cache, 5 step 中排除首个 CUDA warm-up, 结果如下。三组的 micro\_batch\_size 都是 1, actual\_batched\_forward=false; 所谓 batch 4/8 是串行 gradient accumulation。

| micro batch | grad accum | mean s/optimizer step | examples/s | peak GPU memory |
|-------------|------------|-----------------------|------------|-----------------|
| 1           | 1          | 0.0747                | 13.38      | 3.31 GB         |
| 1           | 4          | 0.2720                | 14.70      | 3.65 GB         |
| 1           | 8          | 0.5390                | 14.84      | 3.65 GB         |

因此旧 batch 8 的真实成本约为 0.54s/optimizer step (在 0.5B + 已缓存视觉特征上), 不是一次 8 样本 forward。线性外推到 accumulation 64 约为 4.3s/step, 但该数字仍不能外推 DeepSeek; 它只用于证明计量语义与 V100 小模型预算。retry2 的单步计时有效, 但审查发现它仍在启动时实例化了不参与 forward 的 401M MoonViT, 故其 4.92–5.25 GB peak 不作为缓存结论; 修复后 retry3 完全不构造视觉塔, peak 降到 3.31–3.65 GB, 且三份 report 均记录 vision\_tower\_instantiated=false。两次 step-0 无效启动也完整保留: 第一次在线 HEAD 超时; 第二次启用 offline 后未设置 HDD cache 路径, 三臂均失败并暴露零成功行 CSV 的 driver bug。下一包将生成六类 synthetic minimal-pair 数据; checkpoint 轨迹、probe、干预和方向判定尚未运行, 当前不满足租卡前 go 条件。

10.2 Gate C: Vast 只读调研

2026-08-02 12:23 (UTC+8) 用官方 Search Offers API 查询 verified、rentable、可靠度至少 0.98、至少 4 张卡、单卡至少 80 GB、总显存至少 320 GB 的 on-demand offer。市场是动态的, 以下价格只用于预算, offer ID 不应写进自动租用脚本。

| GPU               | 总显存      | 约美元/小时  | 判断                            |
|-------------------|----------|---------|-------------------------------|
| 4×A100 PCIe 80 GB | 320 GB   | \$4.00  | 最便宜; 无 NVLink, 仅作兼容性/低价 smoke |
| 4×A100 SXM4 80 GB | 320 GB   | \$6.94  | 300 GB/s NVLink; 优先训练候选       |
| 4×H100 PCIe 80 GB | 约 319 GB | \$8.00  | 新架构; 仍需核验拓扑和 Dgrad            |
| 4×H100 SXM 80 GB  | 约 319 GB | \$10.75 | 性能优先候选                        |

|                   |          |         |                          |
|-------------------|----------|---------|--------------------------|
| 8×A100 SXM4 80 GB | 640 GB   | \$10.37 | 显存余量最大且价格低于当时 4×H100 SXM |
| 4×H200 141 GB     | 约 562 GB | \$15.74 | 低 OOM 风险，成本高             |

正式候选还应要求 NVLink/P2P、至少 512 GB RAM、至少 1.5 TB 本地盘并现场复核 CUDA/驱动。查询结果中最低价 A100 PCIe 只有约 617 GB 可用盘，不满足完整缓存计划；A100 SXM4 候选有约 10 TB 盘。当前阶段只记录 offer，明确不创建实例。

当晚第二次查询（增加 RAM ≥500 GB、盘 ≥1.5 TB 过滤，33 个 offer）要点：4×A100 SXM4 降至 \$6.41/h（961 GB RAM、2 TB 盘，Gate D 首选）；4×H100 PCIe \$6.93/h（6392 GB 盘，性价比突出）；8×A100 SXM4 \$10.30/h（11 TB 盘，情景 B 兜底）；4×B200 \$21.25/h。新出现的 4×RTX PRO 6000 96 GB（Blackwell，原生 FP4）\$4.54/h 但总线无 NVLink 且 FP4 kernel 支持未验证，仅作参考。

**架构修正：**A100 为 Ampere，无 FP8/FP4 Tensor Core，0731 的 NVFP4 权重在 Ampere 上没有确认的内核路径，只能解量化至 bf16（568 GB），而 4×A100 的 320 GB 装不下——4×A100 实际上无法加载原生权重，Gate D 首选改为 **4×H100 PCIe**（Hopper FP8 + FP4 专用内核）。8×A100 SXM4（640 GB）仅作为解量化情景 B 的兜底。

10.2.1 最终账单（含下载时间、网络、存储、装机余量）

流量与存储用报价接口的真实计费字段核算：权重下载 160 GB，H100 PCIe 候选流量 \$13.33/TB 约 \$2.13（重传余量加倍 + 数据集/Docker 镜像约 \$1，共约 \$4）；上传仅约 134 MB projector + 800 MB 视觉塔（首次）+ JSON，约 \$0.01。存储按 storage\_total\_cost 约 \$0.001–0.005/h，租期内几分钱——**但实例 stop 后存储继续按 \$/GB/月计费（约 \$0.107/GB/月，2 TB 停一周约 \$53），结束必须 destroy 而不是 stop。**装机与依赖调试按 +1.5 h GPU 时间计余量。

| 阶段（4×H100 PCIe，\$6.93/h）               | 乐观           | 基准            | 悲观           |
|----------------------------------------|--------------|---------------|--------------|
| 装机 + Docker + 环境调试余量                   | 1 h          | 1.5 h         | 2.5 h        |
| 0731 权重下载 160 GB（27 分钟理论最优；断流重传见 R4）   | 0.7 h        | 1 h           | 2 h          |
| MoonViT-V2 视觉塔下载 800 MB（sha256 校验）     | 约 0.05 h     | 约 0.05 h      | 0.2 h        |
| 训练与评测数据约 30 GB                         | 0.3 h        | 0.5 h         | 1.5 h        |
| Gate D 判定（加载→前向→单 batch backward→20 步） | 0.5 h        | 1 h           | 1 h          |
| 对齐训练约 3000 步（checkpoint 随传）            | 3 h          | 4 h           | 5 h          |
| 机上 benchmark 三组对照                      | 1.5 h        | 2 h           | 2.5 h        |
| 权重与结果回传                                | 0.2 h        | 0.2 h         | 0.3 h        |
| 合计时                                    | 7.2 h ≈ \$50 | 10.2 h ≈ \$71 | 15 h ≈ \$104 |

流量费三档均约 \$4–5。**情景 A 最终账单：\$55（乐观） / \$75（基准） / \$110（悲观），按 \$120 预算。**

带宽与耗时已按报价接口的 inet\_down 字段核算：H100 PCIe 候选实测下行 2217 Mbps（约 277 MB/s），理论 160 GB 约 10 分钟；考虑 HF CDN 单连接限速（40–100 MB/s）与断流重传（本地实测 802 MB 在慢代理下耗时 2h46m），基准按 1 h、悲观按 2 h 计，租机筛选条件要求 inet\_down ≥ 1000 Mbps 并用 aria2/hf\_transfer 多连接下载。checkpoint 上行流量每个约 300 MB（projector fp32+bf16+优化器），每 500 步一次，分钟级完成，不影响训练计费。训练日志（train.log）与 history.json 随 checkpoint 一并上传，社区可见完整训练过程。

情景 A' (R3 命中, H100 无法跑 FP4 前向): 转 4×B200 (\$21.25/h), 同排程基准 10 h ≈ \$213; B200 有原生 FP4 Tensor Core, Dgrad 通过率也更高。决策成本为已耗的装机+下载 1.5–2 h (约 \$10–14)。情景 B (FP4 不可反传且 B200 不可用): 8×A100 SXM4 \$10.30/h, 权重解量化至 bf16 (568 GB) 转换 1–2 h 且训练约慢 3 倍, 合计 20–30 h ≈ \$210–310 (该候选流量 \$1.33/TB, 网络几乎免费)。建议总预算: \$120 起步 (情景 A), 预留 \$220 (情景 A'/B), 上限 \$350; 预期实际花费 \$75–110。决策点在租后第 2–3 小时: Gate D 不通过即 destroy 止损, 损失约 \$20。

10.3 训练显存算术 (每卡, 权重张量并行切分, 视觉塔/projector 每卡复制)

冻结 LLM 与冻结视觉塔意味着: LLM 侧 没有优化器状态、没有参数梯度——AdamW 只挂在 projector 上 (train\_overfit.py 里 AdamW(projector.parameters()), LLM 与视觉塔 requires\_grad\_(False), 视觉塔前向在 no\_grad 里, 梯度只需以激活形式穿过 LLM 回到 projector, 不需要对视觉塔反传)。优化器全套 (权重 fp32 + m/v + 梯度) 只有约 0.55 GB。真正的变量是 LLM 权重本体和 Dgrad 路径的激活。

| 组成 (每卡)                      | 情景 A: 4×RTX PRO 6000, FP4 权重 TP=4 | 情景 B: 8×A100, bf16 权重 TP=8 |
|------------------------------|-----------------------------------|----------------------------|
| LLM 权重                       | 160/4 = 40 GB                     | 568/8 = 71 GB              |
| LLM optimizer + 参数梯度         | 0 (冻结)                            | 0 (冻结)                     |
| MoonViT-V2 权重 (bf16/fp32)    | 0.8–1.6 GB                        | 0.8–1.6 GB                 |
| projector 权重 + AdamW + 梯度    | 约 0.55 GB                         | 约 0.55 GB                  |
| LLM 激活 (grad ckpt, seq ≤700) | 1–3 GB                            | 1–2 GB                     |
| 杂项 (CUDA ctx/碎片/通信 bucket)   | 5–10 GB                           | 4–6 GB                     |
| 合计 / 可用                      | 约 47–55 / 96 GB                   | 约 77–79 / 79.1 GB          |
| 判定                           | 余量 41–49 GB, 健康                   | 贴顶, 高风险                    |

激活估算依据: 开 gradient checkpointing 后只存段边界 (61 层 × seq 700 × 4096 × bf16 约 0.35 GB) 加段内重算临时; micro-batch 4–16 线性放大。seq 700 来自候选训练 --max-image-side 640 (方形图最坏 529 视觉 token + 文本 ≤ 700), 但 640/1024 策略须经分辨率消融后再锁定。情景 A 的生命线是 FP4/FP8 原生加载成立 (R1–R3); 一旦需要 bf16, 任何 4×96GB 级机器都装不下 (568/4 = 142 GB > 96 GB), 只剩 8 卡。情景 B 在 8×A100 上余量不足 2 GB, 必须 micro-batch 1 + 更激进 checkpointing, 实测 OOM 即升 4×B200 (142 GB/卡, 余量约 50 GB, \$21.25/h, 账单已含)。

10.4 Gate D 风险清单 (租卡前预演)

不保证一次成功。下表是全部已识别坑点、概率判断与止损方案; 核心原则是失败成本锁死在租后第 2–3 小时 (Gate D 判定, 损失约 \$20), 任何一项失败都有明确的下一步, 而不是现场想办法。

| 风险                                                                | 概率  | 缓解 / 止损                                                                                                                |
|-------------------------------------------------------------------|-----|------------------------------------------------------------------------------------------------------------------------|
| R1 NVFP4 权重 Dgrad 不可用 (推理内核不支持对输入 embedding 求梯度)                  | 中–高 | 核心风险。Gate D 单 batch backward 判定; 失败即退租转情景 B (解量化 bf16) 或情景 A' (B200 原生 FP4 内核重试)。                                      |
| R2 Transformers 加载原生 0731 大权重失败 (quantization config 格式未被 5.x 支持) | 中   | Gate D 第一步即原生加载测试; 备选为 vLLM loader 导出 bf16 权重副本 (同时解决 R1)。                                                             |
| R3 FP4 前向内核在目标卡上不可用                                               | 低–中 | 主机器 RTX PRO 6000 即 Blackwell (sm_120, 原生 NVFP4), 此项已从 “中” 降级; 但硬件支持 ≠ 内核带 Dgrad——Gate D 第 0 步用 tools/gate_d_dgrad.py 单 |

|                                                                                                            |     |                                                                                                                                                                                                                                                                 |
|------------------------------------------------------------------------------------------------------------|-----|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|                                                                                                            |     | 层 reproducer 单独判定。失败转 4×B200 (\$21.25/h) 或情景 B。                                                                                                                                                                                                                 |
| R4 权重下载断流/限速                                                                                               | 高   | 本地实测 802 MB 在慢代理下耗时 2h46m; 租机标称 2217 Mbps 但 HF CDN 单连接限速 40–100 MB/s, 160 GB 理论 27–67 分钟, 断流可拖至 2h+。用 aria2/hf_transfer 多连接 + 断点续传循环 (已验证的做法), 账单已含 0.5–2h 敏感性。                                                                                                 |
| R5 marketplace 实例被中断                                                                                       | 中   | checkpoint 流式上传 (每 500 步, 含 optimizer/RNG, 28/28 测试); 中断后换机 --resume 精确续训, 损失不足 10 分钟训练。                                                                                                                                                                        |
| R6 机器环境与宣传不符 (NVLink 拓扑、驱动、盘速)                                                                             | 低–中 | 开机 10 分钟内 nvidia-smi topo -m + 盘速快测, 不符当场退租换机, 损失不足 1h 租金。                                                                                                                                                                                                      |
| R7 情景 B 显存算术 (bf16 568 GB vs 8×A100 640 GB)                                                                | 低   | 冻结 LLM + activation checkpointing 下单 batch 激活很小, 72 GB 余量足够; 4×H200 (564 GB) 装不下, 明确排除。                                                                                                                                                                         |
| R8 Hash-MoE tid2eid 在多卡张量并行下的分布行为                                                                          | 中   | hook 方案已在真实 tiny DeepseekV4 类验证; Gate D 的单 batch backward 在大权重多卡下复验, 占位位置路由一致性有断言。                                                                                                                                                                              |
| R9 训练数据下载 (约 30 GB) 经代理再耗 1–2 h                                                                            | 中   | 提前把训练数据镜像到项目 HF 仓库 (随 checkpoint 上行通道同路), 租机从 HF 直下; 计入装机时间。                                                                                                                                                                                                    |
| R10 MoonViT-V2 bf16 与 fp32 参考的特征偏差                                                                         | 低   | fp32 参考已锚定 (eager/sdpa 差 3.1e-05); Gate D 记录 bf16 实测差 (预期约 1e-2 相对), 超差则视觉塔回 fp32 (仅多约 800 MB 显存)。                                                                                                                                                              |
| R11 租期内时间不够闭环                                                                                              | 低–中 | checkpoint 流式上传保证权重永不丢; benchmark 三组对照在机上跑但数据落盘 JSON 可增量上传; 最坏情况先公开 checkpoint + 部分指标。                                                                                                                                                                          |
| R12 多卡分布策略与 PCIe 拓扑 (4×RTX PRO 6000 无 NVLink, PCIe 5.0 x16 54.2 GB/s; device_map="auto" 朴素模型并行的激活回传走 PCIe) | 中   | 训练吞吐的直接风险: 3–5 s/步 的估计在 PCIe + 重算下可能偏乐观。多卡路径已定型为单进程 device_map="auto" (LLM 冻结, 无需权重梯度分片; vLLM/SGLang 推理 TP 不可用于反向训练)。Gate D 实测单步耗时: ≤8 s 维持; 8–15 s 重算步数保 benchmark; >15 s 验证 transformers 原生 tp_plan 或换 NVLink 机型 (H100 SXM \$10.75/h); 账单按 5 h 悲观档已可吸收 2 倍减速。 |

## 10.5 Gate D: 正式租卡前

分阶段判定 (完整版见 docs/gate-d-runbook.md §7, 2026-08-03 评审修订, 各步独立记录不合并):

0. 配置发现 + 最小 Dgrad reproducer (tools/gate\_d\_dgrad.py: 打印量化方案; 只取一层真实 quantized linear 权重切片, 判定 input.grad 有限非零、weight.grad 为 None)。
1. nvidia-smi topo -m + 盘速快测 (不符当场退租)。
2. 原生 0731 权重加载成功; 文本短前向正常。
3. 单图短序列 forward (placeholder 注入)。
4. 单 batch backward, projector 梯度有限且非零, LLM/MoonViT 无梯度。
5. hook × activation checkpointing 数值一致性 (开/关梯度检查点 projector 梯度 allclose) + batch > 1 多图位置一致。

6. 多卡路径定型 (device\_map="auto") + 实测单步耗时分档 ( $\leq 8$  /  $8-15$  /  $>15$  s)。  
7. 20 step 无 OOM/NaN; --resume 从流式 checkpoint 恢复一次且轨迹连续。

10.6 租期闭环排程 (2026-08-02 定价)

核心约束:租期一结束就没有机器能跑动 0731 做 benchmark 或回传权重,因此训练、benchmark、上传必须同在一次租期内闭环。交付物只有 projector + 评测 JSON + 报告,与 GLM 社区只发布 projector 一致,不回传 160 GB 主干。checkpoint 发两个精度: fp32 master (约 134 MB, 复现/续训用) 与 bf16 serving (约 67 MB,0731 激活为 bf16), 租期内由训练产物现场转换。推理侧接入 (vLLM/SGLang/llama.cpp/fastllm 补丁点、Hash-MoE 注意事项、验收检查) 已写成 docs/inference-integration.md (2026-08-03 重写为 MoonViT-V2 版), 作为后续给推理引擎提 PR 的合同文档; 要点: vLLM 与 SGLang 均已 Day-0 支持 Kimi-K3 (含 MoonViT3d 视觉塔) 且均有 DeepSeek-V4 文本栈, patch 面只剩 projector 模块、placeholder 扩展与 Hash-MoE 路由检查; placeholder 固定为现有 <| image |>(id 129279) 禁止扩 vocab, 合并只替换 embedding 向量、input\_ids 保留 placeholder 供 Hash-MoE 路由。

Baseten 社区实验 (baseten.co/blog/glm-52-with-vision, checkpoint baseten/GLM-5.2-Vision-NVFP4) 只作为配方先验: **constant lr 5e-4**、global batch 64、约 66k 条短 QA、2 epoch  $\approx$  2070 optimizer steps, grokking 在第一 epoch 末附近出现。它不是本项目的时长承诺。审计发现当前训练器的历史 batch\_size=N 是 micro\_batch\_size=1 下串行 N 次 forward/backward; 若照抄 64, 每个 optimizer step 会执行 64 次视觉塔和 LLM 前后向, 3-6 s/step 与 2-4 h 估计均无效。新版训练器已改用 micro-batch、gradient accumulation、effective batch、examples seen 与 answer tokens 的明确计量, 并暂时拒绝伪造 micro\_batch\_size > 1。正式租卡前必须实现 padded multi-example forward, 在小主干上实测 micro batch 1/2/4 的吞吐与显存, 再由目标 examples/token 数反推 optimizer steps 和租时。

分辨率也从“写死”改为待证: 先跑训练 448/640  $\times$  评测 448/640/1024 的固定子集矩阵, 只有在小字 OCR 收益、分布失配、视觉 token 数和吞吐都可接受时才采用训练 640/评测 1024。容量消融按相同 examples seen 比较 Qwen2.5 0.5B/1.5B/3B 纯文本主干; 随后才做 projector scratch/warm-start、顶部 LoRA、blank/fixed/shuffle/patch-permutation 与 synthetic minimal-pair 控制。完整协议在仓库 docs/ablation-protocol.md。

停训判据不看 loss, 看两条 gap: 主判据是 benchmark 分数 - blind 分数的 gap 随 checkpoint 的曲线, 平台即停; 辅助判据是留出集 shuffle\_delta > 0.1。参考锚点: projector-only 的 TextVQA 现实预期 20-30% (blind 约 10-15%, 成熟 VLM 60+); 达到 GLM 社区实验同量级 (grounding parse 率 >80%、Acc@50 个位数) 即成功。

| 阶段           | 时长      | 说明                                                                                                                      |
|--------------|---------|-------------------------------------------------------------------------------------------------------------------------|
| 装机 + 下载权重    | 1-1.5 h | 160 GB; 好主机 1-2 GB/s                                                                                                    |
| Gate D 判定    | 0.5-1 h | FP4 Dgrad 失败则当场退租 (损失约 \$10), 转情景 B                                                                                     |
| Stage 1 对齐训练 | 待租前实测   | 按 examples/token 预算与真实 micro-batch 吞吐反推; 禁止用 64 次串行 forward 冒充 global batch 64                                          |
| benchmark 全套 | 1.5-2 h | TextVQA 500 / DocVQA 200 / OCRBench 200 / ScreenSpot 200; 训练 checkpoint $\times$ blind $\times$ 随机 projector 三组对照, 机上完成 |
| 权重与结果回传      | 0.5 h   | projector 约 134 MB + 评测 JSON 上传 HF                                                                                      |
| 合计           | 暂不锁定    | 装机、Gate D、benchmark 与回传有时间盒; 训练段待 batching/分辨率/容量消融后重新报价                                                                |

若 FP4 Dgrad 不可用 (情景 B): 权重解量化至 bf16 (568 GB), 需 8×A100 SXM (\$10.30/h), 同编程时长大约 ×2–3, 预算 \$300–500。

## 11 评测与验收计划

没有 benchmark 就无法回答“接上了没有”。评测口径对标 Baseten 社区 GLM-5.2V 实验 (原文 baseten.co/blog/glm-52-with-vision,0xSero/fable-glm-vision 复现): 双方视觉塔都来自 Kimi 的 MoonViT3d 家族 (他们从 Kimi K2.6 抽取, 我们从 Kimi K3 抽取 MoonViT-V2, 当前塔宽 1024), 其标志性指标是 **MMMU-Pro** (原文声称 55%, 约 Claude 4.5 Haiku 水平), 因此我们的评测集在 TextVQA/DocVQA/OCRBench/ScreenSpot 之外加入 **MMMU-Pro (单图子集, exact match)**。所有数字必须与 blind baseline (同一模型、无图输入) 一起报告: VQA 类基准有显著语言先验, 无图基线把“模型本来就会答”与“图像带来了信息”分开。

社区配方还有两个直接影响数据计划的实测结论: 其一, **grokking**——batch 64 / lr 5e-4 配短答案时 loss 平台数百步后骤降 (原文约 step 900) 完成对齐, **长描述性答案会阻止 grok**, 因此对齐数据应以短 QA 为主、长 caption 为辅, 而不是只用长 caption; 其二, **warm start**——从已对齐 projector 初始化可跳过大半平台期, 多阶段数据混训时应复用上一阶段 checkpoint 而不是重零开始。

训练数据泄露控制 (2026-08-03 定稿, GUI 修订): 正式 mix 含 TextVQA train (34.6k)、DocVQA train (25k)、0xSero art 子集 (约 10k) 与 ShowUI-desktop (8k) 四类短答案监督; GUI 数据按用户决定纳入以建立 computer-use 基础, 答案统一为 0xSero 动作格式 `click(start_box=[x,y])` (0..999 尺度, 评测 parser 原生兼容)。0xSero 自带的 screenshots/multistep 行不直接复用 (图像改名无法回 join; multistep 为轨迹格式), 改为从同源公开数据集自取。代价与处理: ScreenSpot 自此为**域内基准**, 报告中必须标注; fetch 规格机械执行 `max_answer_words ≤ 20`; 组装去重为三道独立机制 (2026-08-03 评审加固): 感知 aHash (hamming ≤ 6, 抓缩放/重压缩重复) + 精确像素 sha256 (抓跨容器同内容) + 归一化问题文本近重复 ( --eval-jsonl 抓跨 split 文本泄露), 各机制的丢弃数分别计入 `decontamination_report.json` 随数据发布。数据产物托管于 dataset repo `cyjin-yl/moonvit-dsv4-data`, 含来源、固定 revision 与 sha256, 租机上一次下载即用 (上传通道已实测: 新 huggingface\_hub 分块上传经代理约 2.6 MB/s, 全量数据约 1.5–2 h, 见变更日志)。

已实现的评测资产:

- `moonvit_glue.metrics`: 纯 Python 指标, 无 torch 依赖。exact match、soft VQA (官方 min(1, 同意人数/3))、ANLS、token-F1, 以及 grounding 的 parse/Acc@threshold/mean error。
- `tools/eval_vlm.py`: 生成式评分 ( --blind 输出无图基线) 与 --shuffle-loss (真图 vs 随机图的 teacher-forced loss 差) 两种模式。shuffle-loss 是训练前最便宜的信号检验: projector 学到东西后, 真图 loss 应显著低于随机图。
- `tools/fetch_eval_data.py`: 固定来源拉取 TextVQA (soft VQA)、DocVQA (ANLS)、OCRBench (exact match)、ScreenSpot (in-box grounding)、MMMU-Pro (单图子集, exact match), 落盘 JSONL 与 MANIFEST.json (resolved revision sha 与 JSONL sha256), 沿用“信任 manifest 而不是 tag”的纪律。

| 阶段     | 运行内容                                             | 通过判据                                  |
|--------|--------------------------------------------------|---------------------------------------|
| Gate A | 指标单元测试; 小模型 shuffle-loss 管线                      | 测试全绿; 管线可跑                            |
| Gate B | 真实 MoonViT + 小 LM: 生成、评分、blind 对照; overfit 训练    | 端到端无报错; shuffle_delta = +0.343 (显著为正) |
| Gate C | 训练前/后各一次: TextVQA、DocVQA、OCRBench、ScreenSpot 小子集 | 训练后显著高于训练前与 blind                     |

预期锚点: 0xSero 的 GLM-5.2 projector-only checkpoint 报告坐标格式解析率 92%、Accuracy@50 4.3%、平均点击误差约 564/999。第一阶段的成功定义是 DeepSeek 路径达到同量级信号, 而不是成熟 VLM 水平; grounding 在 projector-only 阶段大概率仍很弱。

本地对照臂 (与租机训练并行, 不花租金钱): (1) MoonViT-V2 + 小型纯文本 LM (Gate B 各 checkpoint) 跑全套 1,400 例, 作为 “胶水通路在小模型上的接口可学习性” 读数; (2) 原生 4B VLM (官方权重、官方精度) 经独立适配脚本读同一 eval JSONL、输出同格式评分, 只作为评测阳性对照和成熟小 VLM 参照, 不作为映射/迁移证据; (3) 小模型 projector 不能直插 0731 (hidden 896/576 vs 4096), 合法对照臂是 “小模型 trunk 热启动 (到 GELU 的 4,096 维) + V4 重训最后一层”, 与全程从零的 scratch 臂对比收敛速度。除非另有具体问题, 不再追加 9B/27B 原生 VLM 对照; 它们不会缩小 DeepSeek 证据缺口。

12 数据集挑选过程与构建管线

本章记录正式数据资产的挑选理由、排除项与现行构建做法 (2026-08-03 定稿)。所有产物托管于 dataset repo cyjin-yl/moonvit-dsv4-data, 来源、resolved revision 与逐片 sha256 随数据发布。

12.1 挑选原则

- 1. **对标社区实验**: 评测集与训练集对齐 Baseten/0xSero 的 GLM-5.2V 配方——他们用的我们照用, 保证数字横向可比; 其标志指标 MMMU-Pro 必须在内。
- 2. **短答案优先**: 社区实测长描述性答案会阻止 grokking, 正式训练集全部为短答案监督 (fetch 机械执行 max\_answer\_words ≤ 20); 长 caption 只用于 Gate B 信号验证, 不进正式 mix。
- 3. **视觉塔同源**: 视觉塔从 Kimi K3 抽取 (与 0xSero 从 K2.6 抽取同族); art 子集离线复刻 0xSero build\_art\_dataset.py 的 QA 模板与 schema (tools/fetch\_art\_data.py), 减少配方变量。
- 4. **可复现优先**: 每个来源固定 resolved revision; 逐分片 sha256 对 LFS oid 校验; MANIFEST 随数据发布, 信任 manifest 而不是 tag。

12.2 评测集 (1,400 行)

| 数据集             | 来源 (HF)                                  | 行数  | 指标               | 挑选理由                              |
|-----------------|------------------------------------------|-----|------------------|-----------------------------------|
| TextVQA val     | lmms-lab/textvqa                         | 500 | soft VQA         | OCR-VQA 基本盘, 社区通用口径               |
| DocVQA val      | lmms-lab/DocVQA                          | 200 | ANLS             | 文档理解, 与训练同族任务的 held-out           |
| OCRBench test   | echo840/OCRBench                         | 200 | exact match      | 纯文字识别                             |
| ScreenSpot test | rootsautomation/ScreenSpot               | 200 | in-box grounding | GUI 定位; ShowUI 进训练后为域内基准, 报告中单独标注 |
| MMMU-Pro test   | MMMU/MMMU_Pro standard (10 options) 单图子集 | 300 | exact match      | 社区实验标志指标 (原文声称约 55%)              |

每行一图, 图像落盘, JSONL 附 MANIFEST (resolved revision + 逐分片 sha256 + JSONL sha256)。评测纪律: 分 selection/final 两半——checkpoint 选择只看 selection 半, final 半只对最终 checkpoint 跑一次, 避免把 test 当训练集; 域内 (ScreenSpot) /跨域/零样本三组分开报告, 不混入一张表。

12.3 训练集 (四类短答案监督)

| 来源                     | 行数       | 答案形态 | 理由                              |
|------------------------|----------|------|---------------------------------|
| lmms-lab/textvqa train | 34,602   | 短答案  | 与评测同任务不同 split; 组装时对 eval 做文本去重 |
| lmms-lab/DocVQA train  | 约 25,000 | 短答案  | 文档 QA; 12 个官方 train 分片离线抽取      |



|                                                                                       |                                               |                                                |                                                      |
|---------------------------------------------------------------------------------------|-----------------------------------------------|------------------------------------------------|------------------------------------------------------|
| showlab/ShowUI-desktop<br>train                                                       | 7,496                                         | GUI 动作<br>click(start_box=[x,y])<br>(0.999 尺度) | 用户决定纳入，建立 computer-<br>use 基础；答案格式与评测<br>parser 原生兼容 |
| Artificio/WikiArt_Full<br>+ benitomartin/<br>fashion-product-images-<br>small-384x512 | 池 71,780 +<br>2,220 val;<br>mix 取 约<br>10,000 | 短描述 QA                                         | 与五个评测集零交集；复刻<br>0xSero schema                        |

### 12.4 排除项与理由

- **长 caption 数据** (flickr8k/COCO 类): grokking 实证表明长答案阻止对齐; flickr8k 仅用于 Gate B 信号轨，不进正式 mix。
- **0xSero screenshots / multistep 行**: screenshots 图像经改名无法回 join; multistep 为轨迹格式，与单步 QA 合同不符。GUI 监督改从同源公开集 ShowUI-desktop 自取。
- **与评测集近重复的任何行**: 见下方三道去重机制。
- **低于发布精度的量化对照**: 对照组评测一律官方发布权重精度 + 官方 kernel; fp8 发布的模型升 bf16 无损可做，GGUF Q4/Q6 等降精度量化不做——量化损失会混进“模型能力”读数。本地 V100 跑不动全精度 27B 则放弃该臂，或挪入租机 benchmark 窗口。

### 12.5 下载与校验通道 (现行做法)

十二种数据源、93 个正式分片全部落 staging，逐片 sha256 对 LFS oid 校验并打 .sha256ok 幂等标记，最终 0 mismatch。通道是实测淘汰出来的：

- hf\_transfer 在代理下 0 字节挂起; hf-mirror 限流; 工作站 datasets+dill 无法 pickle pyarrow MonthDayNano (任何本地 parquet 都炸 load\_dataset) → fetch 全程 raw pyarrow 离线直读 (--data-files)。
- ModelScope 镜像境内直连可达 8.8 MB/s，但约 1.5 小时高强度拉取后被 CDN 按 IP 渐进限速至 0; Tailscale 中继 (RTT 3.7 s, 聚合 250–400 KB/s) 与代理同速且挤占家庭带宽，应用户要求退役。
- 最终方案: 工作站经 Clash 代理 aria2 预取 + 离线 fetch。代理上下行共享总带宽 (约 250 KB/s 封顶)，**上传与下载严禁并行**，HF 上传统一串行排在下载之后。
- **关键事故**: xet-bridge 签名 URL 按 range 签发，aria2 -x8 分段重试拿过期 URL 会读到错 range 的字节并写入错偏移——TLS 合法、文件尺寸正确、内容静默损坏 (25 片)。根因定位后改单连接 -x1 -s1 + 每片 sha256 校验，坏片全部重拉修复; 另修 aria2 不认大写 HTTPS\_PROXY 一处。

### 12.6 组装、去重与打包

1. tools/build\_train\_mix.py 按配额组装 (TextVQA train 全量 + DocVQA train 25k + ShowUI 8k + art 10k)，三道独立去重: 感知 aHash (hamming ≤ 6, 抓缩放/重压缩) + 精确像素 sha256 (抓跨容器同内容) + 归一化问题文本近重复 (对五份 eval 全量比对，抓跨 split 文本泄露); 各机制丢弃数分别计入 decontamination\_report.json 随数据发布。
2. tools/pack\_to\_parquet.py 打包: union-keys schema (from\_pylist 只按首行推断的坑已修，测试 6/6); train 按 20,000 行分片，eval 五份各打一包。图像统一为 PNG 字节内嵌 parquet——付费服务器上顺序读、免密集小文件 IO，租机下载一次即用。
3. 串行上传 cyjin-yl/moonvit-dsv4-data (已传文件自动跳过); README 记录来源、revision、sha256 与复现命令，原数据集协议随产物保留。

### 12.7 当前状态 (2026-08-04)

- eval\_v1: 五个评测集 1,400 行 + 1,400 张图像 + MANIFEST，完成并已上传 cyjin-yl/moonvit-dsv4-data。
- train\_v1: 59,198 行 mix (TextVQA 29,252 / DocVQA 17,351 / ShowUI 5,167 / art 7,428; 三道去重合计丢弃 23%) 打包 3 片约 20 GB，完成并已上传。

- sft\_art: 71,780 train / 2,220 val, 完成并已上传。
- Gate B full-mix early alignment: 完成 (2000 optimizer steps、16,000 examples、约 0.27 epoch, 历史 shuffle\_delta +0.727); 五基准与 stock 4B 阳性对照均完成并发布。当前优先级转为 true batching 与容量/projector/LoRA/分辨率/因果诊断消融, 租时暂不锁定。

13 变更日志

| 日期         | 变更                                                                                                                                                                                                                                       |
|------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 2026-08-02 | 建立通用 placeholder 扩展、PatchMerger、MoonViT wrapper 和 DeepSeek embedding hook。                                                                                                                                                               |
| 2026-08-02 | 确认 0731 已有 <  image  > ID 129279, 禁止扩 vocab。                                                                                                                                                                                             |
| 2026-08-02 | 真实缩小 DeepSeek-V4 Hash-MoE 完成 backward。                                                                                                                                                                                                   |
| 2026-08-02 | 发现 Transformers 4.57.6 缺少 DeepSeek-V4; 基线切换为 5.12+。                                                                                                                                                                                      |
| 2026-08-02 | 完成 Vast on-demand 只读快照; 未创建或租用实例。                                                                                                                                                                                                        |
| 2026-08-02 | 公开仓库 cyjin-yl/moonvit-deepseek-v4-glue 上线并推送。                                                                                                                                                                                            |
| 2026-08-02 | 新增评测资产: metrics 指标库、eval_vlm 评分器 (含 blind 与 shuffle-loss 模式)、fetch_eval_data 数据清单; 新增 generate() 生成路径。                                                                                                                                   |
| 2026-08-02 | V100 工作站: torch 2.10.0+cu128 确认含 sm_70; 26/26 测试通过; 记录 NVML mismatch 与 Xet-over-proxy 挂起 (HF_HUB_DISABLE_XET=1 解决)。                                                                                                                      |
| 2026-08-02 | V100 完成真实 MoonViT smoke (fp32) 与评测管线端到端干跑; 发现 MoonViT remote code 与 Transformers 5.x 两处不兼容并 shim; 确认视觉 token 数可顶爆小模型上下文。                                                                                                                 |
| 2026-08-02 | Gate B 通过: V100 上冻结 MoonViT + SmolLM2-135M 只训 projector, 1000 步后 shuffle_delta = +0.343; 生成随图变化、blind 恒定。数据路径修复为相对 JSONL。                                                                                                                |
| 2026-08-02 | Gate B 第二 backbone 复测通过: Qwen2.5-0.5B 同条件 shuffle_delta = +0.282, 确认信号与文本主干选型无关。                                                                                                                                                         |
| 2026-08-02 | Gate B 第三轨通过: flickr8k 1100 条 (jxie 开放镜像, 离线 parquet 救援落盘), Qwen2.5-0.5B 1500 步 shuffle_delta = +0.148; 三轨全部通过。                                                                                                                          |
| 2026-08-02 | 训练器支持流式 checkpoint: 每 500 步保存 projector(fp32+bf16)+AdamW+RNG 的完整可续训单元, 后台线程传 HF; --resume 可从任一 checkpoint 精确续训。                                                                                                                          |
| 2026-08-02 | 对齐社区 GLM-5.2V 配方: 确认其视觉塔同为 MoonViT、标志指标为 MMMU-Pro (加入评测集); 记录 grokking (短答案) 与 warm-start 两条训练结论; 带宽速度与数据集流量成本计入预算。                                                                                                                      |
| 2026-08-03 | MoonViT-V2 移植验证: K3 视觉代码 vision-only 抽取并 vendor 进仓库 (去文本模型依赖); 随机权重前向输出 [G,4,1024] 符合 PatchMerger 合同; 新增 sdpa varlen attention 并与 eager 数值一致; moonvit_v2 wrapper 复用 MoonViTEncoder 契约; 34/34 测试通过。权重单分片 (802 MB/1.56 TB) 下载中, HF 写权限已验证。 |
| 2026-08-03 | 真实权重回归完成: shard 96 下载 (sha256 9d10c74f...) → 抽取 165 张量 strict-load 通过 → V100 真实前向 [1369,4,1024]@1024px、finite、逐位确                                                                                                                        |

|            |                                                                                                                                                                                                                                                                                                                                                |
|------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|            | 定、eager/sdpa 差 $3.1e-05 \rightarrow 34/34$ 回归 $\rightarrow$ 产物 (含 sha256 MANIFEST) 上传 HF vision_tower_k3/; 训练/评测支持 --vision-tower v2。                                                                                                                                                                                                          |
| 2026-08-03 | 推理集成文档重写为 MoonViT-V2 版: 确认 vLLM/SGLang 均 Day-0 支持 K3 (含 MoonViT3d) 且均有 DeepSeek-V4 文本栈, patch 面收敛为 projector 模块 + placeholder 扩展 + Hash-MoE 路由检查; llama.cpp/fastllm patch 点记录在案但 v1 不做。新增 Gate D 风险清单 (R1-R11, 每条带缓解与止损) 与三档最终账单 (情景 A \$55/\$75/\$110, 预算 \$120; 情景 A' B200 与情景 B 约 \$210-310; 上限 \$350); projector 合同更新为 V2 的 33,564,672 参数。 |
| 2026-08-03 | 下载通道定论: aria2 多连接预取 parquet + 离线 pyarrow fetch (--data-files), 绕开 hf_transfer 挂起、hf-mirror 限流与 datasets+dill 的 MonthDayNano pickle 崩溃; 新增 prefetch_parquet 与 fetch_art_data (OxSero art 离线复刻); MMMU-Pro config 修正为 standard (10 options); 62/62 测试通过。                                                                                          |
| 2026-08-03 | 租前全链路彩排通过 (Gate B+): V100 上 400 步训练 + checkpoint 流式上传 + 三组评测 + 聚合全部闭环并落 HF; 训练组 gap +0.117 vs 随机对照 +0.019, 管线可判别; 作为正式训练的对照组基线。                                                                                                                                                                                                                |
| 2026-08-03 | 外部评审 (Max) 并入 runbook: Gate D 分阶段化 (含 gate\_d\_dgrad.py 单层 Dgrad reproducer、hook $\times$ 梯度检查点数值一致性、device\_map="auto" 步时定律); 版本固定 + pip freeze 随产物; 视觉 token 预算写死 (训练 640 / 评测 1024); 配方谦逊条款 (LR 探针兜底); 评测纪律 (selection/final 两半、域内/跨域/零样本三组、3 种子 shuffle 统计)。                                                                               |
| 2026-08-03 | 数据管线定稿并写入报告新章节: 评测 5 集 1,400 行 (TextVQA/DocVQA/OCRBench/ScreenSpot/MMMU-Pro) 与训练 4 类来源 (TextVQA train 34.6k、DocVQA train 25k、ShowUI-desktop 7.5k、art 池 71.8k 取 10k) 的挑选理由与排除项; 93 个正式分片 sha256 校验 0 mismatch; 三道去重、union-keys parquet 打包与串行上传纪律; DocVQA train 抽取收尾中。                                                                           |
| 2026-08-04 | 数据全链路闭合: train_v1 mix 59,198 行 (去重丢 23%) + eval_v1 + sft_art_v1 全部上传 cyjin-yl/moonvit-dsv4-data; 数据仓 README 记录来源、revision、sha256 与复现命令。                                                                                                                                                                                                        |
| 2026-08-04 | Gate B 全量 mix 训练完成 (V100, Qwen2.5-0.5B + MoonViT-V2, 2000 步): loss $6.41 \rightarrow 3.01$ , held-out shuffle_delta <b>+0.727</b> , 全量数据上视觉对齐信号明确; 修复占位 token 双默认值不一致 bug (训练 Qwen <  image_pad > vs 评测 DeepSeek <  image  >) 为候选自动探测, 85/85 测试; 4 个 checkpoint 因代理 SSL 抖动待手动补传。                                                               |
| 2026-08-04 | Gate B 五基准终表 (trained/random/blind): textvqa 0.081/0/0、docvqa 0.039/0/0、ocrbench 0/0/0 (地板)、screenspot 解析 0.51 精度 0.01、MMMU-Pro 0.073/0/0——判别力三条全成立, 绝对读数如实留存 (含坏结果)。误判审计: 判别器清白 (最宽提取 +1-2% 封顶); 抓到 MMMU 输入格式化两个 bug (选项字面量被逐字符拆行、缺字母标签), 修复后 2.0% $\rightarrow$ 7.3%, 旧读数作废。                                                                 |
| 2026-08-04 | 原生 Qwen3.5-4B 阳性对照修复并跑完: 发现同字节数坏 shard (视觉塔全集所在分片) $\rightarrow$ SHA-256 manifest 校验、1024px 上限与指标化短输出约束。修复后 vision/blind: TextVQA 0.820/0.031、DocVQA 0.926/0.071、OCR-Bench 0.900/0、ScreenSpot acc 0.760/0.010、MMMU-Pro 0.300/0.280。                                                                                                            |

|            |                                                                                                                                                                                                                                                                                                                          |
|------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|            | 用户指出并纠正证据边界：该模型自带视觉塔与多模态对齐，只验证评测器，不证明 MoonViT-V2→DeepSeek；训练器新增原生 VLM 拒绝保护，Gate D 才是目标能力证据。                                                                                                                                                                                                                              |
| 2026-08-04 | 用户指出 0.5B 容量混杂：Qwen2.5-0.5B 虽为纯文本主干，但会压低 OCR/推理/格式遵从上限，dense 小模型的收敛也不能预测 DeepSeek Hash-MoE。Gate B 正式降格为工程/信号闸门；尚未完成的干净桥接对照定义为无 vision_config 的约 3B 纯文本主干，在相同 mix、seen-record、分辨率、scratch projector 与 selection 评测下复测。                                                                                                    |
| 2026-08-04 | 训练计量审计：历史 batch 8 是 micro-batch 1 下串行累积，full-mix Gate B 共见 16,000 样本、仅约 0.27 epoch，故重命名为 early alignment，低 benchmark 不作能力上限。训练器新增 examples/answer tokens/effective epochs 与显式 batch 语义、固定分层 validation manifest、10 组 derangement mean±std、多答案监督 provenance；租前实验按容量→projector/LoRA→分辨率→因果/合成诊断排序，true batching 实测前暂停锁定租时。 |

## 14 下一位执行者的最短路径

先运行 `pytest` 和 `examples/smoke_tiny_text_lm.py`。然后在 V100 工作站使用机械盘作为 `HF_HOME`，按 MANIFEST 校验并验证真实 MoonViT-V2。正式 0731 实验前不要写训练循环，先证明目标 CUDA/量化 runtime 支持 `input data-gradient`。若失败，优先评估 FP8 可微加载或定制 Dgrad，不要改用 GGUF 假装完成训练链路。