

MoonViT-V2 接入 DeepSeek-V4-Flash-0731

训练前架构审计、胶水原型与硬件计划

版本 0.3 · 2026-08-04

Contents

1	执行摘要	2
2	来源与可复现边界	2
3	权重与张量合同	2
4	DeepSeek-V4 特殊适配	2
5	已完成验证	3
6	MoonViT-V2 尺寸与适配性	3
7	MoonViT-V2 (Kimi K3 视觉塔) 移植	3
8	本地与云端硬件计划	4
9	分阶段门槛	4
9.1	Gate A: 无需大权重	4
9.2	Gate B: V100 工作站	5
9.3	Gate B 实测: projector overfit 实验 (2026-08-02)	5
9.4	Gate B+: 租前全链路彩排 (2026-08-03, 正式训练的对照组)	6
9.5	Gate B 全量 mix 正式训练 (2026-08-04, V100, 租前最后一闸)	7
9.5.1	五基准评测终表 (selection 半侧, 1024px, 逐条原始输出已公开于 HF eval/v100-fullmix-qwen05/)	7
9.5.2	证据边界: 原生 VLM 不是 DeepSeek 代理	8
9.5.3	误判审计 (应用户要求: 先怀疑判别器, 再怀疑模型)	9
9.6	Gate C: Vast 只读调研	9
9.6.1	最终账单 (含下载时间、网络、存储、装机余量)	10
9.7	训练显存算术 (每卡, 权重张量并行切分, 视觉塔/projector 每卡复制)	10
9.8	Gate D 风险清单 (租卡前预演)	11
9.9	Gate D: 正式租卡前	12
9.10	租期闭环排程 (2026-08-02 定价)	12
10	评测与验收计划	13
11	数据集挑选过程与构建管线	14
11.1	挑选原则	15
11.2	评测集 (1,400 行)	15
11.3	训练集 (四类短答案监督)	15
11.4	排除项与理由	15
11.5	下载与校验通道 (现行做法)	16
11.6	组装、去重与打包	16
11.7	当前状态 (2026-08-04)	16
12	变更日志	16
13	下一位执行者的最短路径	18

1 执行摘要

本项目目标是给纯文本的 DeepSeek-V4-Flash-0731 接入从 Kimi K3 抽取的 MoonViT-V2 (MoonViT3d) 视觉编码器。第一阶段不训练视觉塔和语言模型，只训练一个 Kimi 风格 PatchMerger projector；独立发布的 MoonViT-SO-400M (V1) 只保留作历史对照。当前结论是：V2 的真实权重、预处理和 [tokens, 4, 1024] 合同均已在 V100 验证，projector-only 全量数据训练已得到明确视觉对齐信号；正式 0731 大权重的 FP4/FP8 可微 kernel 是尚未消除的主要风险。

MoonViT-V2 有 401.2M 参数，抽取后的 BF16 权重约 802 MB，相对于约 160 GB 级的 DeepSeek 混合精度权重很小。更大的资源变量是图像分辨率带来的视觉 token 数和冻结 LLM 反向所保留的激活，而不是视觉塔权重。

2 来源与可复现边界

- 社区 projector checkpoint: 0xSero/glm-local-vision-checkpoint。它证明了 projector-only 路线能把视觉信号接到 GLM-5.2，但公开 grounding 指标仍弱，不能等同于成熟 VLM。
- 社区复现记录: Giving a 753B Model Eyes。
- DeepSeek 权重: deepseek-ai/DeepSeek-V4-Flash-0731, MIT。
- 当前视觉塔: 从 Kimi K3 的 MoonViT3d 权重分片抽取的 MoonViT-V2；抽取权重、配置、代码快照与哈希清单发布在项目模型仓 vision_tower_k3/。
- 历史对照视觉塔: moonshotai/MoonViT-SO-400M, MIT。
- Kimi-K2.5 技术报告: Kimi K2.5: Visual Agentic Intelligence。
- Vast offer 搜索接口: Vast.ai Search Offers API。本文只调用搜索接口，不调用创建实例接口。

独立 MoonViT-SO-400M 来自 Kimi-VL；当前主线使用 Kimi K3 的 MoonViT3d/MoonViT-V2。两者输出合同同构不代表特征分布或通道宽度相同。视觉塔 revision 与权重哈希是训练 provenance 的组成部分；更换视觉塔必须重训 projector。

3 权重与张量合同

组件	合同	状态
MoonViT-V2	[tokens, 4, 1024]	冻结
PatchMerger	LN(1024) → flatten → 4096 → GELU → 4096	训练
DeepSeek embedding	vocab → 4096	冻结
Placeholder	< image > / ID 129279	现有词表
Hash-MoE routing	扩展后的 placeholder IDs	冻结

V2 projector 精确参数量是 33,564,672 (fp32 约 134 MB, bf16 约 67 MB；配置见 configs/deepseek-v4-flash-0731-projector-moonvit-v2.json)。备选的 V1 塔 (MoonViT-SO-400M, 1152 维) projector 为 40,119,040 参数，两条配置不得混用。保存格式由 projector_config.json 与 projector.safetensors 组成，加载时使用 strict state-dict 校验。MoonViT、DeepSeek 与 projector 始终保留为三个可独立哈希和升级的来源，不把大权重复制到自有仓库。

4 DeepSeek-V4 特殊适配

DeepSeek-V4 的早期 Hash-MoE 通过 tid2eid[input_ids] 选 expert。只给 inputs_embeds 会丢失路由 IDs，而当前公共 forward 不允许同时给 input_ids 和 inputs_embeds。

原型保留扩展后的 placeholder IDs，并用仅在一次 forward 内生效的 embedding forward hook 替换查表输出。这样 Hash-MoE 看到合法 token IDs，Transformer 隐藏状态看到 projector embeddings，loss 仍可反向到 projector。hook 在 forward 结束后自动移除，不修改 Transformers 源码。

不得向 0731 tokenizer 增加 <image>: 扩词表会同时要求修改输入 embedding、LM head 和 Hash-MoE 的 tid2eid 表。0731 已含多个视觉相关 token，因此没有必要承担该风险。

5 已完成验证

测试	结果	意义
Placeholder 可变长度扩展和 label mask	通过	序列/监督合同
Projector Safetensors round-trip	通过	权重可恢复
冻结普通 GPT-2 的 backward	通过	通用文本主干
真实 DeepseekV4ForCausalLM 1 层 Hash-MoE	通过	DeepSeek 路由合同
MoonViT-V2 输出 shape/freeze 合同	通过	真实 K3 视觉权重
真实 MoonViT-V2 + 小 LM 前向/反向	通过	V100 CUDA eager/sdpa
eval_vlm 生成/blind/shuffle-loss 干跑	通过	评测管线端到端
generate(): generic 与 deepseek_v4 两种路径	通过	评测/推理前置
指标库 (VQA/ANLS/token-F1/grounding)	通过	纯 Python, 无 torch
完整测试集	96/96	Linux + torch 2.10.0+cu128

V100 实测：真实 K3 MoonViT-V2 在 1024×1024 输入下输出 [1369,4,1024]，特征全部 finite、逐位确定，eager 与 sdpa 最大绝对差 3.1e-05；真实权重 strict-load、预处理与 loss/backward 合同均正常。旧 V1 路径也保留了 448px 和原生分辨率回归，但不再代表当前训练主线。评测管线的生成、blind 基线与 shuffle-loss 全部端到端通过；训练后 shuffle-loss 差值应当变正，这是对齐信号最便宜的读数。

离线 smoke 结果：输入 6 token 扩展为 8 token；projector 六组参数均获得梯度；语言模型参数梯度数为 0。同一结果在 doesworkstation (V100) 上复现。

版本审计发现，公开 PyPI Transformers 4.57.6 不含 deepseek_v4 模块；真实 DeepSeek 类测试使用 Transformers 5.14.1。因此统一环境暂定 transformers>=5.12,<6，不能盲从 checkpoint config 中的历史版本字符串。

6 MoonViT-V2 尺寸与适配性

MoonViT-V2 适合该任务：27 层、hidden size 1024、12 heads、401.2M 参数，原生分辨率和 NaViT packing 对 GUI、文档、截图有价值。它不会显著改变完整 0731 的权重门槛；V1 的 1152 维/16 头规格只作为对照记录。

风险来自 token 数。patch size 为 14, 随后 2×2 合并。392×392 图像产生约 196 个合并 token；896×896 产生约 1024 个。第一阶段应把每图上限锁在 1024；更高分辨率必须以梯度激活显存实测决定。

7 MoonViT-V2 (Kimi K3 视觉塔) 移植

按项目决策，视觉塔改为从 Kimi 直接抽取 (K3 优先, K2.6 备选)，与社区 GLM-5.2V 实验同源（他们从 K2.6 抽）。Kimi-K3 仓库全量约 1.56 TB，但其 safetensors index 显示全部 165 个 vision_tower.* 张量集中在单个分片 model-00096-of-000096.safetensors (约 802 MB)。抽取与验证全部在自有工作站完成，不依赖租用机器；租服务器时使用抽取后的独立视觉塔产物，不触碰完整 K3 仓库。

K3 的 MoonViT3d(下称 MoonViT-V2)与 MoonViT-SO-400M 的合同差异: vision width 1152 → **1024** (27 层、12 头、qkv 1536、rmsnorm、无 attn bias、divided-fixed 位置插值)；merge 方式 sd2_tpool, 单图 (t=1) 时时域池化为恒等，输出仍是每图 [tokens, 4, 1024] 的特征组——与既有 PatchMerger 的

[G,4,C] 合同同构，胶水层零改动，仅 projector 的 vision_width 换为 1024 (flatten 维度 4096)。输入格式为 NaViT packing 的 [total_patches, 3, 14, 14] + grid_thws，与 V1 的 flatten 格式不同，由 processor 适配器统一。

移植方式：将 K3 仓库中视觉塔所需的最小代码集 vendor 进本仓库 (src/moonvit_glue/vendor/kimi_k3/, Apache-2.0 + Kimi K3 License, 已附 LICENSE)，删除文本模型依赖 (modeling_kimi_linear 要求更新版 Transformers 的 OutputRecorder, 与本项目 5.12 基线冲突) 与条件生成类；加载不再需要 trust_remote_code, 也不再需要下载完整 K3 仓库。moonvit_glue.moonvit_v2 复用既有 MoonViTEncoder 契约 (freeze、形状校验、preprocess)，新增 sdpa varlen attention (K3 代码只注册 flash-attention-2 与 eager；V100 等无 flash-attn 硬件用 eager/sdpa, 数值一致性有测试)。

已验证 (工作站)：vision-only 模块独立实例化 (真实配置 401.2M 参数)；前向输出 [G,4,1024] 符合合同；eager 与 sdpa 注意力数值一致；带/不带 vision_tower. 前缀的 state-dict 均 strict 加载；processor 适配器产出 pixel_values/image_grid_hws 合同键；完整测试集 34/34 通过。真实 shard 的 header 元数据与模型 state_dict 逐项比对：165/165 key、形状、dtype (全 BF16) 完全一致，且该 shard 不含任何非视觉权重。**服务器端同样只需部分下载**：干净房间测试 (PYTHONPATH 仅含本仓库、无 K3 staging) 确认 vendored 代码只依赖 stdlib/torch/transformers/numpy/PIL，租机时视觉塔侧只需 git 仓库 + 抽取产物 (约 800 MB, 附 sha256 MANIFEST 供下载校验)，完整 K3 仓库不进入训练链路。

真实权重回归 (2026-08-03)：shard 下载完成 (802,448,352 B, sha256 9d10c74f...)，tools/extract_moonvit_v2.py 抽取 165 张量 / 401.2M 参数并 strict-load 通过，产物 moonvit_v2.safetensors (BF16, sha256 01436a95...) + MANIFEST (双哈希)。V100 上真实权重前向：1024×1024 图像 → 5476 patches (74×74 grid) → [1369,4,1024]，全部 finite，特征统计健康 (mean 0.0003 / std 0.0511 / absmax 0.60, RMSNorm 后典型量级)；两次前向逐位一致 (确定性)；eager 与 sdpa 在真实权重上最大绝对差 3.1e-05 (fp32 累加顺序的正常量级)。抽取产物上传至项目 HF 仓库 vision_tower_k3/ 子目录，训练与评测经 --vision-tower v2 --moonvit-v2-weights 使用。

8 本地与云端硬件计划

目标	建议硬件	判断
胶水/单元测试	CPU 或任意 8 GB GPU	已完成
MoonViT-V2 + 0.5B–3B LM	12–24 GB GPU	适合本地开发
V100 32 GB	SM70、32 GB	可跑 MoonViT-V2/小 LM；不能装完整 0731
完整 0731 推理验证	同机 4×48 GB 起步	上下文和 kernel 受限
projector-only 正式训练	4×H100 80 GB 或更高	先过单 batch backward
低风险首跑	4×H200/B200	更大激活余量

消费级单卡不能纯 GPU 运行完整 0731。110–192 GB 主机内存配合 3/4-bit CPU offload 可能极慢推理，但 GGUF/llama.cpp 不能作为当前 projector 训练路径。MoonViT 单独可在普通本地机器运行；完成后的完整组合能否“本地跑”，取决于本地是否具备多卡或大内存 offload 条件。

9 分阶段门槛

9.1 Gate A: 无需大权重

- 1. 固定 tokenizer/image token 合同。
- 2. 固定 MoonViT revision、processor 和输出 shape。
- 3. 小型纯文本 LM 完成 overfit 与保存/恢复。
- 4. 真实 DeepSeek-V4 缩小配置完成 Hash-MoE backward。

9.2 Gate B: V100 工作站

- 1. 在不占用现有 Qwen 优化任务的情况下盘点 CUDA/PyTorch/磁盘。✓ 已完成，并经 tmux 向 fastllm 任务留言协调。
- 2. 大文件仅写入 /run/media/ezra/13D010B6FDBC1A06/。✓ 已确认 /home 89% 占用，机械盘约 3.7 TB 可用。
- 3. 跑 MoonViT standalone 与小 LM；记录 SM70 fallback。✓ 真实 MoonViT-SO-400M 前向/反向与评测管线干跑均通过。torch 2.10.0+cu128 wheel 自带 sm_70，V100 matmul 与 26/26 测试通过，不需要旧版 PyTorch。
- 4. 不尝试加载完整 0731。✓ 保持该约束。
- 5. 小规模 overfit 训练验证信号。✓ 通过（见下节）。

9.3 Gate B 实测：projector overfit 实验 (2026-08-02)

数据：109 条 ComfyUI 产出图的英文描述性 caption (data/comfy_captions.jsonl，零下载，93 训练 + 16 评测)。设置：冻结 MoonViT-SO-400M (fp32) 与 SmolLM2-135M-Instruct (fp32)，只训 40.1M 参数 PatchMerger projector；placeholder 用现有 token <|endoftext|> (id 0)，不扩 vocab；--max-image-side 448 (每图 192 token)；batch 4，AdamW。

第一次跑 (200 步，lr 1e-3，约 8.6 epoch)：训练 loss 4.25 → 3.74，但 shuffle_delta 仅 +0.007，在噪声内——模型主要学到 caption 文体先验。第二次跑 (1000 步，lr 2e-3，约 43 epoch) 信号确立：

指标	数值
训练 loss (首窗 → 末窗)	4.303 → 3.338
评测真图 loss	3.300
评测打乱图 loss (16 样本 × 5 轮)	3.642
shuffle_delta	+0.343
训练耗时 (V100)	951 秒 (1000 步)

生成对照 (8 条评测样本，greedy 48 token)：有图输出随图变化且出现内容词 (“Korean dress”、“3D model”、“beard, pastel houses”，token-F1 0.112)；同一模型的 blind 无图输出 8 条逐字节相同 (“beautiful, serene landscape...” ， token-F1 0.082)。三项证据一致：loss 下降、shuffle_delta 显著为正、生成随图变化且 blind 恒定——projector 确实把图像信息送进了冻结 LM，训练合同在真实权重上成立。checkpoint 在 checkpoints/overfit-smolllm135-1k。

注意：评测集 loss (3.30) 低于训练集末窗 (3.34)，且 43 epoch 已过拟合，shuffle_delta 部分来自对 93 张训练图的记忆；这一 gate 的目的是验证信号通路，不是产出可用 captioner。

第二个 backbone 复测 (同一数据与超参，placeholder 自动解析为 <|image_pad|>)：Qwen2.5-0.5B-Instruct 1000 步后训练 loss 3.898 → 3.160，评测真图 3.310 vs 打乱图 3.592，shuffle_delta = +0.282，耗时 1194 秒，checkpoint 在 checkpoints/overfit-qwen05-1k。两条 backbone 轨给出同量级正 delta，说明该信号来自胶水层与 projector 通路本身，与文本主干选型无关。

第三轨在更大更干净的数据上复测：flickr8k 训练分片 1100 条 (1036 训练 + 64 评测；jxie/flickr8k 镜像，nlphuji 原仓为 gated；因代理网络反复断流，最终直接从 HF 缓存的 train parquet 离线解出，MANIFEST 记录 resolved revision)。Qwen2.5-0.5B，1500 步、batch 8、lr 2e-3 (约 11.6 epoch，记忆成分远小于 comfy 小集)：训练 loss 3.091 → 2.435，评测真图 2.574 vs 打乱图 2.722 (64 样本 × 5 轮)，shuffle_delta = +0.148，耗时 2102 秒，checkpoint 在 checkpoints/overfit-qwen05-flickr8k。在 10 倍数据、1/4 epoch 数下 delta 仍显著为正——信号不依赖小集记忆。

该 checkpoint 的生成对照同样干净：8 条评测样本有图输出为正常 flickr8k 风格 caption (“A boy in a red shirt and blue shorts is holding a toy”， token-F1 0.284)；blind 无图输出全部退化为同一句拒绝话术 (“I’ m sorry, but you haven’ t provided an image...” ， token-F1 0.0)。

三轨汇总 (判据均为真图 vs 打乱图 teacher-forced loss 差):

数据	文本主干	步数/epoch	delta	结论
comfy 109 条	SmolLM2-135M	1000 / 43	+0.343	通过
comfy 109 条	Qwen2.5-0.5B	1000 / 43	+0.282	通过
flickr8k 1100 条	Qwen2.5-0.5B	1500 / 11.6	+0.148	通过

Gate B 结论: 胶水层 + projector 训练合同在真实权重、两个文本主干、两个数据集上全部成立, 可以进入 Gate D (租卡验证 0731 大权重的 Dgrad 通路)。

工作站实测注意项:

- NVML 版本不匹配 (内核模块 580.159.04 vs 用户态库 580.173): nvidia-smi 不可用, 但 CUDA 初始化与 kernel 运行正常。不要为修复它而重载驱动或重启——同机其他任务正在使用 GPU。
- MoonViT remote code 与 Transformers 5.x 有两处不兼容: 缺 all_tied_weights_keys (已在 moonvit.py shim, ViT 无 tied weights, 空映射语义正确); bf16 下 remote code 内部存在 float32/bf16 混用的 layer_norm 调用, V100 上 MoonViT 以 fp32 运行 (约 1.6 GB, 可接受)。
- 小上下文文本模型装不下原生分辨率视觉 token: 640×480 照片产生 1064 个合并 token, 加 prompt 后超过 tiny-gpt2 的 1024 positions, 表现为 scatter-gather device assert (异步报错会漂移到无关位置, 需 CUDA_LAUNCH_BLOCKING=1 定位)。--max-image-side 控制 token 数; 正式 0731 的 128k 上下文无此问题。
- HF 下载须走本机代理 127.0.0.1:7890 (约 0.4–0.5 MB/s), 且该仓库默认 Xet 传输在代理下会挂起, 必须设 HF_HUB_DISABLE_XET=1。
- 复用现有 venv (torch 2.10.0+cu128 + transformers 5.12.1); pytest 用 pip --target 装在独立目录, 不改对方环境。
- 工作站负载高 (其他 agent 编译/跑 inference server) 时, 机械盘上的 torch import 可达 90 秒以上; 批处理脚本超时预算要放宽。

9.4 Gate B+: 租前全链路彩排 (2026-08-03, 正式训练的对照组)

目的不是能力验证, 而是把租期闭环的每一个环节在 V100 上先炸一遍: 离线取数 → 切分 → 训练 (checkpoint 流式传 HF) → trained/blind/random 三组评测 → 聚合 → 全部产物落 HF。设置: SmolLM2-135M-Instruct + 真实 K3 MoonViT-V2 权重 (eager), flickr8k 1200 条 (train parquet 本地直读, 零下载; 该数据集每行一图、只用 caption_0, 行切分即图切分, 无泄露), 1000 训练 / 200 评测, 400 步、batch 4、lr 5e-4 (Baseten 配方默认值), placeholder 为现有 token <|endoftext|>, --max-image-side 448。

组别	vision token-F1	blind token-F1	gap
训练后 projector (400 步)	0.1565	0.0391	+0.117
随机 projector (管线对照)	0.0584	0.0391	+0.019

训练 loss 4.30 → 3.06 (前 200 步)。三点结论: (1) 训练组 gap 是对照组的 6 倍, 管线对 “是否训练过” 可判别——评测不是摆设; (2) checkpoint 流式上传经代理真实落地 (HF 上 step-000200/000400 含 projector fp32+bf16、training_state、history.json), 租期中断不丢训练; (3) 全部评测原始输出 (逐条预测 + 元数据) 与 SUMMARY 已公开在 eval/v100-smoke-smolllm135/。注意: 400 步远低于 grokking 区间 (约 900 步起), 135M 主干 + caption 任务的绝对 F1 不代表正式结果; 此表是正式训练的**对照组基线**。

本轮同时打通了下载通道的完整答案 (此前三种路径全部失败): hf_transfer 在代理下 0 字节挂起、hf-mirror 限流、工作站的 datasets+dill 无法 pickle pyarrow 的 MonthDayNano (任何本地 parquet 都炸 load_dataset)。最终方案: aria2 -x8 -c --max-tries=0 预取 parquet 分片 (xet-bridge CDN 随机 TLS 重

置/403, 无限重试磨过去) + fetch 全程离线读本地 parquet (raw pyarrow, 跳过 datasets 指纹层), 新增 tools/prefetch_parquet.py 与 tools/fetch_art_data.py (0xSero art 数据集的离线复刻, schema 与 build_train_mix 兼容, 有测试)。另修正一处数据规格错误: MMMU-Pro 仓库不存在裸 standard config, 已固定为 standard (10 options)。

同日下午的带宽攻防补充了一课: (1) ModelScope 存在与 HF 逐字节一致的镜像 (lmms-lab/textvqa、lmms-lab/DocVQA、AI-ModelScope/MMMU_Pro、showlab/ShowUI-desktop), 境内直连可达 8.8 MB/s, 但工作站 IP 在约 1.5 小时高强度拉取后被 CDN 边缘渐进限速至 0 B/s (按 IP 不按账号, token 与 IPv6 均无效; 本机家庭 IP 同文件仍有 5.3 MB/s); (2) 随即搭建的“本机 ModelScope → scp 回传工作站”中继受 Tailscale 链路限制 (3.7 s RTT, 多流聚合仅约 250–400 KB/s), 与代理通道同速且挤占家庭带宽, 应用户要求退役; (3) 最终全部十个数据源统一由工作站经 Clash 代理直下 (moondata 八个评测/训练集 + moonart 的 WikiArt/fashion), 代理总带宽封顶约 250 KB/s (并行不扩展, 单连接约 50 KB/s 即节点拥塞), 剩余约 15 GB 预计 16 小时; mihomo 核心未开 external-controller, 换节点只能由用户在 GUI 操作, 这是当前唯一可能提速一个数量级的杠杆。也曾评估 \$0.056/h 的香港数据盒 (2–3 小时收工、总成本 < \$0.5) 作为替代, 用户选择免费慢磨方案。

9.5 Gate B 全量 mix 正式训练 (2026-08-04, V100, 租前最后一闸)

目的: 在正式 train_v1 mix (59,198 行 packed parquet) 上验证“parquet 消费路径 + 全量数据 + 2000 步训练 + 全套评测 + 上传”的租期闭环, 同时作为正式 0731 训练的本地对照组。设置: Qwen2.5-0.5B-Instruct (冻结) + K3 MoonViT-V2 (冻结, eager), 只训 projector (33.6M 参数), 2000 步、batch 8、恒定 lr 5e-4、--max-image-side 448, 占位 token 自动解析为 Qwen 词表已有的 <|image_pad|> (ID 151643, 不扩词表)。

训练结果 (train.log 实测):

指标	数值
loss (首窗口 → 末窗口)	6.413 → 3.006 (单步 10.19 → 3.01, 最低 2.718 @ step 1750)
held-out 真实 loss (32 条)	3.175
held-out 打乱图像 loss	3.902
shuffle_delta	+0.727

shuffle_delta +0.727 是此前三条 smoke 轨 (+0.343 / +0.282 / +0.148) 的两倍以上: 全量 mix 上视觉信号对齐明确成立。但本轮同时炸出两个租前必须暴露的问题, 均已定位:

- 1. **checkpoint 流式上传全部失败** (step 500/1000/1500/2000 共 4 次): 训练期间代理 SSL 持续重置 (UNEXPECTED_EOF_WHILE_READING 于 S3 multipart PUT), 重试 5 次仍败。训练本身无损, 4 个 checkpoint 本地完好; 按“上传下载串行”纪律, 等评测结束带宽空出后手动一次性补传。教训: 租机上 checkpoint 上传同样要与数据集预取错开。
- 2. **10 个评测进程全部启动即崩**: 训练器默认占位 token 是 Qwen 的 <|image_pad|>, 而评测器默认是 DeepSeek 的 <|image|>——两者默认值不一致, Qwen tokenizer 里没有后者, resolve_placeholder_token_id 按设计拒绝扩词表而报错。修复为候选自动探测 (DeepSeek token 优先、Qwen token 兜底; 显式指定仍严格报错), 85/85 测试通过 (commit 034be8b)。此 bug 若不在本地炸出, 租机首跑 DeepSeek 时训练器会以旧默认 <|image_pad|> 直接崩在 0731 tokenizer 上——本地彩排的价值正在于此。

9.5.1 五基准评测终表(selection 半侧, 1024px, 逐条原始输出已公开于 HF eval/v100-fullmix-qwen05/)

基准	指标	trained	random	blind	读法
----	----	---------	--------	-------	----

TextVQA (250)	soft-VQA	0.081	0.000	0.000	真实对齐, 距成熟 VLM 远
DocVQA (100)	ANLS	0.039	0.000	0.000	同上, 实体级读错居多
OCRBench (100)	exact	0.000	0.000	0.000	地板; 小字 OCR 超出 0.5B 能力
ScreenSpot (100), 域内	解析率 / 精度 @50	0.51 / 0.01	0 / 0	0 / 0	格式学会一半, 点位退化 (常数坐标, 中位误差 729/999)
MMMU-Pro (150)	exact	0.073	0.000	0.000	修复输入后 2.0%→7.3%; 宽松提取 18%

判别力三条全部成立: vision 严格大于 blind; trained 严格大于 random (随机 projector 臂五项全零——冻结 LLM 收到噪声视觉 embedding 时输出不了任何切题内容); shuffle_delta +0.727。Gate B 作为租前闸门的结论: **信号真实、训练有效、评测可判别、checkpoint/上传管线可用 (但易受代理抖动影响, 需错峰)**。能力层面如实记录: 所有绝对读数都低, 与参照系一致——社区用 744B 的 GLM 跑同配方 ScreenSpot 也只有 4.3%/564px。0.5B 冻结主干 + 33.6M projector + 1.6 万样本见过的训练量, 本来就只承担“对照组”角色; 能力问题是 0731 (激活 13B) 那趟要回答的。

9.5.2 证据边界: 原生 VLM 不是 DeepSeek 代理

必须区分两个名字相近但因果意义完全不同的 Qwen 实验。Gate B 的冻结文本主干配置是 Qwen2ForCausalLM, 且 vision_config 为空; 它本身没有图像输入路径, 视觉信号只能来自外接 K3 MoonViT-V2 与本项目训练的 projector。因此 shuffle_delta 和 trained/random/blind 差异可以证明“纯文本 LM 接口可学习”。训练器现已加入硬防线: --text-model 若暴露 vision_config 会直接拒绝, 原生 VLM 只能进入独立的 stock-eval 路径。

另一方面, Qwen3.5-4B 对照的配置是 Qwen3_5ForConditionalGeneration 且自带 vision_config; 它使用官方视觉塔、processor、chat template 和既有多模态对齐, 完全不经过 MoonViT-V2 或本项目 projector。它的高分只校验评测数据、图像读取、输出约束和评分器, 并给出成熟小型 VLM 的参照上界; **不得据此推断 projector 能快速映射到 DeepSeek**。证据链严格分为: (1) 原生 VLM 阳性对照 = 评测有效; (2) 纯文本小主干 Gate B = 接口可学; (3) tiny DeepSeek-V4 Hash-MoE = 路由与梯度合同; (4) 完整 0731 Gate D/正式训练 = 目标可行性与能力, 前三项均不能替代第四项。

原生 Qwen3.5-4B 的修复后阳性对照如下。它与 Gate B 使用相同的 selection 半侧、1024px 上限和 strict scorer; “vision” 列是 Qwen 自带视觉塔的结果, 不是本项目 projector 的结果。

基准	指标	Gate trained	B	Gate blind	B	原生 Qwen vision	Qwen blind
TextVQA (250)	soft-VQA	0.081		0.000		0.820	0.031
DocVQA (100)	ANLS	0.039		0.000		0.926	0.071
OCRBench (100)	exact	0.000		0.000		0.900	0.000
ScreenSpot (100)	parse / acc@50	0.51 / 0.01		0 / 0		0.86 / 0.76	0.99 / 0.01
MMMU-Pro (150)	exact	0.073		0.000		0.300	0.280

前三个感知/OCR 基准与 ScreenSpot 的 vision-blind 差距很大，证明图像读取与评分管线已恢复健康；MMMU-Pro 只有 +0.020，30% 中绝大部分来自题干、选项与语言知识先验，不能全部计作视觉能力。这正是强制报告 blind 的价值，也再次说明原生 VLM 总分不能成为 DeepSeek 映射证据。

该对照还产生了一次必须保留的完整性事故记录：首次运行中，第二个 3.99 GB safetensors 分片虽字节数正确，SHA-256 却为 547d2f...8627（官方 cb544b...e188），而模型索引恰把全部视觉塔权重放在该分片，导致模型把真实图片一致描述成空白。高分辨率样本又触发 OOM，并被工作站的 NVML 驱动/库版本不一致掩盖成 allocator assert；开放式长回答则会被严格短答案指标计零。修复措施为：逐分片 SHA-256 manifest、--max-image-side 1024、按指标约束短答案/选项字母/归一化坐标。损坏运行的产物从未上传；修复套件在一次完整哈希验证后运行，原始逐条输出与 suite provenance 单独发布。

9.5.3 误判审计（应用户要求：先怀疑判别器，再怀疑模型）

对五个基准逐条重打分，用逐级放宽的提取器量化“判错”成分。结论：判别器基本清白，最宽提取也最多 1-2 分——textvqa 单复数漏判 0 条、子串漏判 4 条（+1.6% 封顶）；screenspot 不可解析的 49% 中 48 条是纯散文无坐标（模型在描述而非点击），仅 1 条格式边缘漏判；ocrbench 用官方 contains 式口径依然全零；docvqa 无 32-token 截断。但审计抓到两个真 输入侧 bug：(1) MMMU-Pro 的 options 列在 parquet 里是字符串装的 Python 列表字面量，旧代码直接 join 字符串导致选项被逐字符拆行，prompt 不可读；(2) 渲染选项缺字母标签，而参考答案是字母（“B”），模型无从对应。修复（解析字面量 + A./B./C. 标签，commit bf3413b/f9b94a5，含测试）后离线重建 300 条数据并重测：2.0% → 7.3%（严格），宽松“字母出现即算”18%——0.5B 输出多为推理散文、没有落字母的习惯，严格 exact-match 只承认单字母输出。此基准的 2.0% 旧读数作废，以修复版为准。

评测补跑（5 基准 × trained/random × vision/blind）已全部完成并聚合；仓库归置（Qwen 对照产物归入 gate_b_qwen05_v100/、smoke 产物归入 gate_b_smoke_smol1m135_v100/、README 标注与 DeepSeek 目标无关）与 4 个 checkpoint 补传按串行纪律排在 4B 下载之后。

9.6 Gate C: Vast 只读调研

2026-08-02 12:23 (UTC+8) 用官方 Search Offers API 查询 verified、rentable、可靠度至少 0.98、至少 4 张卡、单卡至少 80 GB、总显存至少 320 GB 的 on-demand offer。市场是动态的，以下价格只用于预算，offer ID 不应写进自动租用脚本。

GPU	总显存	约美元/小时	判断
4×A100 PCIe 80 GB	320 GB	\$4.00	最便宜；无 NVLink，仅作兼容性/低价 smoke
4×A100 SXM4 80 GB	320 GB	\$6.94	300 GB/s NVLink；优先训练候选
4×H100 PCIe 80 GB	约 319 GB	\$8.00	新架构；仍需核验拓扑和 Dgrad
4×H100 SXM 80 GB	约 319 GB	\$10.75	性能优先候选
8×A100 SXM4 80 GB	640 GB	\$10.37	显存余量最大且价格低于当时 4×H100 SXM
4×H200 141 GB	约 562 GB	\$15.74	低 OOM 风险，成本高

正式候选还应要求 NVLink/P2P、至少 512 GB RAM、至少 1.5 TB 本地盘并现场复核 CUDA/驱动。查询结果中最低价 A100 PCIe 只有约 617 GB 可用盘，不满足完整缓存计划；A100 SXM4 候选有约 10 TB 盘。当前阶段只记录 offer，明确不创建实例。

当晚第二次查询（增加 RAM ≥ 500 GB、盘 ≥ 1.5 TB 过滤，33 个 offer）要点：4×A100 SXM4 降至 \$6.41/h（961 GB RAM、2 TB 盘，Gate D 首选）；4×H100 PCIe \$6.93/h（6392 GB 盘，性价比突出）；8×A100 SXM4 \$10.30/h（11 TB 盘，情景 B 兜底）；4×B200 \$21.25/h。新出现的 4×RTX PRO 6000 96 GB（Blackwell，原生 FP4）\$4.54/h 但总线无 NVLink 且 FP4 kernel 支持未验证，仅作参考。

架构修正：A100 为 Ampere，无 FP8/FP4 Tensor Core，0731 的 NVFP4 权重在 Ampere 上没有确认的内核路径，只能解量化至 bf16（568 GB），而 4×A100 的 320 GB 装不下——4×A100 实际上无法加载原生权重，Gate D 首选改为 **4×H100 PCIe**（Hopper FP8 + FP4 专用内核）。8×A100 SXM4（640 GB）仅作为解量化情景 B 的兜底。

9.6.1 最终账单（含下载时间、网络、存储、装机余量）

流量与存储用报价接口的真实计费字段核算：权重下载 160 GB，H100 PCIe 候选流量 \$13.33/TB 约 \$2.13（重传余量加倍 + 数据集/Docker 镜像约 \$1，共约 \$4）；上传仅约 134 MB projector + 800 MB 视觉塔（首次）+ JSON，约 \$0.01。存储按 storage_total_cost 约 \$0.001–0.005/h，租期内几分钱——**但实例 stop 后存储继续按 \$/GB/月计费（约 \$0.107/GB/月，2 TB 停一周约 \$53），结束必须 destroy 而不是 stop。** 装机与依赖调试按 +1.5 h GPU 时间计余量。

阶段（4×H100 PCIe，\$6.93/h）	乐观	基准	悲观
装机 + Docker + 环境调试余量	1 h	1.5 h	2.5 h
0731 权重下载 160 GB（27 分钟理论最优；断流重传见 R4）	0.7 h	1 h	2 h
MoonViT-V2 视觉塔下载 800 MB（sha256 校验）	约 0.05 h	约 0.05 h	0.2 h
训练与评测数据约 30 GB	0.3 h	0.5 h	1.5 h
Gate D 判定（加载→前向→单 batch backward→20 步）	0.5 h	1 h	1 h
对齐训练约 3000 步（checkpoint 随传）	3 h	4 h	5 h
机上 benchmark 三组对照	1.5 h	2 h	2.5 h
权重与结果回传	0.2 h	0.2 h	0.3 h
合计时	7.2 h ≈ \$50	10.2 h ≈ \$71	15 h ≈ \$104

流量费三档均约 \$4–5。**情景 A 最终账单：\$55（乐观） / \$75（基准） / \$110（悲观），按 \$120 预算。**

带宽与耗时已按报价接口的 inet_down 字段核算：H100 PCIe 候选实测下行 2217 Mbps（约 277 MB/s），理论 160 GB 约 10 分钟；考虑 HF CDN 单连接限速（40–100 MB/s）与断流重传（本地实测 802 MB 在慢代理下耗时 2h46m），基准按 1 h、悲观按 2 h 计，租机筛选条件要求 inet_down ≥ 1000 Mbps 并用 aria2/hf_transfer 多连接下载。checkpoint 上行流量每个约 300 MB（projector fp32+bf16+优化器），每 500 步一次，分钟级完成，不影响训练计费。训练日志（train.log）与 history.json 随 checkpoint 一并上传，社区可见完整训练过程。

情景 A'（R3 命中，H100 无法跑 FP4 前向）：转 4×B200（\$21.25/h），同排程基准 10 h ≈ \$213；B200 有原生 FP4 Tensor Core，Dgrad 通过率也更高。决策成本为已耗的装机+下载 1.5–2 h（约 \$10–14）。情景 B（FP4 不可反传且 B200 不可用）：8×A100 SXM4 \$10.30/h，权重解量化至 bf16（568 GB）转换 1–2 h 且训练约慢 3 倍，合计 20–30 h ≈ \$210–310（该候选流量 \$1.33/TB，网络几乎免费）。**建议总预算：\$120 起步（情景 A），预留 \$220（情景 A'/B），上限 \$350；预期实际花费 \$75–110。** 决策点在租后第 2–3 小时：Gate D 不通过即 destroy 止损，损失约 \$20。

9.7 训练显存算术（每卡，权重张量并行切分，视觉塔/projector 每卡复制）

冻结 LLM 与冻结视觉塔意味着：LLM 侧 **没有优化器状态、没有参数梯度**——AdamW 只挂在 projector 上（train_overfit.py 里 AdamW(projector.parameters())），LLM 与视觉塔 requires_grad_(False)，视觉塔前向在 no_grad 里，梯度只需以激活形式穿过 LLM 回到 projector，不需要对视觉塔反传）。优化器全套（权重 fp32 + m/v + 梯度）只有约 0.55 GB。真正的变量是 LLM 权重本体和 Dgrad 路径的激活。

组成 (每卡)	情景 A: 4×RTX PRO 6000, FP4 权重 TP=4	情景 B: 8×A100, bf16 权重 TP=8
LLM 权重	160/4 = 40 GB	568/8 = 71 GB
LLM optimizer + 参数梯度	0 (冻结)	0 (冻结)
MoonViT-V2 权重 (bf16/fp32)	0.8–1.6 GB	0.8–1.6 GB
projector 权重 + AdamW + 梯度	约 0.55 GB	约 0.55 GB
LLM 激活 (grad ckpt, seq ≤700)	1–3 GB	1–2 GB
杂项 (CUDA ctx/碎片/通信 bucket)	5–10 GB	4–6 GB
合计 / 可用	约 47–55 / 96 GB	约 77–79 / 79.1 GB
判定	余量 41–49 GB, 健康	贴顶, 高风险

激活估算依据：开 gradient checkpointing 后只存段边界 (61 层 × seq 700 × 4096 × bf16 约 0.35 GB) 加段内重算临时；micro-batch 4–16 线性放大。seq 上限来自已写死的视觉 token 预算：训练 --max-image-side 640 (方形图最坏 529 视觉 token + 文本 ≤ 700；1024px 原生分辨率只用于评测推理，不进训练回路)。情景 A 的生命线是 FP4/FP8 原生加载成立 (R1–R3)；一旦需要 bf16，任何 4×96GB 级机器都装不下 (568/4 = 142 GB > 96 GB)，只剩 8 卡。情景 B 在 8×A100 上余量不足 2 GB，必须 micro-batch 1 + 更激进 checkpointing，实测 OOM 即升 4×B200 (142 GB/卡，余量约 50 GB，\$21.25/h，账单已含)。

9.8 Gate D 风险清单 (租卡前预演)

不保证一次成功。下表是全部已识别坑点、概率判断与止损方案；核心原则是**失败成本锁死在租后第 2–3 小时** (Gate D 判定，损失约 \$20)，任何一项失败都有明确的下一步，而不是现场想办法。

风险	概率	缓解 / 止损
R1 NVFP4 权重 Dgrad 不可用 (推理内核不支持对输入 embedding 求梯度)	中–高	核心风险。Gate D 单 batch backward 判定；失败即退租转情景 B (解量化 bf16) 或情景 A' (B200 原生 FP4 内核重试)。
R2 Transformers 加载原生 0731 大权重失败 (quantization config 格式未被 5.x 支持)	中	Gate D 第一步即原生加载测试；备选为 vLLM loader 导出 bf16 权重副本 (同时解决 R1)。
R3 FP4 前向内核在目标卡上不可用	低–中	主机器 RTX PRO 6000 即 Blackwell (sm_120, 原生 NVFP4)，此项已从“中”降级；但硬件支持 ≠ 内核带 Dgrad——Gate D 第 0 步用 tools/gate_d_dgrad.py 单层 reproducer 单独判定。失败转 4×B200 (\$21.25/h) 或情景 B。
R4 权重下载断流/限速	高	本地实测 802 MB 在慢代理下耗时 2h46m；租机标称 2217 Mbps 但 HF CDN 单连接限速 40–100 MB/s，160 GB 理论 27–67 分钟，断流可拖至 2h+。用 aria2/hf_transfer 多连接 + 断点续传循环 (已验证的做法)，账单已含 0.5–2h 敏感性。
R5 marketplace 实例被中断	中	checkpoint 流式上传 (每 500 步，含 optimizer/RNG, 28/28 测试)；中断后换机 -- resume 精确续训，损失不足 10 分钟训练。

R6 机器环境与宣传不符 (NVLink 拓扑、驱动、盘速)	低-中	开机 10 分钟内 <code>nvidia-smi topo -m</code> + 盘速快测, 不符当场退租换机, 损失不足 1h 租金。
R7 情景 B 显存算术 (bf16 568 GB vs 8×A100 640 GB)	低	冻结 LLM + activation checkpointing 下单 batch 激活很小, 72 GB 余量足够; 4×H200 (564 GB) 装不下, 明确排除。
R8 Hash-MoE tid2eid 在多卡张量并行下的分布行为	中	hook 方案已在真实 tiny DeepseekV4 类验证; Gate D 的单 batch backward 在大权重多卡下复验, 占位位置路由一致性有断言。
R9 训练数据下载 (约 30 GB) 经代理再耗 1-2 h	中	提前把训练数据镜像到项目 HF 仓库 (随 checkpoint 上行通道同路), 租机从 HF 直下; 计入装机时间。
R10 MoonViT-V2 bf16 与 fp32 参考的特征偏差	低	fp32 参考已锚定 (eager/sdpa 差 $3.1e-05$); Gate D 记录 bf16 实测差 (预期约 $1e-2$ 相对), 超差则视觉塔回 fp32 (仅多约 800 MB 显存)。
R11 租期内时间不够闭环	低-中	checkpoint 流式上传保证权重永不丢; benchmark 三组对照在机上跑但数据落盘 JSON 可增量上传; 最坏情况先公开 checkpoint + 部分指标。
R12 多卡分布策略与 PCIe 拓扑 (4×RTX PRO 6000 无 NVLink, PCIe 5.0 x16 54.2 GB/s; <code>device_map="auto"</code> 朴素模型并行的激活回传走 PCIe)	中	训练吞吐的直接风险: 3-5 s/步 的估计在 PCIe + 重算下可能偏乐观。多卡路径已定型为单进程 <code>device_map="auto"</code> (LLM 冻结, 无需权重梯度分片; vLLM/SGLang 推理 TP 不可用于反向训练)。Gate D 实测单步耗时: ≤ 8 s 维持; 8-15 s 重算步数保 benchmark; > 15 s 验证 transformers 原生 <code>tp_plan</code> 或换 NVLink 机型 (H100 SXM \$10.75/h); 账单按 5 h 悲观档已可吸收 2 倍减速。

9.9 Gate D: 正式租卡前

分阶段判定 (完整版见 docs/gate-d-runbook.md §7, 2026-08-03 评审修订, 各步独立记录不合并):

- 配置发现 + 最小 Dgrad reproducer (tools/gate_d_dgrad.py: 打印量化方案; 只取一层真实 quantized linear 权重切片, 判定 input.grad 有限非零、weight.grad 为 None)。
- `nvidia-smi topo -m` + 盘速快测 (不符当场退租)。
- 原生 0731 权重加载成功; 文本短前向正常。
- 单图短序列 forward (placeholder 注入)。
- 单 batch backward, projector 梯度有限且非零, LLM/MoonViT 无梯度。
- hook × activation checkpointing 数值一致性 (开/关梯度检查点 projector 梯度 allclose) + batch > 1 多图位置一致。
- 多卡路径定型 (`device_map="auto"`) + 实测单步耗时分档 (≤ 8 / 8-15 / > 15 s)。
- 20 step 无 OOM/NaN; `--resume` 从流式 checkpoint 恢复一次且轨迹连续。

9.10 租期闭环排程 (2026-08-02 定价)

核心约束: 租期一结束就没有机器能跑动 0731 做 benchmark 或回传权重, 因此训练、benchmark、上传必须同在一次租期内闭环。交付物只有 projector + 评测 JSON + 报告, 与 GLM 社区只发布 projector 一致, 不回传 160 GB 主干。checkpoint 发两个精度: fp32 master (约 134 MB, 复现/续训用) 与 bf16 serving (约 67 MB, 0731 激活为 bf16), 租期内由训练产物现场转换。推理侧接入 (vLLM/SGLang/llama.cpp/fastllm 补丁点、Hash-MoE 注意事项、验收检查) 已写成 docs/inference-integration.md (2026-08-03 重写为 MoonViT-V2 版), 作为后续给推理引擎提 PR 的合同文档; 要点: vLLM 与 SGLang 均已 Day-0 支持 Kimi-K3 (含 MoonViT3d 视觉塔) 且均有 DeepSeek-V4 文本栈, patch 面只剩 projector 模块、

placeholder 扩展与 Hash-MoE 路由检查; placeholder 固定为现有 <| image |>(id 129279) 禁止扩 vocab, 合并只替换 embedding 向量、input_ids 保留 placeholder 供 Hash-MoE 路由。

训练配方直接采用 Baseten 社区实验的实测方案 (baseten.co/blog/glm-52-with-vision, checkpoint baseten/GLM-5.2-Vision-NVFP4, 唯一公开的同级成功案例): **constant lr 5e-4**——原文未使用任何 LR schedule, LLaVA 式 cosine 属于未在此场景验证的外推, 因此不引入调度器, checkpoint 也无需保存调度器状态 (该待办关闭); global batch 64; 约 66k 条**短 QA** 配对; 2 个 epoch $\approx$ 2070 步。grokking 预期在第一 epoch 末 (约 step 900–1100) 出现 loss 骤降; 每 500 步存 checkpoint 并立刻后台传 HF, 使我们能在 pre/post-grokking checkpoint 间择优。checkpoint 是完整可续训单元 (projector fp32 + bf16、AdamW 状态、RNG、步数、loss 历史, 见 moonvit_glue.checkpointing): 实例中断不丢成果, 社区可实时看到训练曲线形成, 任何 checkpoint 可用 --resume <repo-id> 精确续训 (跨机器 GPU 数不同亦可恢复)。4 $\times$ RTX PRO 6000 估 3–6 s/步 (13B 激活、seq 典型约 450–700——训练 --max-image-side 640 已写死, 1024px 仅用于评测推理、不进训练回路——开 activation checkpointing), 训练段 2–4 h。若 step 约 1400 仍无 grokking 迹象, 按配方谦逊条款执行: 先查数据是否混入长答案, 数据无误则用剩余预算做 200 步 LR 探针 ({1e-3, 2e-4} 各一), 仍无则照常 benchmark 并如实报告负结果; 另注意我们的 MoonViT-V2 projector 为 1024 维输入 (GLM 侧 1152), 无法 warm-start, 全程从零训练。

停训判据不看 loss, 看两条 gap: 主判据是 benchmark 分数 – blind 分数的 gap 随 checkpoint 的曲线, 平台即停; 辅助判据是留出集 shuffle_delta > 0.1。参考锚点: projector-only 的 TextVQA 现实预期 20–30% (blind 约 10–15%, 成熟 VLM 60+); 达到 GLM 社区实验同量级 (grounding parse 率 >80%、Acc@50 个位数) 即成功。

阶段	时长	说明
装机 + 下载权重	1–1.5 h	160 GB; 好主机 1–2 GB/s
Gate D 判定	0.5–1 h	FP4 Dgrad 失败则当场退租 (损失约 \$10), 转情景 B
Stage 1 对齐训练	2–4 h	约 2100 步 (66k 短 QA $\times$ 2 epoch, batch 64, constant lr 5e-4); checkpoint 随训随传; step 约 1400 无 grokking 则停训查数据
benchmark 全套	1.5–2 h	TextVQA 500 / DocVQA 200 / OCRBench 200 / ScreenSpot 200; 训练 checkpoint $\times$ blind $\times$ 随机 projector 三组对照, 机上完成
权重与结果回传	0.5 h	projector 约 134 MB + 评测 JSON 上传 HF
合计	6.5–9 h	4 $\times$ RTX PRO 6000 (\$5.18/h 含 400 GB 挂盘) 约 \$34–47; \$50 余额单次闭环可行, 失败重试需追加

若 FP4 Dgrad 不可用 (情景 B): 权重解量化至 bf16 (568 GB), 需 8 $\times$ A100 SXM (\$10.30/h), 同排程时长大约 $\times$ 2–3, 预算 \$300–500。

10 评测与验收计划

没有 benchmark 就无法回答 “接上了没有”。评测口径对标 Baseten 社区 GLM-5.2V 实验 (原文 baseten.co/blog/glm-52-with-vision,0xSero/fable-glm-vision 复现): 双方视觉塔都来自 Kimi 的 MoonViT3d 家族 (他们从 Kimi K2.6 抽取, 我们从 Kimi K3 抽取 MoonViT-V2, 当前塔宽 1024), 其标志性指标是 **MMMU-Pro** (原文声称 55%, 约 Claude 4.5 Haiku 水平), 因此我们的评测集在 TextVQA/DocVQA/OCRBench/ScreenSpot 之外加入 **MMMU-Pro (单图子集, exact match)**。所有数字必须与 blind baseline (同一模型、无图输入) 一起报告: VQA 类基准有显著语言先验, 无图基线把 “模型本来就会答” 与 “图像带来了信息” 分开。

社区配方还有两个直接影响数据计划的实测结论：其一，**grokking**——batch 64 / lr 5e-4 配短答案时 loss 平台数百步后骤降（原文约 step 900）完成对齐，**长描述性答案会阻止 grok**，因此对齐数据应以短 QA 为主、长 caption 为辅，而不是只用长 caption；其二，**warm start**——从已对齐 projector 初始化可跳过大半平台期，多阶段数据混训时应复用上一阶段 checkpoint 而不是重零开始。

训练数据泄露控制（2026-08-03 定稿，GUI 修订）：正式 mix 含 TextVQA train (34.6k)、DocVQA train (25k)、0xSero art 子集(约 10k)与 ShowUI-desktop(8k)四类短答案监督；GUI 数据按用户决定纳入以建立 computer-use 基础，答案统一为 0xSero 动作格式 `click(start_box=[x,y])` (0..999 尺度，评测 parser 原生兼容)。0xSero 自带的 screenshots/multistep 行不直接复用（图像改名无法回 join；multistep 为轨迹格式），改为从同源公开数据集自取。代价与处理：ScreenSpot 自此为**域内基准**，报告中必须标注；fetch 规格机械执行 `max_answer_words ≤ 20`；组装去重为三道独立机制（2026-08-03 评审加固）：感知 aHash (hamming ≤ 6，抓缩放/重压缩重复) + 精确像素 sha256 (抓跨容器同内容) + 归一化问题文本近重复 (--eval-jsonl 抓跨 split 文本泄露)，各机制的丢弃数分别计入 `decontamination_report.json` 随数据发布。数据产物托管于 dataset repo `cyjin-yl/moonvit-dsv4-data`，含来源、固定 revision 与 sha256，租机上一次下载即用（上传通道已实测：新 huggingface_hub 分块上传经代理约 2.6 MB/s，全量数据约 1.5–2 h，见变更日志）。

已实现的评测资产：

- `moonvit_glue.metrics`：纯 Python 指标，无 torch 依赖。exact match、soft VQA（官方 min(1, 同意人数/3)）、ANLS、token-F1，以及 grounding 的 parse/Acc@threshold/mean error。
- `tools/eval_vlm.py`：生成式评分 (--blind 输出无图基线) 与 --shuffle-loss (真图 vs 随机图的 teacher-forced loss 差) 两种模式。shuffle-loss 是训练前最便宜的信号检验：projector 学到东西后，真图 loss 应显著低于随机图。
- `tools/fetch_eval_data.py`：固定来源拉取 TextVQA (soft VQA)、DocVQA (ANLS)、OCRBench (exact match)、ScreenSpot (in-box grounding)、MMMUI-Pro (单图子集，exact match)，落盘 JSONL 与 MANIFEST.json (resolved revision sha 与 JSONL sha256)，沿用“信任 manifest 而不是 tag”的纪律。

阶段	运行内容	通过判据
Gate A	指标单元测试；小模型 shuffle-loss 管线	测试全绿；管线可跑
Gate B	真实 MoonViT + 小 LM：生成、评分、blind 对照；overfit 训练	端到端无报错；shuffle_delta = +0.343（显著为正）
Gate C	训练前/后各一次：TextVQA、DocVQA、OCRBench、ScreenSpot 小子集	训练后显著高于训练前与 blind

预期锚点：0xSero 的 GLM-5.2 projector-only checkpoint 报告坐标格式解析率 92%、Accuracy@50 4.3%、平均点击误差约 564/999。第一阶段的成功定义是 DeepSeek 路径达到同量级信号，而不是成熟 VLM 水平；grounding 在 projector-only 阶段大概率仍很弱。

本地对照臂（与租机训练并行，不花租金钱）：(1) MoonViT-V2 + 小型纯文本 LM (Gate B 各 checkpoint) 跑全套 1,400 例，作为“胶水通路在小模型上的接口可学习性”读数；(2) 原生 4B VLM（官方权重、官方精度）经独立适配脚本读同一 eval JSONL、输出同格式评分，只作为评测阳性对照和成熟小 VLM 参照，不作为映射/迁移证据；(3) 小模型 projector 不能直插 0731 (hidden 896/576 vs 4096)，合法对照臂是“小模型 trunk 热启动（到 GELU 的 4,096 维）+ V4 重训最后一层”，与全程从零的 scratch 臂对比收敛速度。除非另有具体问题，不再追加 9B/27B 原生 VLM 对照；它们不会缩小 DeepSeek 证据缺口。

11 数据集挑选过程与构建管线

本章记录正式数据资产的挑选理由、排除项与现行构建做法（2026-08-03 定稿）。所有产物托管于 dataset repo `cyjin-yl/moonvit-dsv4-data`，来源、resolved revision 与逐片 sha256 随数据发布。

11.1 挑选原则

- 1. **对标社区实验**：评测集与训练集对齐 Baseten/0xSero 的 GLM-5.2V 配方——他们用的我们照用，保证数字横向可比；其标志指标 MMMU-Pro 必须在内。
- 2. **短答案优先**：社区实测长描述性答案会阻止 grokking，正式训练集全部为短答案监督 (fetch 机械执行 max_answer_words ≤ 20)；长 caption 只用于 Gate B 信号验证，不进正式 mix。
- 3. **视觉塔同源**：视觉塔从 Kimi K3 抽取 (与 0xSero 从 K2.6 抽取同族)；art 子集离线复刻 0xSero build_art_dataset.py 的 QA 模板与 schema (tools/fetch_art_data.py)，减少配方变量。
- 4. **可复现优先**：每个来源固定 resolved revision；逐分片 sha256 对 LFS oid 校验；MANIFEST 随数据发布，信任 manifest 而不是 tag。

11.2 评测集 (1,400 行)

数据集	来源 (HF)	行数	指标	挑选理由
TextVQA val	lmms-lab/textvqa	500	soft VQA	OCR-VQA 基本盘，社区通用口径
DocVQA val	lmms-lab/DocVQA	200	ANLS	文档理解，与训练同族任务的 held-out
OCRBench test	echo840/OCRBench	200	exact match	纯文字识别
ScreenSpot test	rootsautomation/ScreenSpot	200	in-box grounding	GUI 定位；ShowUI 进训练后为域内基准，报告中单独标注
MMMU-Pro test	MMMU/MMMU_Pro_standard (10 options) 单图子集	300	exact match	社区实验标志指标 (原文声称约 55%)

每行一图，图像落盘，JSONL 附 MANIFEST (resolved revision + 逐分片 sha256 + JSONL sha256)。评测纪律：分 selection/final 两半——checkpoint 选择只看 selection 半，final 半只对最终 checkpoint 跑一次，避免把 test 当训练集；域内 (ScreenSpot) /跨域/零样本三组分开报告，不混入一张表。

11.3 训练集 (四类短答案监督)

来源	行数	答案形态	理由
lmms-lab/textvqa train	34,602	短答案	与评测同任务不同 split；组装时对 eval 做文本去重
lmms-lab/DocVQA train	约 25,000	短答案	文档 QA；12 个官方 train 分片离线抽取
showlab/ShowUI-desktop train	7,496	GUI 动作 click(start_box=[x,y]) (0..999 尺度)	用户决定纳入，建立 computer-use 基础；答案格式与评测 parser 原生兼容
Artificio/WikiArt_Full + benitomartin/fashion-product-images-small-384x512	池 71,780 + 2,220 val；mix 取约 10,000	短描述 QA	与五个评测集零交集；复刻 0xSero schema

11.4 排除项与理由

- **长 caption 数据** (flickr8k/COCO 类)：grokking 实证表明长答案阻止对齐；flickr8k 仅用于 Gate B 信号轨，不进正式 mix。

- **0xSero screenshots / multistep 行**: screenshots 图像经改名无法回 join; multistep 为轨迹格式, 与单步 QA 合同不符。GUI 监督改从同源公开集 ShowUI-desktop 自取。
- **与评测集近重复的任何行**: 见下方三道去重机制。
- **低于发布精度的量化对照**: 对照组评测一律官方发布权重精度 + 官方 kernel; fp8 发布的模型升 bf16 无损可做, GGUF Q4/Q6 等降精度量化不做——量化损失会混进“模型能力”读数。本地 V100 跑不动全精度 27B 则放弃该臂, 或挪入租机 benchmark 窗口。

11.5 下载与校验通道 (现行做法)

十二种数据源、93 个正式分片全部落 staging, 逐片 sha256 对 LFS oid 校验并打 .sha256ok 幂等标记, 最终 0 mismatch。通道是实测淘汰出来的:

- hf_transfer 在代理下 0 字节挂起; hf-mirror 限流; 工作站 datasets+dill 无法 pickle pyarrow MonthDayNano (任何本地 parquet 都炸 load_dataset) → fetch 全程 raw pyarrow 离线直读 (--data-files)。
- ModelScope 镜像境内直连可达 8.8 MB/s, 但约 1.5 小时高强度拉取后被 CDN 按 IP 渐进限速至 0; Tailscale 中继 (RTT 3.7 s, 聚合 250–400 KB/s) 与代理同速且挤占家庭带宽, 应用户要求退役。
- 最终方案: 工作站经 Clash 代理 aria2 预取 + 离线 fetch。代理上下行共享总带宽 (约 250 KB/s 封顶), **上传与下载严禁并行**, HF 上传统一串行排在下载之后。
- **关键事故**: xet-bridge 签名 URL 按 range 签发, aria2 -x8 分段重试拿过期 URL 会读到错 range 的字节并写入错偏移——TLS 合法、文件尺寸正确、内容静默损坏 (25 片)。根因定位后改单连接 -x1 -s1 + 每片 sha256 校验, 坏片全部重拉修复; 另修 aria2 不认大写 HTTPS_PROXY 一处。

11.6 组装、去重与打包

1. tools/build_train_mix.py 按配额组装 (TextVQA train 全量 + DocVQA train 25k + ShowUI 8k + art 10k), 三道独立去重: 感知 aHash (hamming ≤ 6, 抓缩放/重压缩) + 精确像素 sha256 (抓跨容器同内容) + 归一化问题文本近重复 (对五份 eval 全量比对, 抓跨 split 文本泄露); 各机制丢弃数分别计入 decontamination_report.json 随数据发布。
2. tools/pack_to_parquet.py 打包: union-keys schema (from_pylist 只按首行推断的坑已修, 测试 6/6); train 按 20,000 行分片, eval 五份各打一包。图像统一为 PNG 字节内嵌 parquet——付费服务器上顺序读、免密集小文件 IO, 租机下载一次即用。
3. 串行上传 cyjin-yl/moonvit-dsv4-data (已传文件自动跳过); README 记录来源、revision、sha256 与复现命令, 原数据集协议随产物保留。

11.7 当前状态 (2026-08-04)

- eval_v1: 五个评测集 1,400 行 + 1,400 张图像 + MANIFEST, 完成并已上传 cyjin-yl/moonvit-dsv4-data。
- train_v1: 59,198 行 mix (TextVQA 29,252 / DocVQA 17,351 / ShowUI 5,167 / art 7,428; 三道去重合计丢弃 23%) 打包 3 片约 20 GB, 完成并已上传。
- sft_art: 71,780 train / 2,220 val, 完成并已上传。
- Gate B 全量 mix 训练: 完成 (2000 步, shuffle_delta +0.727); 五基准评测完成并聚合 (见 9.5 终表); 待办: 仓库归置 + 4 个 checkpoint 补传 + stock 4B 对照评测 (下载收尾中)。

12 变更日志

日期	变更
2026-08-02	建立通用 placeholder 扩展、PatchMerger、MoonViT wrapper 和 DeepSeek embedding hook。
2026-08-02	确认 0731 已有 < image > ID 129279, 禁止扩 vocab。
2026-08-02	真实缩小 DeepSeek-V4 Hash-MoE 完成 backward。

2026-08-02	发现 Transformers 4.57.6 缺少 DeepSeek-V4; 基线切换为 5.12+。
2026-08-02	完成 Vast on-demand 只读快照; 未创建或租用实例。
2026-08-02	公开仓库 cyjin-yl/moonvit-deepseek-v4-glue 上线并推送。
2026-08-02	新增评测资产: metrics 指标库、eval_vlm 评分器 (含 blind 与 shuffle-loss 模式)、fetch_eval_data 数据清单; 新增 generate() 生成路径。
2026-08-02	V100 工作站: torch 2.10.0+cu128 确认含 sm_70; 26/26 测试通过; 记录 NVML mismatch 与 Xet-over-proxy 挂起 (HF_HUB_DISABLE_XET=1 解决)。
2026-08-02	V100 完成真实 MoonViT smoke (fp32) 与评测管线端到端干跑; 发现 MoonViT remote code 与 Transformers 5.x 两处不兼容并 shim; 确认视觉 token 数可顶爆小模型上下文。
2026-08-02	Gate B 通过: V100 上冻结 MoonViT + SmolLM2-135M 只训 projector, 1000 步后 shuffle_delta = +0.343; 生成随图变化、blind 恒定。数据路径修复为相对 JSONL。
2026-08-02	Gate B 第二 backbone 复测通过: Qwen2.5-0.5B 同条件 shuffle_delta = +0.282, 确认信号与文本主干选型无关。
2026-08-02	Gate B 第三轨通过: flickr8k 1100 条 (jxie 开放镜像, 离线 parquet 救援落盘), Qwen2.5-0.5B 1500 步 shuffle_delta = +0.148; 三轨全部通过。
2026-08-02	训练器支持流式 checkpoint: 每 500 步保存 projector(fp32+bf16)+AdamW+RNG 的完整可续训单元, 后台线程传 HF; --resume 可从任一 checkpoint 精确续训。
2026-08-02	对齐社区 GLM-5.2V 配方: 确认其视觉塔同为 MoonViT、标志指标为 MMMU-Pro (加入评测集); 记录 grokking (短答案) 与 warm-start 两条训练结论; 带宽速度与数据集流量成本计入预算。
2026-08-03	MoonViT-V2 移植验证: K3 视觉代码 vision-only 抽取并 vendor 进仓库 (去文本模型依赖); 随机权重前向输出 [G,4,1024] 符合 PatchMerger 合同; 新增 sdpa varlen attention 并与 eager 数值一致; moonvit_v2 wrapper 复用 MoonViTEncoder 契约; 34/34 测试通过。权重单分片 (802 MB/1.56 TB) 下载中, HF 写权限已验证。
2026-08-03	真实权重回归完成: shard 96 下载 (sha256 9d10c74f...) → 抽取 165 张量 strict-load 通过 → V100 真实前向 [1369,4,1024]@1024px、finite、逐位确定、eager/sdpa 差 3.1e-05 → 34/34 回归 → 产物 (含 sha256 MANIFEST) 上传 HF vision_tower_k3/; 训练/评测支持 --vision-tower v2。
2026-08-03	推理集成文档重写为 MoonViT-V2 版: 确认 vLLM/SGLang 均 Day-0 支持 K3 (含 MoonViT3d) 且均有 DeepSeek-V4 文本栈, patch 面收敛为 projector 模块 + placeholder 扩展 + Hash-MoE 路由检查; llama.cpp/fastllm patch 点记录在案但 v1 不做。新增 Gate D 风险清单 (R1-R11, 每条带缓解与止损) 与三档最终账单 (情景 A \$55/\$75/\$110, 预算 \$120; 情景 A' B200 与情景 B 约 \$210-310; 上限 \$350); projector 合同更新为 V2 的 33,564,672 参数。
2026-08-03	下载通道定论: aria2 多连接预取 parquet + 离线 pyarrow fetch (--data-files), 绕开 hf_transfer 挂起、hf-mirror 限流与 datasets+dill 的 MonthDayNano pickle 崩溃; 新增 prefetch_parquet 与 fetch_art_data

	(0xSero art 离线复刻); MMMU-Pro config 修正为 standard (10 options); 62/62 测试通过。
2026-08-03	租前全链路彩排通过 (Gate B+): V100 上 400 步训练 + checkpoint 流式上传 + 三组评测 + 聚合全部闭环并落 HF; 训练组 gap +0.117 vs 随机对照 +0.019, 管线可判别; 作为正式训练的对照组基线。
2026-08-03	外部评审 (Max) 并入 runbook: Gate D 分阶段化 (含 gate_d_dgrad.py 单层 Dgrad reproducer、hook×梯度检查点数值一致性、device_map="auto" 步时定律); 版本固定 + pip freeze 随产物; 视觉 token 预算写死 (训练 640 / 评测 1024); 配方谦逊条款 (LR 探针兜底); 评测纪律 (selection/final 两半、域内/跨域/零样本三组、3 种子 shuffle 统计)。
2026-08-03	数据管线定稿并写入报告新章节: 评测 5 集 1,400 行 (TextVQA/DocVQA/OCRBench/ScreenSpot/MMMU-Pro) 与训练 4 类来源 (TextVQA train 34.6k、DocVQA train 25k、ShowUI-desktop 7.5k、art 池 71.8k 取 10k) 的挑选理由与排除项; 93 个正式分片 sha256 校验 0 mismatch; 三道去重、union-keys parquet 打包与串行上传纪律; DocVQA train 抽取收尾中。
2026-08-04	数据全链路闭合: train_v1 mix 59,198 行 (去重丢 23%) + eval_v1 + sft_art_v1 全部上传 cyjin-yl/moonvit-dsv4-data; 数据仓 README 记录来源、revision、sha256 与复现命令。
2026-08-04	Gate B 全量 mix 训练完成 (V100, Qwen2.5-0.5B + MoonViT-V2, 2000 步): loss 6.41→3.01, held-out shuffle_delta +0.727 , 全量数据上视觉对齐信号明确; 修复占位 token 双默认值不一致 bug (训练 Qwen < image_pad > vs 评测 DeepSeek < image >) 为候选自动探测, 85/85 测试; 4 个 checkpoint 因代理 SSL 抖动待手动补传。
2026-08-04	Gate B 五基准终表 (trained/random/blind): textvqa 0.081/0/0、docvqa 0.039/0/0、ocrbench 0/0/0 (地板)、screenspot 解析 0.51 精度 0.01、MMMU-Pro 0.073/0/0——判别力三条全成立, 绝对读数如实留存 (含坏结果)。误判审计: 判别器清白 (最宽提取 +1~2% 封顶); 抓到 MMMU 输入格式化两个 bug (选项字面量被逐字符拆行、缺字母标签), 修复后 2.0%→7.3%, 旧读数作废。
2026-08-04	原生 Qwen3.5-4B 阳性对照修复并跑完: 发现同字节数坏 shard (视觉塔全集所在分片)→SHA-256 manifest 校验、1024px 上限与指标化短输出约束。修复后 vision/blind: TextVQA 0.820/0.031、DocVQA 0.926/0.071、OCR-Bench 0.900/0、ScreenSpot acc 0.760/0.010、MMMU-Pro 0.300/0.280。用户指出并纠正证据边界: 该模型自带视觉塔与多模态对齐, 只验证评测器, 不证明 MoonViT-V2→DeepSeek; 训练器新增原生 VLM 拒绝保护, Gate D 才是目标能力证据。

13 下一位执行者的最短路径

先运行 `pytest` 和 `examples/smoke_tiny_text_lm.py`。然后在 V100 工作站使用机械盘作为 `HF_HOME`, 按 MANIFEST 校验并验证真实 MoonViT-V2。正式 0731 实验前不要写训练循环, 先证明目标 CUDA/量化 runtime 支持 input data-gradient。若失败, 优先评估 FP8 可微加载或定制 Dgrad, 不要改用 GGUF 假装完成训练链路。