

MoonViT-V2 接入 DeepSeek-V4-Flash-0731

训练前架构审计、胶水原型与硬件计划

版本 0.4 · 2026-08-05

Contents

1	执行摘要	3
2	来源与可复现边界	3
3	权重与张量合同	3
4	DeepSeek-V4 特殊适配	3
5	已完成验证	4
6	MoonViT-V2 尺寸与适配性	4
7	MoonViT-V2 (Kimi K3 视觉塔) 移植	4
8	本地与云端硬件计划	5
9	分阶段门槛	6
9.1	Gate A: 无需大权重	6
9.2	Gate B: V100 工作站	6
9.3	Gate B 实测: projector overfit 实验 (2026-08-02)	6
9.4	Gate B+: 租前全链路彩排 (2026-08-03, 正式训练的对照组)	7
9.5	Gate B 全量 mix early-alignment (2026-08-04, V100, 工程/信号闸门)	8
9.5.1	五基准评测终表 (selection 半侧, 1024px, 逐条原始输出已公开于 HF eval/v100-fullmix-qwen05/)	9
9.5.2	0.5B 主干的容量混杂	9
9.5.3	证据边界: 原生 VLM 不是 DeepSeek 代理	9
9.5.4	误判审计 (应用户要求: 先怀疑判别器, 再怀疑模型)	10
10	冻结语言主干中的视觉感知涌现: V100 方向筛选实验	10
10.1	实验基础设施与真实计量 (包 1, 2026-08-04)	11
10.2	Synthetic Perception Diagnostic (包 2, 2026-08-04)	11
10.3	Checkpoint-wise Emergence of Visual Dependence (包 3, 2026-08-05)	12
10.3.1	固定口径、checkpoint 与有效性	12
10.3.2	Teacher-forced paired preference: shape 在 step 1500 短暂出现	12
10.3.3	自由生成: 视觉触发存在, 正确图像内容没有进入成对答案	13
10.3.4	真实 heldout 与 benchmark 轨迹	14
10.3.5	假设更新与下一项本地实验	14
10.4	Shape 的逐层机制定位 (包 4, 2026-08-05)	15
10.4.1	冻结口径与校准 null	15
10.4.2	projector 没丢 shape; 训练后的上层把它压回 chance	15
10.4.3	activation patching: 中层存在内容特异因果通路	16
10.4.4	token-position 干预边界与假设更新	16
10.5	Shape 适配诊断 (包 5, 2026-08-05)	17
10.5.1	等训练顺序的顶部 LoRA 与 projector 续训	17
10.5.2	逐层复测: projector 重新建立稳定的晚层通路	18
10.5.3	假设更新与下一项本地实验	18
10.6	Shape-only projector 的六任务迁移 (包 6, 2026-08-05)	19
10.6.1	零附加训练的预注册迁移矩阵	19
10.6.2	Teacher forcing 与自由生成给出同一边界	20

10.6.3	假设更新与下一项本地实验	20
10.7	六任务均衡 projector continuation (包 7, 2026-08-05)	21
10.7.1	可审计缓存与真实 batch	21
10.7.2	一轮监督建立六任务 teacher-forced 视觉读出	21
10.7.3	剩余差距集中在冻结语言栈的使用与生成	22
10.7.4	假设更新与下一项本地实验	22
10.8	Gate C: Vast 只读调研	23
10.8.1	最终账单 (含下载时间、网络、存储、装机余量)	23
10.9	训练显存算术 (每卡, 权重张量并行切分, 视觉塔/projector 每卡复制)	24
10.10	Gate D 风险清单 (租卡前预演)	25
10.11	Gate D: 正式租卡前	26
10.12	租期闭环排程 (2026-08-02 定价)	26
11	评测与验收计划	27
12	数据集挑选过程与构建管线	28
12.1	挑选原则	28
12.2	评测集 (1,400 行)	28
12.3	训练集 (四类短答案监督)	29
12.4	排除项与理由	29
12.5	下载与校验通道 (现行做法)	29
12.6	组装、去重与打包	30
12.7	当前状态 (2026-08-04)	30
13	变更日志	30
14	下一位执行者的最短路径	33

1 执行摘要

本项目目标是给纯文本的 DeepSeek-V4-Flash-0731 接入从 Kimi K3 抽取的 MoonViT-V2 (MoonViT3d) 视觉编码器。第一阶段不训练视觉塔和语言模型，只训练一个 Kimi 风格 PatchMerger projector; 独立发布的 MoonViT-SO-400M (V1) 只保留作历史对照。当前结论是: V2 的真实权重、预处理和 [tokens, 4, 1024] 合同均已在 V100 验证。包 3-6 依次定位 shape 内容信号、证明 tower/projector 保留信息、用短程 projector 续训完全恢复 shape, 并确认这种 shape-only 恢复不跨任务泛化。包 7 随后用一轮六任务均衡监督使全部任务的 teacher-forced paired preference 和 vision-shuffle 下界同时转正; 自由生成仍只有 shape/spatial 形成 paired 改善, 因而剩余问题已收敛到冻结语言栈的使用/解码与训练量。正式 0731 大权重的 FP4/FP8 可微 kernel 仍是尚未消除的主要风险。

MoonViT-V2 有 401.2M 参数, 抽取后的 BF16 权重约 802 MB, 相对于约 160 GB 级的 DeepSeek 混合精度权重很小。更大的资源变量是图像分辨率带来的视觉 token 数和冻结 LLM 反向所保留的激活, 而不是视觉塔权重。

2 来源与可复现边界

- 社区 projector checkpoint: 0xSero/glm-local-vision-checkpoint。它证明了 projector-only 路线能把视觉信号接到 GLM-5.2, 但公开 grounding 指标仍弱, 不能等同于成熟 VLM。
- 社区复现记录: Giving a 753B Model Eyes。
- DeepSeek 权重: deepseek-ai/DeepSeek-V4-Flash-0731, MIT。
- 当前视觉塔: 从 Kimi K3 的 MoonViT3d 权重分片抽取的 MoonViT-V2; 抽取权重、配置、代码快照与哈希清单发布在项目模型仓 vision_tower_k3/。
- 历史对照视觉塔: moonshotai/MoonViT-SO-400M, MIT。
- Kimi-K2.5 技术报告: Kimi K2.5: Visual Agentic Intelligence。
- Vast offer 搜索接口: Vast.ai Search Offers API。本文只调用搜索接口, 不调用创建实例接口。

独立 MoonViT-SO-400M 来自 Kimi-VL; 当前主线使用 Kimi K3 的 MoonViT3d/MoonViT-V2。两者输出合同同构不代表特征分布或通道宽度相同。视觉塔 revision 与权重哈希是训练 provenance 的组成部分; 更换视觉塔必须重训 projector。

3 权重与张量合同

组件	合同	状态
MoonViT-V2	[tokens, 4, 1024]	冻结
PatchMerger	LN(1024) → flatten → 4096 → GELU → 4096	训练
DeepSeek embedding	vocab → 4096	冻结
Placeholder	< image > / ID 129279	现有词表
Hash-MoE routing	扩展后的 placeholder IDs	冻结

V2 projector 精确参数量是 33,564,672 (fp32 约 134 MB, bf16 约 67 MB; 配置见 configs/deepseek-v4-flash-0731-projector-moonvit-v2.json)。备选的 V1 塔 (MoonViT-SO-400M, 1152 维) projector 为 40,119,040 参数, 两条配置不得混用。保存格式由 projector_config.json 与 projector.safetensors 组成, 加载时使用 strict state-dict 校验。MoonViT、DeepSeek 与 projector 始终保留为三个可独立哈希和升级的来源, 不把大权重复制到自有仓库。

4 DeepSeek-V4 特殊适配

DeepSeek-V4 的早期 Hash-MoE 通过 tid2eid[input_ids] 选 expert。只给 inputs_embeds 会丢失路由 IDs, 而当前公共 forward 不允许同时给 input_ids 和 inputs_embeds。

原型保留扩展后的 placeholder IDs，并用仅在一次 forward 内生效的 embedding forward hook 替换查表输出。这样 Hash-MoE 看到合法 token IDs，Transformer 隐藏状态看到 projector embeddings，loss 仍可反向到 projector。hook 在 forward 结束后自动移除，不修改 Transformers 源码。

不得向 0731 tokenizer 增加 <image>：扩词表会同时要求修改输入 embedding、LM head 和 Hash-MoE 的 tid2eid 表。0731 已含多个视觉相关 token，因此没有必要承担该风险。

5 已完成验证

测试	结果	意义
Placeholder 可变长度扩展和 label mask	通过	序列/监督合同
Projector Safetensors round-trip	通过	权重可恢复
冻结普通 GPT-2 的 backward	通过	通用文本主干
真实 DeepseekV4ForCausalLM 1 层 Hash-MoE	通过	DeepSeek 路由合同
MoonViT-V2 输出 shape/freeze 合同	通过	真实 K3 视觉权重
真实 MoonViT-V2 + 小 LM 前向/反向	通过	V100 CUDA eager/sdpa
eval_vlm 生成/blind/shuffle-loss 干跑	通过	评测管线端到端
generate(): generic 与 deepseek_v4 两种路径	通过	评测/推理前置
指标库 (VQA/ANLS/token-F1/grounding)	通过	纯 Python，无 torch
完整测试集	184/184	Linux + torch 2.10.0+cu128；含包 7 masked-padding、无 random 轨迹、缓存与非单调判定回归

V100 实测：真实 K3 MoonViT-V2 在 1024×1024 输入下输出 [1369,4,1024]，特征全部 finite、逐位确定，eager 与 sdpa 最大绝对差 3.1e-05；真实权重 strict-load、预处理与 loss/backward 合同均正常。旧 V1 路径也保留了 448px 和原生分辨率回归，但不再代表当前训练主线。评测管线的生成、blind 基线与 shuffle-loss 全部端到端通过；训练后 shuffle-loss 差值应当变正，这是对信号最便宜的读数。

离线 smoke 结果：输入 6 token 扩展为 8 token；projector 六组参数均获得梯度；语言模型参数梯度数为 0。同一结果在 doesworkstation (V100) 上复现。

版本审计发现，公开 PyPI Transformers 4.57.6 不含 deepseek_v4 模块；真实 DeepSeek 类测试使用 Transformers 5.14.1。因此统一环境暂定 transformers>=5.12,<6，不能盲从 checkpoint config 中的历史版本字符串。

6 MoonViT-V2 尺寸与适配性

MoonViT-V2 适合该任务：27 层、hidden size 1024、12 heads、401.2M 参数，原生分辨率和 NaViT packing 对 GUI、文档、截图有价值。它不会显著改变完整 0731 的权重门槛；V1 的 1152 维/16 头规格只作为对照记录。

风险来自 token 数。patch size 为 14，随后 2×2 合并。392×392 图像产生约 196 个合并 token；896×896 产生约 1024 个。第一阶段应把每图上限锁在 1024；更高分辨率必须以梯度激活显存实测决定。

7 MoonViT-V2 (Kimi K3 视觉塔) 移植

按项目决策，视觉塔改为从 Kimi 直接抽取 (K3 优先，K2.6 备选)，与社区 GLM-5.2V 实验同源（他们从 K2.6 抽）。Kimi-K3 仓库全量约 1.56 TB，但其 safetensors index 显示全部 165 个 vision_tower.* 张量

集中在单个分片 model-00096-of-000096.safetensors (约 802 MB)。抽取与验证全部在自有工作站完成，不依赖租用机器；租服务器时使用抽取后的独立视觉塔产物，不触碰完整 K3 仓库。

K3 的 MoonViT3d(下称 MoonViT-V2)与 MoonViT-SO-400M 的合同差异: vision width 1152 → **1024** (27 层、12 头、qkv 1536、rmsnorm、无 attn bias、divided-fixed 位置插值); merge 方式 sd2_tpool, 单图 (t=1) 时时域池化为恒等, 输出仍是每图 [tokens, 4, 1024] 的特征组——与既有 PatchMerger 的 [G,4,C] 合同同构, 胶水层零改动, 仅 projector 的 vision_width 换为 1024 (flatten 维度 4096)。输入格式为 NaViT packing 的 [total_patches, 3, 14, 14] + grid_thws, 与 V1 的 flatten 格式不同, 由 processor 适配器统一。

移植方式: 将 K3 仓库中视觉塔所需的最小代码集 vendor 进本仓库 (src/moonvit_glue/vendor/kimi_k3/, Apache-2.0 + Kimi K3 License, 已附 LICENSE), 删除文本模型依赖 (modeling_kimi_linear 要求更新版 Transformers 的 OutputRecorder, 与本项目 5.12 基线冲突) 与条件生成类; 加载不再需要 trust_remote_code, 也不再需要下载完整 K3 仓库。moonvit_glue.moonvit_v2 复用既有 MoonViTEncoder 契约 (freeze、形状校验、preprocess), 新增 sdpa varlen attention (K3 代码只注册 flash-attention-2 与 eager; V100 等无 flash-attn 硬件用 eager/sdpa, 数值一致性有测试)。

已验证 (工作站): vision-only 模块独立实例化 (真实配置 401.2M 参数); 前向输出 [G,4,1024] 符合合同; eager 与 sdpa 注意力数值一致; 带/不带 vision_tower. 前缀的 state-dict 均 strict 加载; processor 适配器产出 pixel_values/image_grid_hws 合同键; 完整测试集 34/34 通过。真实 shard 的 header 元数据与模型 state_dict 逐项比对: 165/165 key、形状、dtype (全 BF16) 完全一致, 且该 shard 不含任何非视觉权重。**服务器端同样只需部分下载**: 干净房间测试 (PYTHONPATH 仅含本仓库、无 K3 staging) 确认 vendored 代码只依赖 stdlib/torch/transformers/numpy/PIL, 租机时视觉塔侧只需 git 仓库 + 抽取产物 (约 800 MB, 附 sha256 MANIFEST 供下载校验), 完整 K3 仓库不进入训练链路。

真实权重回归 (2026-08-03): shard 下载完成 (802,448,352 B, sha256 9d10c74f...), tools/extract_moonvit_v2.py 抽取 165 张量 / 401.2M 参数并 strict-load 通过, 产物 moonvit_v2.safetensors (BF16, sha256 01436a95...) + MANIFEST (双哈希)。V100 上真实权重前向: 1024×1024 图像 → 5476 patches (74×74 grid) → [1369,4,1024], 全部 finite, 特征统计健康 (mean 0.0003 / std 0.0511 / absmax 0.60, RMSNorm 后典型量级); 两次前向逐位一致 (确定性); eager 与 sdpa 在真实权重上最大绝对差 3.1e-05 (fp32 累加顺序的正常量级)。抽取产物上传至项目 HF 仓库 vision_tower_k3/ 子目录, 训练与评测经 --vision-tower v2 --moonvit-v2-weights 使用。

8 本地与云端硬件计划

目标	建议硬件	判断
胶水/单元测试	CPU 或任意 8 GB GPU	已完成
MoonViT-V2 + 0.5B–3B LM	12–24 GB GPU	适合本地开发
V100 32 GB	SM70、32 GB	可跑 MoonViT-V2/小 LM; 不能装完整 0731
完整 0731 推理验证	同机 4×48 GB 起步	上下文和 kernel 受限
projector-only 正式训练	4×H100 80 GB 或更高	先过单 batch backward
低风险首跑	4×H200/B200	更大激活余量

消费级单卡不能纯 GPU 运行完整 0731。110–192 GB 主机内存配合 3/4-bit CPU offload 可能极慢推理, 但 GGUF/llama.cpp 不能作为当前 projector 训练路径。MoonViT 单独可在普通本地机器运行; 完成后的完整组合能否“本地跑”, 取决于本地是否具备多卡或大内存 offload 条件。

9 分阶段门槛

9.1 Gate A: 无需大权重

- 1. 固定 tokenizer/image token 合同。
- 2. 固定 MoonViT revision、processor 和输出 shape。
- 3. 小型纯文本 LM 完成 overfit 与保存/恢复。
- 4. 真实 DeepSeek-V4 缩小配置完成 Hash-MoE backward。

9.2 Gate B: V100 工作站

- 1. 在不占用现有 Qwen 优化任务的情况下盘点 CUDA/PyTorch/磁盘。✓ 已完成，并经 tmux 向 fastllm 任务留言协调。
- 2. 大文件仅写入 /run/media/ezra/13D010B6FDBC1A06/。✓ 已确认 /home 89% 占用，机械盘约 3.7 TB 可用。
- 3. 跑 MoonViT standalone 与小 LM；记录 SM70 fallback。✓ 真实 MoonViT-SO-400M 前向/反向与评测管线干跑均通过。torch 2.10.0+cu128 wheel 自带 sm_70，V100 matmul 与 26/26 测试通过，不需要旧版 PyTorch。
- 4. 不尝试加载完整 0731。✓ 保持该约束。
- 5. 小规模 overfit 训练验证信号。✓ 通过（见下节）。

9.3 Gate B 实测：projector overfit 实验 (2026-08-02)

数据：109 条 ComfyUI 产出图的英文描述性 caption (data/comfy_captions.jsonl，零下载，93 训练 + 16 评测)。设置：冻结 MoonViT-SO-400M (fp32) 与 SmolLM2-135M-Instruct (fp32)，只训 40.1M 参数 PatchMerger projector；placeholder 用现有 token <|endoftext|> (id 0)，不扩 vocab；--max-image-side 448 (每图 192 token)；batch 4，AdamW。

第一次跑 (200 步，lr 1e-3，约 8.6 epoch)：训练 loss 4.25 → 3.74，但 shuffle_delta 仅 +0.007，在噪声内——模型主要学到 caption 文体先验。第二次跑 (1000 步，lr 2e-3，约 43 epoch) 信号确立：

指标	数值
训练 loss (首窗 → 末窗)	4.303 → 3.338
评测真图 loss	3.300
评测打乱图 loss (16 样本 × 5 轮)	3.642
shuffle_delta	+0.343
训练耗时 (V100)	951 秒 (1000 步)

生成对照 (8 条评测样本，greedy 48 token)：有图输出随图变化且出现内容词 (“Korean dress”、“3D model”、“beard, pastel houses”，token-F1 0.112)；同一模型的 blind 无图输出 8 条逐字节相同 (“beautiful, serene landscape...” ， token-F1 0.082)。三项证据一致：loss 下降、shuffle_delta 显著为正、生成随图变化且 blind 恒定——projector 确实把图像信息送进了冻结 LM，训练合同在真实权重上成立。checkpoint 在 checkpoints/overfit-smolllm135-1k。

注意：评测集 loss (3.30) 低于训练集末窗 (3.34)，且 43 epoch 已过拟合，shuffle_delta 部分来自对 93 张训练图的记忆；这一 gate 的目的是验证信号通路，不是产出可用 captioner。

第二个 backbone 复测 (同一数据与超参，placeholder 自动解析为 <|image_pad|>)：Qwen2.5-0.5B-Instruct 1000 步后训练 loss 3.898 → 3.160，评测真图 3.310 vs 打乱图 3.592，**shuffle_delta = +0.282**，耗时 1194 秒，checkpoint 在 checkpoints/overfit-qwen05-1k。两条 backbone 轨给出同量级正 delta，说明该信号来自胶水层与 projector 通路本身，与文本主干选型无关。

第三轨在更大更干净的数据上复测：flickr8k 训练分片 1100 条 (1036 训练 + 64 评测；jxie/flickr8k 镜像，nlphuji 原仓为 gated；因代理网络反复断流，最终直接从 HF 缓存的 train parquet 离线解出，MANIFEST 记录 resolved revision)。Qwen2.5-0.5B，1500 步、batch 8、lr 2e-3 (约 11.6 epoch，记

忆成分远小于 comfy 小集): 训练 loss 3.091 → 2.435, 评测真图 2.574 vs 打乱图 2.722 (64 样本 × 5 轮), **shuffle_delta = +0.148**, 耗时 2102 秒, checkpoint 在 checkpoints/overfit-qwen05-flickr8k。在 10 倍数据、1/4 epoch 数下 delta 仍显著为正——信号不依赖小集记忆。

该 checkpoint 的生成对照同样干净: 8 条评测样本有图输出为正常 flickr8k 风格 caption (“A boy in a red shirt and blue shorts is holding a toy”, token-F1 **0.284**); blind 无图输出全部退化为同一句拒绝话术 (“I’ m sorry, but you haven’ t provided an image...” , token-F1 **0.0**)。

三轨汇总 (判据均为真图 vs 打乱图 teacher-forced loss 差):

数据	文本主干	步数/epoch	delta	结论
comfy 109 条	SmolLM2-135M	1000 / 43	+0.343	通过
comfy 109 条	Qwen2.5-0.5B	1000 / 43	+0.282	通过
flickr8k 1100 条	Qwen2.5-0.5B	1500 / 11.6	+0.148	通过

Gate B 结论: 胶水层 + projector 训练合同在真实权重、两个文本主干、两个数据集上全部成立, 可以进入 Gate D (租卡验证 0731 大权重的 Dgrad 通路)。

工作站实测注意项:

- NVML 版本不匹配 (内核模块 580.159.04 vs 用户态库 580.173): nvidia-smi 不可用, 但 CUDA 初始化与 kernel 运行正常。不要为修复它而重载驱动或重启——同机其他任务正在使用 GPU。
- MoonViT remote code 与 Transformers 5.x 有两处不兼容: 缺 all_tied_weights_keys (已在 moonvit.py shim, ViT 无 tied weights, 空映射语义正确); bf16 下 remote code 内部存在 float32/bf16 混用的 layer_norm 调用, V100 上 MoonViT 以 fp32 运行 (约 1.6 GB, 可接受)。
- 小上下文文本模型装不下原生分辨率视觉 token: 640×480 照片产生 1064 个合并 token, 加 prompt 后超过 tiny-gpt2 的 1024 positions, 表现为 scatter-gather device assert (异步报错会漂移到无关位置, 需 CUDA_LAUNCH_BLOCKING=1 定位)。--max-image-side 控制 token 数; 正式 0731 的 128k 上下文无此问题。
- HF 下载须走本机代理 127.0.0.1:7890 (约 0.4–0.5 MB/s), 且该仓库默认 Xet 传输在代理下会挂起, 必须设 HF_HUB_DISABLE_XET=1。
- 复用现有 venv (torch 2.10.0+cu128 + transformers 5.12.1); pytest 用 pip --target 装在独立目录, 不改对方环境。
- 工作站负载高 (其他 agent 编译/跑 inference server) 时, 机械盘上的 torch import 可达 90 秒以上; 批处理脚本超时预算要放宽。

9.4 Gate B+: 租前全链路彩排 (2026-08-03, 正式训练的对照组)

目的不是能力验证, 而是把租期闭环的每一个环节在 V100 上先炸一遍: 离线取数 → 切分 → 训练 (checkpoint 流式传 HF) → trained/blind/random 三组评测 → 聚合 → 全部产物落 HF。设置: SmolLM2-135M-Instruct + 真实 K3 MoonViT-V2 权重 (eager), flickr8k 1200 条 (train parquet 本地直读, 零下载; 该数据集每行一图、只用 caption_0, 行切分即图切分, 无泄露), 1000 训练 / 200 评测, 400 步、batch 4、lr 5e-4 (Baseten 配方默认值), placeholder 为现有 token <|endoftext|>, --max-image-side 448。

组别	vision token-F1	blind token-F1	gap
训练后 projector (400 步)	0.1565	0.0391	+0.117
随机 projector (管线对照)	0.0584	0.0391	+0.019

训练 loss 4.30 → 3.06 (前 200 步)。三点结论: (1) 训练组 gap 是对照组的 6 倍, 管线对 “是否训练过” 可判别——评测不是摆设; (2) checkpoint 流式上传经代理真实落地 (HF 上 step-000200/000400 含 projector fp32+bf16、training_state、history.json), 租期中断不丢训练; (3) 全部评测原始输出 (逐

条预测 + 元数据) 与 SUMMARY 已公开在 eval/v100-smoke-smollm135/。注意: 400 步远低于 grokking 区间 (约 900 步起), 135M 主干 + caption 任务的绝对 F1 不代表正式结果; 此表是正式训练的**对照组基线**。

本轮同时打通了下载通道的完整答案 (此前三种路径全部失败): hf_transfer 在代理下 0 字节挂起、hf-mirror 限流、工作站的 datasets+dill 无法 pickle pyarrow 的 MonthDayNano (任何本地 parquet 都炸 load_dataset)。最终方案: aria2 -x8 -c --max-tries=0 预取 parquet 分片 (xet-bridge CDN 随机 TLS 重置/403, 无限重试磨过去) + fetch 全程离线读本地 parquet (raw pyarrow, 跳过 datasets 指纹层), 新增 tools/prefetch_parquet.py 与 tools/fetch_art_data.py (0xSero art 数据集的离线复刻, schema 与 build_train_mix 兼容, 有测试)。另修正一处数据规格错误: MMMU-Pro 仓库不存在裸 standard config, 已固定为 standard (10 options)。

同日下午的带宽攻防补充了一课: (1) ModelScope 存在与 HF 逐字节一致的镜像 (lmms-lab/textvqa、lmms-lab/DocVQA、AI-ModelScope/MMMU_Pro、showlab/ShowUI-desktop), 境内直连可达 8.8 MB/s, 但工作站 IP 在约 1.5 小时高强度拉取后被 CDN 边缘渐进限速至 0 B/s (按 IP 不按账号, token 与 IPv6 均无效; 本机家庭 IP 同文件仍有 5.3 MB/s); (2) 随即搭建的“本机 ModelScope → scp 回传工作站”中继受 Tailscale 链路限制 (3.7 s RTT, 多流聚合仅约 250–400 KB/s), 与代理通道同速且挤占家庭带宽, 应用户要求退役; (3) 最终全部十个数据源统一由工作站经 Clash 代理直下 (moondata 八个评测/训练集 + moonart 的 WikiArt/fashion), 代理总带宽封顶约 250 KB/s (并行不扩展, 单连接约 50 KB/s 即节点拥塞), 剩余约 15 GB 预计 16 小时; mihomo 核心未开 external-controller, 换节点只能由用户在 GUI 操作, 这是当前唯一可能提速一个数量级的杠杆。也曾评估 \$0.056/h 的香港数据盒 (2–3 小时收工、总成本 < \$0.5) 作为替代, 用户选择免费慢磨方案。

9.5 Gate B 全量 mix early-alignment (2026-08-04, V100, 工程/信号闸门)

目的: 在正式 train_v1 mix (59,198 行 packed parquet) 上验证“parquet 消费路径 + 全量数据 + early alignment + 全套评测 + 上传”的租期闭环, 同时作为正式 0731 训练的本地对照组。设置: Qwen2.5-0.5B-Instruct(冻结) + K3 MoonViT-V2(冻结, eager), 只训 projector(33.6M 参数), 2000 个 optimizer step、恒定 lr 5e-4、--max-image-side 448。历史参数 batch 8 实际不是一次 8 样本 forward, 而是 micro_batch_size=1 下串行 8 次 forward/backward 后更新, 因此本轮只见过 16,000 样本, 即 59,198 条 mix 的约 **0.27 epoch**; 历史 answer-token 数未记录, 不能精确补齐。占位 token 自动解析为 Qwen 词表已有的 <|image_pad|> (ID 151643, 不扩词表)。

训练结果 (train.log 实测):

指标	数值
loss (首窗口 → 末窗口)	6.413 → 3.006 (单步 10.19 → 3.01, 最低 2.718 @ step 1750)
held-out 真实 loss (32 条)	3.175
held-out 打乱图像 loss	3.902
shuffle_delta	+0.727

历史口径下 shuffle_delta +0.727 是此前三条 smoke 轨 (+0.343 / +0.282 / +0.148) 的两倍以上: 正确图片已经影响答案 loss, 视觉接口可学习性成立。但留出集只是 shuffle 后末尾 32 条, 乱配使用循环平移而非多组随机 derangement; 加上训练量仅 0.27 epoch, 该数字不能证明充分收敛, 五项低分也不能写成架构能力上限。本轮同时炸出两个租前必须暴露的问题, 均已定位:

- 1. **checkpoint 流式上传全部失败** (step 500/1000/1500/2000 共 4 次): 训练期间代理 SSL 持续重置 (UNEXPECTED_EOF_WHILE_READING 于 S3 multipart PUT), 重试 5 次仍败。训练本身无损, 4 个 checkpoint 本地完好; 按“上传下载串行”纪律, 等评测结束带宽空出后手动一次性补传。教训: 租机上 checkpoint 上传同样要与数据集预取错开。

2. **10 个评测进程全部启动即崩**：训练器默认占位 token 是 Qwen 的 `<|image_pad|>`，而评测器默认是 DeepSeek 的 `<|image|>`——两者默认值不一致，Qwen tokenizer 里没有后者，`resolve_placeholder_token_id` 按设计拒绝扩词表而报错。修复为候选自动探测（DeepSeek token 优先、Qwen token 兜底；显式指定仍严格报错），85/85 测试通过（commit 034be8b）。此 bug 若不在本地炸出，租机首跑 DeepSeek 时训练器会以旧默认 `<|image_pad|>` 直接崩在 0731 tokenizer 上——本地彩排的价值正在于此。

9.5.1 五基准评测终表(selection 半侧, 1024px, 逐条原始输出已公开于 HF eval/v100-fullmix-qwen05/)

基准	指标	trained	random	blind	读法
TextVQA (250)	soft-VQA	0.081	0.000	0.000	真实对齐, 距成熟 VLM 远
DocVQA (100)	ANLS	0.039	0.000	0.000	同上, 实体级读错居多
OCRBench (100)	exact	0.000	0.000	0.000	地板; 小字 OCR 超出 0.5B 能力
ScreenSpot (100), 域内	解析率 / 精度 @50	0.51 / 0.01	0 / 0	0 / 0	格式学会一半, 点位退化 (常数坐标, 中位误差 729/999)
MMMU-Pro (150)	exact	0.073	0.000	0.000	修 复 输 入 后 2.0%→7.3%; 宽松提取 18%

判别力三条全部成立：vision 严格大于 blind；trained 严格大于 random（随机 projector 臂五项全零——冻结 LLM 收到噪声视觉 embedding 时输出不了任何切题内容）；`shuffle_delta` +0.727。Gate B 的最小结论是：**信号真实、接口可学习、评测可判别、checkpoint/上传管线可用（但易受代理抖动影响，需错峰）**。它不是充分训练后的能力评测。0.5B 冻结主干 + 33.6M projector + 仅 1.6 万样本见过的训练量只承担 early-alignment 对照角色；下一步先用等 examples-seen 的 0.5B/1.5B/3B 纯文本主干、projector/LoRA、分辨率与因果控制消融定位瓶颈，再估算 0731 Hash-MoE 实验。

9.5.2 0.5B 主干的容量混杂

Qwen2.5-0.5B-Instruct 是纯文本 Qwen2ForCausalLM，没有继承原生视觉能力，但它的容量本身显著影响实验。OCR、复杂视觉推理、指令/输出格式遵从均受 0.5B 语言主干的能力上限约束，所以 Gate B 的低绝对分数更接近能力下界，不能外推完整 0731 的最终分数。反过来，小型 dense Qwen 与 DeepSeek-V4 Hash-MoE 的表示空间和优化曲面不同；它可能更易对齐，也可能因容量不足更难对齐，因此 +0.727 的收敛速度同样不能预测 0731 的训练速度。

不受这一混杂影响的最小结论只有：在一个确实纯文本的冻结 LM 上，训练后的 MoonViT-V2 projector 相对 random/blind 产生了可重复的图像依赖信号。故 Gate B 的正式定位降格为“工程与信号闸门”，不是能力代理。若在租机前追加中间尺度对照，应优先使用配置明确为 ForCausalLM 且无 `vision_config` 的约 3B 纯文本主干（7B 可选），保持相同 train mix、seen-record 数、分辨率、scratch 初始化和 selection benchmark；比较 loss、shuffle 统计及五项 vision-blind。该实验能量化容量敏感性，但仍不能替代完整 DeepSeek Gate D。当前工作站未缓存 3B/7B 纯文本权重，尚未运行此对照。

9.5.3 证据边界：原生 VLM 不是 DeepSeek 代理

必须区分两个名字相近但因果意义完全不同的 Qwen 实验。Gate B 的冻结文本主干配置是 Qwen2ForCausalLM，且 `vision_config` 为空；它本身没有图像输入路径，视觉信号只能来自外接 K3 MoonViT-V2 与本项目训练的 projector。因此 `shuffle_delta` 和 trained/random/blind 差异可以证明“纯文本 LM 接口可学习”。训练器现已加入硬防线：`--text-model` 若暴露 `vision_config` 会直接拒绝，原生 VLM 只能进入独立的 stock-eval 路径。

另一方面, Qwen3.5-4B 对照的配置是 Qwen3_5ForConditionalGeneration 且自带 vision_config; 它使用官方视觉塔、processor、chat template 和既有多模态对齐, 完全不经过 MoonViT-V2 或本项目 projector。它的高分只校验评测数据、图像读取、输出约束和评分器, 并给出成熟小型 VLM 的参照上界; **不得据此推断 projector 能快速映射到 DeepSeek**。证据链严格分为: (1) 原生 VLM 阳性对照 = 评测有效; (2) 纯文本小主干 Gate B = 接口可学; (3) tiny DeepSeek-V4 Hash-MoE = 路由与梯度合同; (4) 完整 0731 Gate D/正式训练 = 目标可行性与能力, 前三项均不能替代第四项。

原生 Qwen3.5-4B 的修复后阳性对照如下。它与 Gate B 使用相同的 selection 半侧、1024px 上限和 strict scorer; “vision” 列是 Qwen 自带视觉塔的结果, 不是本项目 projector 的结果。

基准	指标	Gate trained	B	Gate blind	B	原生 Qwen vision	Qwen blind
TextVQA (250)	soft-VQA	0.081		0.000		0.820	0.031
DocVQA (100)	ANLS	0.039		0.000		0.926	0.071
OCRBench (100)	exact	0.000		0.000		0.900	0.000
ScreenSpot (100)	parse / acc@50	0.51 / 0.01		0 / 0		0.86 / 0.76	0.99 / 0.01
MMMU-Pro (150)	exact	0.073		0.000		0.300	0.280

前三个感知/OCR 基准与 ScreenSpot 的 vision-blind 差距很大, 证明图像读取与评分管线已恢复健康; MMMU-Pro 只有 +0.020, 30% 中绝大部分来自题干、选项与语言知识先验, 不能全部计作视觉能力。这正是强制报告 blind 的价值, 也再次说明原生 VLM 总分不能成为 DeepSeek 映射证据。

该对照还产生了一次必须保留的完整性事故记录: 首次运行中, 第二个 3.99 GB safetensors 分片虽字节数正确, SHA-256 却为 547d2f...8627 (官方 cb544b...e188), 而模型索引恰把全部视觉塔权重放在该分片, 导致模型把真实图片一致描述成空白。高分辨率样本又触发 OOM, 并被工作站的 NVML 驱动/库版本不一致掩盖成 allocator assert; 开放式长回答则会被严格短答案指标计零。修复措施为: 逐分片 SHA-256 manifest、--max-image-side 1024、按指标约束短答案/选项字母/归一化坐标。损坏运行的产物从未上传; 修复套件在一次完整哈希验证后运行, 原始逐条输出与 suite provenance 单独发布。

9.5.4 误判审计 (应用户要求: 先怀疑判别器, 再怀疑模型)

对五个基准逐条重打分, 用逐级放宽的提取器量化 “判错” 成分。结论: **判别器基本清白, 最宽提取也最多 1-2 分**——textvqa 单复数漏判 0 条、子串漏判 4 条 (+1.6% 封顶); screenspot 不可解析的 49% 中 48 条是纯散文无坐标 (模型在描述而非点击), 仅 1 条格式边缘漏判; ocrbench 用官方 contains 式口径依然全零; docvqa 无 32-token 截断。但审计抓到两个真 **输入侧** bug:(1) MMMU-Pro 的 options 列在 parquet 里是 **字符串装的 Python 列表字面量**, 旧代码直接 join 字符串导致选项被逐字符拆行, prompt 不可读; (2) 渲染选项缺字母标签, 而参考答案是字母 (“B”), 模型无从对应。修复 (解析字面量 + A./B./C. 标签, commit bf3413b/f9b94a5, 含测试) 后离线重建 300 条数据并重测: 2.0% → 7.3% (严格), 宽松 “字母出现即算” 18%——0.5B 输出多为推理散文、没有落字母的习惯, 严格 exact-match 只承认单字母输出。此基准的 2.0% 旧读数作废, 以修复版为准。

评测补跑 (5 基准 × trained/random × vision/blind) 已全部完成并聚合; 仓库归置 (Qwen 对照产物归入 gate_b_qwen05_v100/、smoke 产物归入 gate_b_smoke_smollm135_v100/、README 标注与 DeepSeek 目标无关) 与 4 个 checkpoint 补传按串行纪律排在 4B 下载之后。

10 冻结语言主干中的视觉感知涌现: V100 方向筛选实验

本章对应新的租前方向筛选阶段; 约束是只使用现有 V100 32 GB, 不查看 final evaluation half、不租服务器、不启动完整 DeepSeek-V4。研究问题是: (1) frozen text LM 何时开始在可测指标上依赖正确图片;

(2) MoonViT 可线性解码的信息经过 projector 后保留/丢失什么; (3) 视觉属性在哪些 LM 层与 token 位置可解码并影响答案; (4) 下一轮应优先归因于训练量、projector、空间/OCR、语言容量还是冻结主干。可证伪假设预注册如下: 若 MoonViT probe 高而 projector 输出骤降, 则支持 projector 信息瓶颈; 若 projector/LM residual probe 高而生成与干预恢复低, 则支持语言适应/解码瓶颈; 若所有 checkpoint 曲线仍持续上升, 则先支持训练量不足; 若 0.5B 在等 examples-seen 下被 1.5B 清晰超过, 才提高语言容量瓶颈证据; 这些 probe/相似度只作相关性读数, 因果结论必须来自 blank/wrong-image、mask、feature/activation patching 的答案 logit 变化。

10.1 实验基础设施与真实计量 (包 1, 2026-08-04)

环境快照 run v100-perception-infra-20260804-a: 起始 commit 20c2556; Tesla V100-PCIE-32GB (34,072,559,616 B, sm_70); Python 3.12.11; torch 2.10.0+cu128; CUDA build 12.8; cuDNN 91002; Transformers 5.12.1; safetensors 0.8.0。nvidia-smi 仍因已知 NVML 用户态/内核不匹配失败, 但 PyTorch CUDA 分配与计算正常。环境 JSON、pip freeze、GPU device users 和 git dirty state 均提交于 experiments/v100_perception_20260804/infra/environment/。

冻结 MoonViT-V2 特征缓存采用分片 safetensors + MANIFEST: 逐样本记录 ID、原图 SHA-256、原图尺寸、feature shape/dtype、shard offset; 全局记录 MoonViT config/weights hash、分辨率、数据 logical-row hash、cache format version; 每个 shard 自带 bytes 与 SHA-256。有效 run v100-perception-cache-20260804-retry1 在 448px 缓存 64/64、0 失败、14.274s、峰值 1,948,235,264 B; 4 个 shard 全部二次 hash 和逐 ID 读回通过, records hash 98f81a46...55d2a, MoonViT 权重 hash 01436a95...ced24。第一次 foreground SSH 尝试因 stdout 断开触发 BrokenPipe, 只有 3 条临时行且无 manifest, 明确标记 invalid 并保留, 不参与任何结论。

真实 step-time 使用同一 64 条、同一 scratch projector、相同 448px cache, 5 step 中排除首个 CUDA warm-up, 结果如下。三组的 micro_batch_size 都是 1, actual_batched_forward=false; 所谓 batch 4/8 是串行 gradient accumulation。

micro batch	grad accum	mean s/optimizer step	examples/s	peak GPU memory
1	1	0.0747	13.38	3.31 GB
1	4	0.2720	14.70	3.65 GB
1	8	0.5390	14.84	3.65 GB

因此旧 batch 8 的真实成本约为 0.54s/optimizer step (在 0.5B + 已缓存视觉特征上), 不是一次 8 样本 forward。线性外推到 accumulation 64 约为 4.3s/step, 但该数字仍不能外推 DeepSeek; 它只用于证明计量语义与 V100 小模型预算。retry2 的单步计时有效, 但审查发现它仍在启动时实例化了不参与 forward 的 401M MoonViT, 故其 4.92–5.25 GB peak 不作为缓存结论; 修复后 retry3 完全不构造视觉塔, peak 降到 3.31–3.65 GB, 且三份 report 均记录 vision_tower_instantiated=false。两次 step-0 无效启动也完整保留: 第一次在线 HEAD 超时; 第二次启用 offline 后未设置 HDD cache 路径, 三臂均失败并暴露零成功行 CSV 的 driver bug。checkpoint 轨迹、probe、干预和方向判定尚未运行, 当前不满足租卡前 go 条件。

10.2 Synthetic Perception Diagnostic (包 2, 2026-08-04)

生成器 synthetic-perception-v1 固定 seed 20260804, 以 Pillow 12.2.0 在 256×256 画布上生成 color、shape、count (1–9)、spatial (left/right、above/below、inside/outside、nearest)、OCR (2–6 位无歧义大写字母/数字) 和 3×3 coordinate 六类任务。每个任务在 train 与 selection 各有 200 个基础问题; 每个基础问题有 a/b 两张图, 问题文本逐字节相同、答案不同, 生成参数明确记录唯一变化的视觉属性。因此总计 2,400 个基础 minimal pairs、4,800 张图。train/selection 使用不同背景、边框和问题模板; 图像 SHA、OCR 字符串、pair ID、template ID 的跨 split 交集均为 0。OCR 字符本身是必须读取的刺激, 不另绘任何答案标签或提示文本。

任务	train base/ren- dered	selection base/ rendered	pair 中唯一目标变化
颜色	200 / 400	200 / 400	单一图形的填充色
形状	200 / 400	200 / 400	图形几何形状
计数	200 / 400	200 / 400	可见物体数 1–9
空间	200 / 400	200 / 400	目标物位置/关系
OCR	200 / 400	200 / 400	2–6 位 glyph sequence
坐标	200 / 400	200 / 400	3×3 网格中的目标位置

每条记录另有完整控制分配：blind 不提供图；blank 使用同 split 的纯背景；same-image 对该 split 所有样本使用同一张中性条纹图；shuffled-image 在任务内作无固定点的确定性 derangement；patch-permutation 给出逐样本 seed，在 MoonViT merged spatial-token 轴执行 `torch.randperm`，保留值与 token 数量。独立 verifier 检查了 4,800/4,800 图像 SHA、2,400/2,400 pair、4,800/4,800 控制行和全部派生文件 hash；失败数为 0，logical dataset SHA 为 122ae820...cbaa71。完整 PNG 在 V100 数据盘，Git 提交完整 train/selection/control JSONL、manifest/hash、计数 CSV、日志、零失败文件、验证结果与每类一组 a/b 预览。数据生成阶段没有据输出改 scorer；普通/paired/answer-flip 与控制分母由包 3 统一计算，见下一节。

10.3 Checkpoint-wise Emergence of Visual Dependence (包 3, 2026-08-05)

10.3.1 固定口径、checkpoint 与有效性

包 3 从 commit 1cc6f631... 的四个历史 projector checkpoint 读取 step 500/1000/1500/2000；examples seen 分别为 4,000/8,000/12,000/16,000，对应 0.0676/0.1352/0.2028/0.2704 effective epoch。current-final 与 step 2000 是同一权重，只作为别名，不重复推理。训练起点张量未被历史 run 保存，step 0 使用同构 projector 与 seed 0 重建，明确标为 matched random initialization control。所有 checkpoint 的配置、safetensors SHA、来源路径与别名关系由独立 manifest 交叉校验。

Teacher-forced 评测覆盖完整 authoritative synthetic selection: 2,400 图、1,200 对、六任务、五个独立 checkpoint、八种条件，共 96,000 条 answer log-prob 原始记录。自由生成在运行前以 seed 20260804 对 pair ID 做逐任务 SHA-256 排名，固定为每类 50 对/100 图，共 300 对/600 图；manifest 保存全部 ID、源 selection SHA 51ce2741...d6 和 logical SHA 122ae820...a71。这一子集只缩减自由生成计算；teacher-forced 分母保持完整。背景辅助集复用每个 authoritative 场景和答案，只把 selection 背景替换为 train 背景；2,400/2,400 特征缓存完成，明确 diagnostic_only=true、training=false。

有效性审计保留了三类无效产物。preference_v1 的数值本身与修复后 v2 在 96,000 条上逐位一致，但 36,000 条 control visual_source_id 写错，故整 run 标 invalid 后从头重跑；v2 独立 verifier 通过。generation v3 在 batch 2 的 1024px benchmark 筛选中仅约 0.8 sample/s，未完成 step 0；v4 在不足 1% 时确认 batch 16 仍只有约 8.3 synthetic sample/s，均保存 partial raw、逐文件 hash 与 invalidation。最终批量筛选中，synthetic/benchmark batch 64/16 为 221.3s、峰值 9.82 GB；128/32 为 215.4s、峰值 18.57 GB，仅快 2.6%，最终采用 64/16。筛选器另发现 limit > heldout count 的分母边界 bug；该 attempt 在生成前退出，修复加入测试后重跑。

10.3.2 Teacher-forced paired preference: shape 在 step 1500 短暂出现

最强证据集中在 shape。step 1500 的 authoritative vision strict paired-preference 为 **0.130**，mean correct margin 为 **+0.133**；matched-random 分别为 0.055/−0.021。成对 bootstrap 的 trained-random strict gap 为 **+0.075, 95% CI [0.025, 0.135]**。同一 checkpoint 的 shuffled image strict preference 只有 0.015，vision-shuffle 为 **+0.115 [0.070, 0.160]**；paired-counterfactual image 把 mean margin 精确翻成 −0.133，vision-counterfactual margin 为 **+0.266 [0.219, 0.313]**。blind、

blank、same-image 均为 strict 0；patch permutation 为 0.005。该组结果同时满足训练对照、样本级错图控制与单属性反事实三条因果约束。

任务 / strict paired preference	step 0	step 500	step 1000	step 1500	step 2000
color	0.015	0.015	0	0	0
shape	0.055	0	0	0.130	0
count	0	0	0	0	0
spatial	0	0	0	0	0
OCR	0.030	0	0	0	0
coordinate	0.070	0	0.035	0	0

表中的随机 projector 非零值说明单看“峰值”会误判；只有 shape/step 1500 同时显著超过 matched random，并在 shuffled 与 paired-image 因果控制下保留。color、count、spatial、OCR、coordinate 在 16,000 examples 内均没有 causally validated onset，现阶段的能力顺序只能写为“shape 首先出现，其余未出现”，不能给其余五类强排顺序。

该 shape 信号随后坍塌：step 2000 strict preference 回到 0，step1500–step2000 为 **+0.130 [0.085, 0.180]**；latest overall 虽保留很小的 vision mean margin +0.0081，strict preference 已为 0，vision–paired-image margin 仍有 +0.0162 [0.0121, 0.0203]。曲线因此反驳当前训练区间内的单调“多训即可”解释，支持表征/解码稳定性问题进入优先诊断。

背景匹配没有把结论翻转。shape/step 1500 的 auxiliary strict preference 为 0.105，authoritative–auxiliary 为 +0.025 [0.005, 0.050]；auxiliary mean margin 反而更高 (0.171 vs 0.133)。shape 信号在两种背景都存在，且 train 背景没有稳定提高两个 paired 指标，当前没有证据把主要失败归因于背景域偏移。

10.3.3 自由生成：视觉触发存在，正确图像内容没有进入成对答案

自由生成主跑包含 37,300 条 generation 原始记录和 160 条 heldout shuffle-loss 记录，失败数为 0；总时长 2,745.9s，峰值显存 9.82 GB。独立 verifier 重算六个原始文件的 hash、精确分母、alias、固定子集 manifest 与每个控制的 visual_source_id 关系，确认五个独立 checkpoint、final_half_scored=false。step 500/1000/1500/2000 的 synthetic vision sample accuracy 分别为 0.1367/0.1550/0.1350/0.1417；严格 paired generation 与 answer-flip 在所有 checkpoint、所有任务都精确为 0。

step 2000 的 vision–blind sample-accuracy gap 为 **+0.1417 [0.1167, 0.1683]**，vision–blank 为 +0.0383 [0.0150, 0.0617]；vision–same-image 为 −0.0033 [−0.0183, 0.0100]，vision–shuffled-image 同为 −0.0033 [−0.0150, 0.0083]。视觉 token 能触发一个盲态没有的答案分布，但正确图、固定中性图与错配图之间没有可检出的内容优势。step 1500 的 shape 单样本准确率为 0.26，paired generation 仍为 0；同一数据上的 teacher-forced strict paired preference 为 0.13。这组差异直接支持“已形成可评分的内部证据、现有解码没有稳定使用它”。




Figure 1: 左: teacher-forced strict paired preference; 右: 逐任务内部 paired 证据与 paired 自由生成。shape/step 1500 是唯一经过因果控制的非零训练信号，自由生成轴仍为 0。

10.3.4 真实 heldout 与 benchmark 轨迹

32 条历史 heldout、每条十次 derangement 的 mean shuffled-minus-true loss 从 matched random 的 -0.0095 变为 step 500/1000/1500/2000 的 $+1.0263/+0.6703/+0.9533/+1.1886$; step 2000 repeat std 为 0.2477。projector 很早就学会让真实图像降低训练分布上的 teacher-forced loss，此后各 checkpoint 始终为正且 step 2000 最强。它测到全局图文匹配依赖，无法单独证明细粒度答案内容已进入生成。

step 2000 的 selection-half benchmark vision/blind 为: DocVQA ANLS 0.026/0, TextVQA 0.008/0, OCRBench 0/0, ScreenSpot accuracy 0.010/0 (parse 0.19/0), MMMU-Pro exact 0.0067/0。blank 与 shuffled 控制也能保留部分低分，例如 TextVQA blank 0.0093、MMMU-Pro blank/shuffled 均为 0.0067；绝对 benchmark 分数因此继续只作 0.5B、0.27 epoch 条件下的诊断。ScreenSpot 的最常见坐标和 collapse rate 已逐 checkpoint 保存，未见可用 grounding 能力。




Figure 2: 左: heldout 真图与错配图 loss 轨迹; 右: synthetic 控制条件相对 vision 的 correct-margin gap。

10.3.5 假设更新与下一项本地实验

假设	包 3 更新	证据与动作
内部表征存在、解码使用失败	强支持	shape/step 1500: teacher paired 0.13, generation paired 0; 先做 layerwise probe 与 upper-layer activation patching。
现有训练量只需直接延长	削弱	shape 在 step 1500 出现、step 2000 归零，反对当前区间的单调外推；延长训练需等定位结果并加入稳定化监控。
信息在 projector/冻结主干间丢失	待定位	shape 首先出现，OCR/coordinate 无因果 onset; 需直接测 projector token 与逐层 hidden state 的属性可分性、位置池化与 patch 消融。

背景域偏移是主因	弱支持	shape 在 authoritative 与 background-matched auxiliary 都存在，辅助背景没有一致改善。
0.5B 语言容量是主瓶颈	尚未判定	当前结果与容量瓶颈相容，也与冻结上层不会使用视觉证据相容；机制定位后再决定 Qwen2.5-1.5B 对照或顶部 LoRA。

下一包固定比较 step 1500 与 step 2000：在 projector 输出和 Qwen2.5-0.5B 全 24 层训练逐层 linear probe；用正确图激活 patch paired-counterfactual run 的图像 span，并对 upper layers 做最小筛选；加入 random-label、blind、shuffled-image 和 layer-0 控制。判别目标是定位 shape 信息何时可线性恢复、何处在 step 2000 丢失，以及少量因果替换能否恢复 correct margin。结果再决定 projector 辅助目标、顶部 LoRA、延长训练或 1.5B 容量对照的优先级。

10.4 Shape 的逐层机制定位（包 4，2026-08-05）

10.4.1 冻结口径与校准 null

包 4 使用 package-3 唯一通过因果控制的 shape 任务。synthetic train 与 selection 各固定 200 个完整 a/b pair、400 条记录，两者 ID 与 pair overlap 均为 0；activation patching 在运行前以 seed 20260808 对 pair ID 做 SHA-256 排名，固定 50 pair/100 个方向。checkpoint 为 matched random、step 1500 与 step 2000。表示抽取覆盖 train vision，以及 selection 的 vision、paired-counterfactual、shuffled-image、patch-permutation；每个 cell 保存 tower/projector 三种池化、25 个 hidden-state index 的 assistant 与 image-span mean、类别 logit 和 target/source label，共 59 个 tensor key。

完整表示 run 耗时 122.3s、峰值显存 3.61 GB；30 个 safetensors/metadata 文件约 899 MB，保留在 V100 数据盘并逐文件绑定 bytes/SHA。probe 只在完全隔离的 train split 拟合 class-balanced dual ridge，固定 $\alpha=1$ ，在 selection 上报告 raw/balanced accuracy。早期 v1 分析曾把单个 random-training-label probe 当显著性 null；该诊断方差过高，某 cell 达到 0.49。v1 已标 invalid，v2 对每个 vision cell 使用 2,000 次完整 pair 标签元组置换，最小可报告 p 值为 $1/2001=0.00050$ 。random-label probe 只保留作过拟合诊断。

10.4.2 projector 没丢 shape；训练后的上层把它压回 chance

tower 与 projector 在三个 checkpoint 都至少有一种预注册池化达到 **1.000 balanced accuracy**。matched-random projector 同样达到 1.000，说明高维随机映射本身能保存线性可读的 shape；这个数字不能解释成训练收益。训练 checkpoint 的差异出现在语言主干内部：step 1500 的 assistant probe 在 layer 12 达到 raw **0.790**、balanced **0.816**，pair-permutation $p=0.00050$ 、null 95% upper=0.285；step 2000 的峰值后移到 layer 14 并降为 raw **0.605**、balanced **0.632**， $p=0.00050$ 、null upper=0.278。

这两个 probe 追随实际图像来源。step1500/layer12 在 paired-counterfactual 条件下 target accuracy 降到 0.075，source accuracy 保持 0.790；shuffled-image 为 target 0.230、source 0.790。step2000/layer14 对应为 0.1125/0.605 与 0.2025/0.605。patch permutation 则把 step1500/step2000 的 target/source 同时降至 0.4475/0.445，说明空间 token 排列也参与了读出。

到 final hidden state，step 1500 与 2000 的 balanced accuracy 都精确回到 **0.250**，pair-permutation $p=1$ ；native LM-head 对 vision、paired-counterfactual 与 shuffled-image 也全部为 balanced 0.250。随机主干 final probe 仍有 balanced 0.429，进一步表明训练后的收缩是 checkpoint 特定的上层变换。证据链因此把 shape 瓶颈定位在冻结语言主干的上部使用/保留路径，projector 信息丢失解释在这个任务上被反驳。




Figure 3: 左: assistant 位置的逐层 shape balanced accuracy; 右: 冻结 tower/projector 的池化读出。训练 checkpoint 的中层峰值在顶部消失, 而 projector 始终保留完整可读信息。

10.4.3 activation patching: 中层存在内容特异因果通路

activation patching 对每个 checkpoint 扫描全部 24 个 decoder layer。目标 run 使用 paired-counterfactual 图, donor 来自同一样本的正确图; 分别替换 image span 和最后一个 assistant token。layer 0/5/11/17/23 加入不同 pair、不同标签 donor 与 zero donor。每种干预覆盖 50 个 pair 的两个方向, 以 pair 为 bootstrap 单位。最终 run 共 18,300 条原始记录、183 个 cell, 耗时 306.1s、峰值显存 3.50 GB。

实现审计发现第一版把 post-final-RMSNorm 的 hidden_states[-1] 注入 pre-final-RMSNorm 的 layer-23 hook; 旧 smoke 与 18,300 行完整 v1 均保留并标 invalid。v2 从 decoder layer forward hook 捕获精确 pre-final-norm 输出, 从头重跑。最终 assistant patch 对每条样本以 $1e-6$ 精度复现 clean margin; clean/counter pair margin 反对称误差为 0。

step 1500 的 correct-image-span replacement 在 layer 11 达到 **+0.3538 [0.2506, 0.4569]**; 减去 wrong-label donor 的通用替换效应后仍有 **+0.2194 [0.1463, 0.2994]**。step 2000 的 raw 峰值缩为 layer 6 的 **+0.1531 [0.1125, 0.1931]**, 预注册 layer 5 的 correct-minus-wrong 为 **+0.0856 [0.0519, 0.1181]**; step1500-step2000 在 layer 11 为 **+0.2219 [0.1338, 0.3094]**。这与 probe 的“后期更弱”一致, 同时表明 step 2000 仍残留较早、较小的内容因果路径。

final-layer image-span effect 为 0, 因为该层之后没有注意力运算把被替换的图像位置传给 assistant。final assistant patch 是正控制: step 1500 恢复 **+0.2925 [0.1875, 0.3950]**, step 2000 恢复 **+0.0950 [0.0712, 0.1200]**, 数值等于各 checkpoint 的 clean-counter mean margin。




Figure 4: 左: 正确图 image-span 的逐层 margin 恢复; 右: 正确 donor 减 wrong-label donor 的内容特异效应。step 1500 的 layer-11 路径最强, step 2000 明显减弱并前移。

10.4.4 token-position 干预边界与假设更新

在 projector 输入 token 位置上, step 1500 的 center replacement 为 $-0.0044 [-0.0119, 0.0025]$, outer 为 $+0.2969 [0.1963, 0.4088]$, full 为 $+0.2925 [0.1913, 0.4013]$; outer-center 为 **+0.3013 [0.1988, 0.4188]**, full-outer 为 $-0.0044 [-0.0119, 0.0025]$ 。step 2000 的 center/outer/full 分别为 $+0.0094/+0.0856/+0.0950$ 。MoonViT 的 projector token 已经过全局 contextualization, 这组结果只定位 receiver 中的 token position, 不能映射成原图背景/前景像素位置。后续若要回答 region 因果问题, 必须在视觉塔输入或早期 patch 网格上做遮蔽/替换。

假设	包 4 更新	证据与动作
projector 丢失 shape	反驳	三个 checkpoint 的 tower/projector 最佳 balanced accuracy 均为 1.000; 不再优先靠扩大 projector 容量解决 shape。
冻结主干上层不会稳定使用视觉证据	强支持	中层 probe 与 patching 均为正, 训练 checkpoint 的 final probe/native head 回到 chance; 下一项直接做顶部 LoRA 诊断。
继续 projector-only 训练会单调改善	进一步削弱	step 2000 的 mid-layer probe 与内容特异 patch effect 都弱于 step 1500; 延长训练必须带 checkpoint paired 监控与 matched continuation 对照。
0.5B 容量是首要瓶颈	仍未判定	top-LoRA 若恢复读出, 先确认适配瓶颈; 若失败, 再以相同 examples seen 跑 Qwen2.5-1.5B 容量对照。
背景像素驱动 shape 信号	未由本实验检验	outer projector-token 位置足够, 但这些 token 已全局 contextualized; 需要视觉输入/早期网格干预。

下一包冻结 step-1500 projector, 以小规模顶部 LoRA 只适配 Qwen2.5-0.5B 上层, 并运行 projector-only continuation 与 frozen baseline。训练 checkpoint 同时计算 teacher-forced strict paired preference、paired margin、自由生成 paired/answer-flip, 以及逐层 probe 是否能把中层信号传到 final。若 LoRA 有效, 继续做层数/rank/辅助目标最小消融; 若无效, 再转 Qwen2.5-1.5B 容量对照与视觉输入 region 干预。付费 Gate D 继续暂缓。

10.5 Shape 适配诊断 (包 5, 2026-08-05)

10.5.1 等训练顺序的顶部 LoRA 与 projector 续训

两个 arm 都从 step 1500 projector 出发, 使用同一 400 条 shape train、同一 shuffle 顺序、true batch 8, 并在 0/50/100/200 optimizer step 保存完整 checkpoint。LoRA 在 Qwen layer 12–23 的 q_proj/v_proj/o_proj 注入 rank 8、alpha 16, 共 442,368 个可训练参数; projector arm 继续训练全部 20,454,272 个参数。两份 training_order.jsonl 的 SHA-256 均为 993f1b2e...6988。LoRA 与 projector 的 200 步训练分别耗时 64.2s/74.6s, 峰值显存 3.74/4.41 GB。

状态	已见样本	strict paired preference	自由生成 paired
frozen step 1500	0	0.130	0.000
LoRA step 50	400	0.180	0.000
LoRA step 100	800	0.605	0.080
LoRA step 200	1,600	0.430	0.080
projector step 50	400	1.000	1.000
projector step 100	800	0.945	0.880
projector step 200	1,600	0.945	0.880

projector step 50 相对 frozen 的 strict paired preference 提升为 **+0.870 [0.825, 0.915]**, 自由生成 paired 提升为 **+1.000 [1.000, 1.000]**。其 vision/shuffled strict paired 为 1.000/0.180, 差值 **+0.820 [0.765, 0.870]**; vision-paired-counterfactual correct-margin 为 **+20.4459 [19.7584, 21.1797]**。

这排除了只记住 answer 先验的解释。等 400 个样本下，LoRA-projector 的 strict paired 为 -0.820 $[-0.870, -0.765]$ ，生成 paired 为 -1.000 $[-1.000, -1.000]$ 。




Figure 5: 左: strict paired preference; 右: 自由生成 paired accuracy。projector 续训在 400 个 shape 样本处已达到完整配对恢复，LoRA 只恢复一部分。

10.5.2 逐层复测：projector 重新建立稳定的晚层通路

最佳 LoRA step 100 与 projector step 50 都从头抽取 train/selection 表征并重跑 2,000 次 pair-label permutation probe。LoRA 的最佳 assistant 仍在 layer 12，balanced accuracy 为 0.816；layer 14–21 再度压到 chance，final assistant probe 与 native LM-head 都只有 balanced 0.500。它确实改变了自由生成，但没有建立稳定的上层线性通路。

projector step 50 的轨迹不同：layer 12 为 0.691、layer 14 为 0.750、layer 17/18 为 1.000，final assistant probe 仍有 0.945，native LM-head 达到 1.000。paired-counterfactual native target/source 为 0/1，shuffled-image native target 为 0.2375，说明最终 head 读取的是实际视觉来源。primary vision probe 的 pair-permutation p 均为 1/2001。




Figure 6: 左: 冻结、LoRA 与 projector 续训的 assistant 逐层 balanced accuracy; 右: strict paired preference 的 vision/shuffled 控制。短程 projector 续训把中层信号延伸到 native head。

10.5.3 假设更新与下一项本地实验

假设	包 5 更新	证据与动作
冻结主干上层不会使用视觉证据	部分支持	顶部 LoRA 把 strict paired 从 0.130 提到 0.605、生成 paired 从 0 提到 0.080，确认 use/decoding 瓶颈真实存在；效果显著弱于 projector 续训。
当前 shape 主瓶颈是 projector 接口训练不足	强支持	projector step 50 在 vision 达到 preference/generation 1.000，shuffle 仅 0.180；晚层 probe 与 native head 同时恢复。
需要先扩大 projector 结构	本任务反驳	不改结构、不改初始化，400 个额外 shape 样本已完全恢复；结构消融应等多任务迁移读数。

0.5B 容量是 shape 首要瓶颈	削弱	同一个 0.5B 冻结主干可被短程 projector 续训驱动到 1.000；容量仍可能限制 OCR、推理与自然图像。
shape 恢复会跨任务泛化	未检验	立即用现有六任务 selection 评估 projector step 50，并跑 balanced multi-task 最小训练；结果决定辅助目标、1.5B 对照与分辨率域偏移的顺序。

独立 verifier 已重读两条训练轨迹的 8 个 checkpoint、8,400 条 preference、1,400 条 generation、63 个配对 bootstrap contrast、4,000 条 layerwise representation metadata 与 179,200 条 probe prediction。projector 大权重和两纽约 286 MB 表征保留在 V100 HDD，Git 包含完整路径、bytes/SHA、聚合表、probe 权重及无损 gzip 预测。付费 Gate D 继续暂缓。

10.6 Shape-only projector 的六任务迁移 (包 6, 2026-08-05)

10.6.1 零附加训练的预注册迁移矩阵

直接把包 5 的 shape-projector-step50 应用于 color、coordinate、count、OCR、shape、spatial 六项 selection，不再更新参数。对照为同一 step-1500 frozen projector 与 matched random initialization。Teacher-forced 矩阵对每个 checkpoint 跑 vision、shuffled-image、paired-counterfactual-image、background-matched-aux，共 28,800 行；自由生成矩阵再加入 blind，共 9,000 行。每项 preference 有 200 个完整 counterfactual pair，generation 使用与适配训练 ID/pair 都不相交的 50 pair。所有置信区间均以完整 pair 为重采样单位，2,000 次 bootstrap。

预注册的 broad-transfer 判据要求：至少三个非 shape 任务同时满足 checkpoint 相对 step 1500 的 strict paired preference 下界大于零，且 vision 相对 shuffled-image 的下界大于零。这样，单纯改变答案先验或解码习惯无法被计作视觉迁移。

任务	step 1500	shape projector	checkpoint 增益 (95% CI)	vision-shuffle (95% CI)
color	0.000	0.010	+0.010 [0.000, 0.025]	-0.015 [-0.040, 0.010]
coordinate	0.000	0.000	0.000 [0.000, 0.000]	0.000 [0.000, 0.000]
count	0.000	0.005	+0.005 [0.000, 0.015]	-0.005 [-0.025, 0.010]
OCR	0.000	0.015	+0.015 [0.000, 0.035]	+0.015 [0.000, 0.035]
shape	0.130	1.000	+0.870 [0.820, 0.915]	+0.820 [0.765, 0.875]
spatial	0.000	0.000	0.000 [0.000, 0.000]	0.000 [0.000, 0.000]



Figure 7: 左: 六任务 strict paired preference; 右: 自由生成 paired accuracy。shape-only continuation 的完整恢复没有扩散到其余五项。

10.6.2 Teacher forcing 与自由生成给出同一边界

shape 的自由生成 paired accuracy 从 step 1500 的 0 提升到 **1.000 [1.000, 1.000]**, vision-shuffled 为 **+0.980 [0.940, 1.000]**; 其余五项的 checkpoint paired-generation 增益全为 0。color、count、spatial 在 sample accuracy 或 prediction flip 上出现零散变化, 但始终无法同时答对完整 pair, 也没有稳定跟随正确图像来源, 因此不构成内容能力迁移。




Figure 8: shape-projector-step50 的图像因果效应。只有 shape 在 teacher-forced 与自由生成两种口径上同时形成大幅正差。

10.6.3 假设更新与下一项本地实验

假设	包 6 更新	证据与动作
shape 续训修复了可跨任务复用的通用视觉接口	反驳	五个非 shape 任务均未通过 checkpoint 增益与 visual-causality 双门槛; shape 的恢复是窄任务映射。
shape 的 1.000 只是语言答案先验	反驳	vision-shuffled preference +0.820、generation +0.980, 输出随真实图像中的配对属性变化。
短程 projector continuation 足以学习新内容映射	支持, 范围待测	40 个 shape pair 已足够; 下一项给六任务相同配额, 直接检验一轮 balanced supervision 的能力轨迹。
应立即扩大语言主干	暂不优先	0.5B 在得到任务监督后可完整解决 shape; 先测 balanced projector 能覆盖多少任务, 再把仍失败项交给 1.5B 容量对照。

下一包从 step 1500 开始, 以 true batch 24 每步固定放入每任务 4 条记录; checkpoint 0/25/50/100 对应已见 0/600/1,200/2,400 样本, step 100 恰好完成 synthetic train 一轮。先构建完整 feature cache 并做 OOM smoke; 随后复用本包全矩阵, 按任务观察 paired preference、correct margin、paired generation 与 visual controls。若多任务广泛恢复, 再做辅助目标和初始化消融; 若 OCR/coordinate/spatial 仍失败, 再进入 Qwen2.5-1.5B 容量对照与 projector loss/region 诊断。

独立校验重读 28,800 条 preference、9,000 条 generation、567 行聚合指标与 525 个 contrast, 并核对源摘要和分析文件 SHA-256。两条 canonical run 均为零失败, 完整测试集 **178/178** 通过, final odd halves 未评分。旧分析器因硬编码 blind teacher-forced 条件而中止, 其空结果目录已显式作废并随包保留。付费 Gate D 继续暂缓。

10.7 六任务均衡 projector continuation (包 7, 2026-08-05)

10.7.1 可审计缓存与真实 batch

完整 synthetic train 的 2,400 条记录先在 256 px 编码为 75 个 float32 shard。独立 verifier 重哈希 3,932,170,800 bytes, 并逐条读回 2,400 个张量、983,040,000 个数值, shape 与 finite 检查全通过。缓存耗时 251.5s, 峰值显存 1.95 GB。

续训仍从 step 1500 出发, 只更新 20,454,272 参数的 projector。每个 true batch 固定 24 条, 每项任务恰好 4 条; 100 步恰好遍历每项 400 条记录/200 pair 一轮。loss 在 step 1/25/50/100 为 2.7778/1.4495/1.4594/1.3490; 总耗时 144.5s, 峰值显存 11.80 GB。四个 projector/optimizer checkpoint、每步任务配额、6,577 个 answer token 与全部 tensor 均通过独立验证。




Figure 9: 一轮六任务均衡 projector continuation 的 true-batch loss。每步六项任务配额固定, 不把任务采样漂移混入能力轨迹。

10.7.2 一轮监督建立六任务 teacher-forced 视觉读出

Preference 终表含 38,400 行、16 个 checkpoint/condition cell、每格 1,200 个完整 counterfactual pair、零失败。step 25 只有 coordinate 通过预注册双门槛; step 50 增至 color 与 shape; step 100 六项全部同时满足 checkpoint 增益和 vision-shuffle 的 bootstrap 下界大于零。

任务	vision	shuffle	checkpoint 增益 (95% CI)	vision-shuffle (95% CI)
color	0.230	0.095	+0.230 [0.175, 0.290]	+0.135 [0.065, 0.205]
coordinate	0.055	0.000	+0.055 [0.025, 0.090]	+0.055 [0.025, 0.090]
count	0.115	0.060	+0.115 [0.075, 0.160]	+0.055 [0.005, 0.105]
OCR	0.135	0.050	+0.135 [0.085, 0.185]	+0.085 [0.040, 0.140]
shape	0.560	0.155	+0.430 [0.330, 0.525]	+0.405 [0.325, 0.480]
spatial	0.250	0.000	+0.250 [0.190, 0.310]	+0.250 [0.190, 0.310]



Figure 10: 左：strict paired preference 随均衡训练量的六任务轨迹；右：step 100 的图像因果差。六项都已摆脱 teacher-forced 地板。

早期轨迹存在可复现的多任务干扰：shape 在 step 25 相对 step 1500 下降 -0.130 $[-0.180, -0.085]$ ，step 50 恢复到 0.435，step 100 达到 0.560。单个短 checkpoint 会把“暂时被别的任务覆盖”误判成结构性失败，因此包 7 的决策使用整条轨迹。

10.7.3 剩余差距集中在冻结语言栈的使用与生成

Generation 终表含 12,000 行和 128 条 heldout shuffle-loss，零失败。step 100 只有 shape 与 spatial 的 paired generation 显著改善：相对 step 1500 为 $+0.160$ $[0.080, 0.280]$ 和 $+0.220$ $[0.120, 0.340]$ ；vision-shuffle 为 $+0.140$ $[0.060, 0.240]$ 和 $+0.220$ $[0.100, 0.340]$ 。color、coordinate、count、OCR 的 teacher-forced 双门槛已通过，自由生成 paired 仍为 0。




Figure 11: 自由生成 paired accuracy 的 checkpoint 轨迹。均衡 projector 已让 shape/spatial 可按图生成，另外四项仍停在“能偏好正确答案、不能稳定说出”的阶段。

10.7.4 假设更新与下一项本地实验

假设	包 7 更新	证据与动作
五项地板来自 projector 结构或 tower 信息损失	反驳	结构、初始化与冻结主干均不变；仅补一轮均衡监督，六项 teacher-forced checkpoint/causal 下界全部转正。
原训练覆盖不足是主要 teacher-forced 瓶颈	强支持	有效任务随每任务已见样本累积到六项；balanced supervision 是首个跨任务验证的改进方向。
0.5B 容量立即限制视觉内容选择	进一步削弱	同一 0.5B 主干已在六项给出因果正确偏好；容量仍可能限制自由生成、OCR 与格式遵从。

只延长 projector 即可关闭全部生成差距	未定	四项仍有 teacher-forced/generation 裂缝；下一项做等 record-order 的额外 projector epoch 与顶部 LoRA screen。
--------------------------	----	---

下一包从 balanced-projector-step100 出发，让 projector-only continuation 与小规模顶部 LoRA 使用同一均衡记录顺序和 examples-seen。若 projector 继续训练同时抬高 preference/generation，优先延长训练；若 LoRA 对四项生成的改善明显更大，则先定位上层 use/decoding 瓶颈，再做 Qwen2.5-1.5B 容量对照。三次实现失败均完整保留并作废：padding/placeholder 同 ID、checkpoint provenance 缺字段、runner 强制 random control。final odd halves 未评分，付费 Gate D 继续暂缓。

10.8 Gate C: Vast 只读调研

2026-08-02 12:23 (UTC+8) 用官方 Search Offers API 查询 verified、rentable、可靠度至少 0.98、至少 4 张卡、单卡至少 80 GB、总显存至少 320 GB 的 on-demand offer。市场是动态的，以下价格只用于预算，offer ID 不应写进自动租用脚本。

GPU	总显存	约美元/小时	判断
4×A100 PCIe 80 GB	320 GB	\$4.00	最便宜；无 NVLink，仅作兼容性/低价 smoke
4×A100 SXM4 80 GB	320 GB	\$6.94	300 GB/s NVLink；优先训练候选
4×H100 PCIe 80 GB	约 319 GB	\$8.00	新架构；仍需核验拓扑和 Dgrad
4×H100 SXM 80 GB	约 319 GB	\$10.75	性能优先候选
8×A100 SXM4 80 GB	640 GB	\$10.37	显存余量最大且价格低于当时 4×H100 SXM
4×H200 141 GB	约 562 GB	\$15.74	低 OOM 风险，成本高

正式候选还应要求 NVLink/P2P、至少 512 GB RAM、至少 1.5 TB 本地盘并现场复核 CUDA/驱动。查询结果中最低价 A100 PCIe 只有约 617 GB 可用盘，不满足完整缓存计划；A100 SXM4 候选有约 10 TB 盘。当前阶段只记录 offer，明确不创建实例。

当晚第二次查询 (增加 RAM ≥500 GB、盘 ≥1.5 TB 过滤，33 个 offer) 要点：4×A100 SXM4 降至 \$6.41/h (961 GB RAM、2 TB 盘，Gate D 首选)；4×H100 PCIe \$6.93/h (6392 GB 盘，性价比突出)；8×A100 SXM4 \$10.30/h (11 TB 盘，情景 B 兜底)；4×B200 \$21.25/h。新出现的 4×RTX PRO 6000 96 GB (Blackwell，原生 FP4) \$4.54/h 但总线无 NVLink 且 FP4 kernel 支持未验证，仅作探索。

架构修正：A100 为 Ampere，无 FP8/FP4 Tensor Core，0731 的 NVFP4 权重在 Ampere 上没有确认的内核路径，只能解量化至 bf16 (568 GB)，而 4×A100 的 320 GB 装不下——4×A100 实际上无法加载原生权重，Gate D 首选改为 **4×H100 PCIe** (Hopper FP8 + FP4 专用内核)。8×A100 SXM4 (640 GB) 仅作为解量化情景 B 的兜底。

10.8.1 最终账单 (含下载时间、网络、存储、装机余量)

流量与存储用报价接口的真实计费字段核算：权重下载 160 GB，H100 PCIe 候选流量 \$13.33/TB 约 \$2.13 (重传余量加倍 + 数据集/Docker 镜像约 \$1，共约 \$4)；上传仅约 134 MB projector + 800 MB 视觉塔 (首次) + JSON，约 \$0.01。存储按 storage_total_cost 约 \$0.001–0.005/h，租期内几分钱——**但实例 stop 后存储继续按 \$/GB/月计费 (约 \$0.107/GB/月，2 TB 停一周约 \$53)，结束必须 destroy 而不是 stop**。装机与依赖调试按 +1.5 h GPU 时间计余量。

阶段 (4×H100 PCIe, \$6.93/h)	乐观	基准	悲观
装机 + Docker + 环境调试余量	1 h	1.5 h	2.5 h

0731 权重下载 160 GB (27 分钟理论最优; 断流重传见 R4)	0.7 h	1 h	2 h
MoonViT-V2 视觉塔下载 800 MB (sha256 校验)	约 0.05 h	约 0.05 h	0.2 h
训练与评测数据约 30 GB	0.3 h	0.5 h	1.5 h
Gate D 判定 (加载→前向→单 batch backward→20 步)	0.5 h	1 h	1 h
对齐训练约 3000 步 (checkpoint 随传)	3 h	4 h	5 h
机上 benchmark 三组对照	1.5 h	2 h	2.5 h
权重与结果回传	0.2 h	0.2 h	0.3 h
合计机时	7.2 h ≈ \$50	10.2 h ≈ \$71	15 h ≈ \$104

流量费三档均约 \$4–5。情景 A 最终账单: \$55 (乐观) / \$75 (基准) / \$110 (悲观), 按 \$120 预算。带宽与耗时已按报价接口的 inet_down 字段核算: H100 PCIe 候选实测下行 2217 Mbps (约 277 MB/s), 理论 160 GB 约 10 分钟; 考虑 HF CDN 单连接限速 (40–100 MB/s) 与断流重传 (本地实测 802 MB 在慢代理下耗时 2h46m), 基准按 1 h、悲观按 2 h 计, 租机筛选条件要求 inet_down ≥ 1000 Mbps 并用 aria2/hf_transfer 多连接下载。checkpoint 上行流量每个约 300 MB (projector fp32+bf16+优化器), 每 500 步一次, 分钟级完成, 不影响训练计费。训练日志 (train.log) 与 history.json 随 checkpoint 一并上传, 社区可见完整训练过程。

情景 A' (R3 命中, H100 无法跑 FP4 前向): 转 4×B200 (\$21.25/h), 同排程基准 10 h ≈ \$213; B200 有原生 FP4 Tensor Core, Dgrad 通过率也更高。决策成本为已耗的装机+下载 1.5–2 h (约 \$10–14)。情景 B (FP4 不可反传且 B200 不可用): 8×A100 SXM4 \$10.30/h, 权重解量化至 bf16 (568 GB) 转换 1–2 h 且训练约慢 3 倍, 合计 20–30 h ≈ \$210–310 (该候选流量 \$1.33/TB, 网络几乎免费)。建议总预算: \$120 起步 (情景 A), 预留 \$220 (情景 A'/B), 上限 \$350; 预期实际花费 \$75–110。决策点在租后第 2–3 小时: Gate D 不通过即 destroy 止损, 损失约 \$20。

10.9 训练显存算术 (每卡, 权重张量并行切分, 视觉塔/projector 每卡复制)

冻结 LLM 与冻结视觉塔意味着: LLM 侧 没有优化器状态、没有参数梯度——AdamW 只挂在 projector 上 (train_overfit.py 里 AdamW(projector.parameters()), LLM 与视觉塔 requires_grad_(False), 视觉塔前向在 no_grad 里, 梯度只需以激活形式穿过 LLM 回到 projector, 不需要对视觉塔反传)。优化器全套 (权重 fp32 + m/v + 梯度) 只有约 0.55 GB。真正的变量是 LLM 权重本体和 Dgrad 路径的激活。

组成 (每卡)	情景 A: 4×RTX PRO 6000, FP4 权重 TP=4	情景 B: 8×A100, bf16 权重 TP=8
LLM 权重	160/4 = 40 GB	568/8 = 71 GB
LLM optimizer + 参数梯度	0 (冻结)	0 (冻结)
MoonViT-V2 权重 (bf16/fp32)	0.8–1.6 GB	0.8–1.6 GB
projector 权重 + AdamW + 梯度	约 0.55 GB	约 0.55 GB
LLM 激活 (grad ckpt, seq ≤700)	1–3 GB	1–2 GB
杂项 (CUDA ctx/碎片/通信 bucket)	5–10 GB	4–6 GB
合计 / 可用	约 47–55 / 96 GB	约 77–79 / 79.1 GB
判定	余量 41–49 GB, 健康	贴顶, 高风险

激活估算依据: 开 gradient checkpointing 后只存段边界 (61 层 $\times$ seq 700 $\times$ 4096 $\times$ bf16 约 0.35 GB) 加段内重算临时; micro-batch 4–16 线性放大。seq 700 来自候选训练 --max-image-side 640 (方形图最坏 529 视觉 token + 文本 $\leq$ 700), 但 640/1024 策略须经分辨率消融后再锁定。情景 A 的生命线是 FP4/FP8 原生加载成立 (R1–R3); 一旦需要 bf16, 任何 4 $\times$ 96GB 级机器都装不下 (568/4 = 142 GB > 96 GB), 只剩 8 卡。情景 B 在 8 $\times$ A100 上余量不足 2 GB, 必须 micro-batch 1 + 更激进 checkpointing, 实测 OOM 即升 4 $\times$ B200 (142 GB/卡, 余量约 50 GB, \$21.25/h, 账单已含)。

10.10 Gate D 风险清单 (租卡前预演)

不保证一次成功。下表是全部已识别坑点、概率判断与止损方案; 核心原则是**失败成本锁死在租后第 2–3 小时** (Gate D 判定, 损失约 \$20), 任何一项失败都有明确的下一步, 而不是现场想办法。

风险	概率	缓解 / 止损
R1 NVFP4 权重 Dgrad 不可用 (推理内核不支持对输入 embedding 求梯度)	中–高	核心风险。Gate D 单 batch backward 判定; 失败即退租转情景 B (解量化 bf16) 或情景 A' (B200 原生 FP4 内核重试)。
R2 Transformers 加载原生 0731 大权重失败 (quantization config 格式未被 5.x 支持)	中	Gate D 第一步即原生加载测试; 备选为 vLLM loader 导出 bf16 权重副本 (同时解决 R1)。
R3 FP4 前向内核在目标卡上不可用	低–中	主机 RTX PRO 6000 即 Blackwell (sm_120, 原生 NVFP4), 此项已从 “中” 降级; 但硬件支持 $\neq$ 内核带 Dgrad——Gate D 第 0 步用 tools/gate_d_dgrad.py 单层 reproducer 单独判定。失败转 4 $\times$ B200 (\$21.25/h) 或情景 B。
R4 权重下载断流/限速	高	本地实测 802 MB 在慢代理下耗时 2h46m; 租机标称 2217 Mbps 但 HF CDN 单连接限速 40–100 MB/s, 160 GB 理论 27–67 分钟, 断流可拖至 2h+。用 aria2/hf_transfer 多连接 + 断点续传循环 (已验证的做法), 账单已含 0.5–2h 敏感性。
R5 marketplace 实例被中断	中	checkpoint 流式上传 (每 500 步, 含 optimizer/RNG, 28/28 测试); 中断后换机 --resume 精确续训, 损失不足 10 分钟训练。
R6 机器环境与宣传不符 (NVLink 拓扑、驱动、盘速)	低–中	开机 10 分钟内 nvidia-smi topo -m + 盘速快测, 不符当场退租换机, 损失不足 1h 租金。
R7 情景 B 显存算术 (bf16 568 GB vs 8 $\times$ A100 640 GB)	低	冻结 LLM + activation checkpointing 下单 batch 激活很小, 72 GB 余量足够; 4 $\times$ H200 (564 GB) 装不下, 明确排除。
R8 Hash-MoE tid2eid 在多卡张量并行下的分布行为	中	hook 方案已在真实 tiny DeepseekV4 类验证; Gate D 的单 batch backward 在大权重多卡下复验, 占位位置路由一致性有断言。
R9 训练数据下载 (约 30 GB) 经代理再耗 1–2 h	中	提前把训练数据镜像到项目 HF 仓库 (随 checkpoint 上行走道同路), 租机从 HF 直下; 计入装机时间。
R10 MoonViT-V2 bf16 与 fp32 参考的特征偏差	低	fp32 参考已锚定 (eager/sdpa 差 3.1e-05); Gate D 记录 bf16 实测差 (预期约 1e-2 相对), 超差则视觉塔回 fp32 (仅多约 800 MB 显存)。

R11 租期内时间不够闭环	低-中	checkpoint 流式上传保证权重永不丢; benchmark 三组对照在机上跑但数据落盘 JSON 可增量上传; 最坏情况先公开 checkpoint + 部分指标。
R12 多卡分布策略与 PCIe 拓扑 (4×RTX PRO 6000 无 NVLink, PCIe 5.0 x16 54.2 GB/s; device_map="auto" 朴素模型并行的激活回传走 PCIe)	中	训练吞吐的直接风险: 3–5 s/步 的估计在 PCIe + 重算下可能偏乐观。多卡路径已定型为单进程 device_map="auto" (LLM 冻结, 无需权重梯度分片; vLLM/SGLang 推理 TP 不可用于反向训练)。Gate D 实测单步耗时: ≤8 s 维持; 8–15 s 重算步数保 benchmark; >15 s 验证 transformers 原生 tp_plan 或换 NVLink 机型 (H100 SXM \$10.75/h); 账单按 5 h 悲观档已可吸收 2 倍减速。

10.11 Gate D: 正式租卡前

分阶段判定 (完整版见 docs/gate-d-runbook.md §7, 2026-08-03 评审修订, 各步独立记录不合并):

- 0. 配置发现 + 最小 Dgrad reproducer (tools/gate_d_dgrad.py:打印量化方案; 只取一层真实 quantized linear 权重切片, 判定 input.grad 有限非零、weight.grad 为 None)。
- 1. nvidia-smi topo -m + 盘速快测 (不符当场退租)。
- 2. 原生 0731 权重加载成功; 文本短前向正常。
- 3. 单图短序列 forward (placeholder 注入)。
- 4. 单 batch backward, projector 梯度有限且非零, LLM/MoonViT 无梯度。
- 5. hook × activation checkpointing 数值一致性 (开/关梯度检查点 projector 梯度 allclose) + batch>1 多图位置一致。
- 6. 多卡路径定型 (device_map="auto") + 实测单步耗时分档 (≤8 / 8–15 / >15 s)。
- 7. 20 step 无 OOM/NaN; --resume 从流式 checkpoint 恢复一次且轨迹连续。

10.12 租期闭环排程 (2026-08-02 定价)

核心约束:租期一结束就没有机器能跑动 0731 做 benchmark 或回传权重,因此训练、benchmark、上传必须同在一次租期内闭环。交付物只有 projector + 评测 JSON + 报告,与 GLM 社区只发布 projector 一致,不回传 160 GB 主干。checkpoint 发两个精度: fp32 master (约 134 MB, 复现/续训用) 与 bf16 serving (约 67 MB,0731 激活为 bf16), 租期内由训练产物现场转换。推理侧接入 (vLLM/SGLang/llama.cpp/fastllm 补丁点、Hash-MoE 注意事项、验收检查) 已写成 docs/inference-integration.md (2026-08-03 重写为 MoonViT-V2 版), 作为后续给推理引擎提 PR 的合同文档; 要点: vLLM 与 SGLang 均已 Day-0 支持 Kimi-K3 (含 MoonViT3d 视觉塔) 且均有 DeepSeek-V4 文本栈, patch 面只剩 projector 模块、placeholder 扩展与 Hash-MoE 路由检查; placeholder 固定为现有 <| image |>(id 129279) 禁止扩 vocab, 合并只替换 embedding 向量、input_ids 保留 placeholder 供 Hash-MoE 路由。

Baseten 社区实验 (baseten.co/blog/glm-52-with-vision, checkpoint baseten/GLM-5.2-Vision-NVFP4) 只作为配方先验: **constant lr 5e-4**、global batch 64、约 66k 条短 QA、2 epoch ≈ 2070 optimizer steps, grokking 在第一 epoch 末附近出现。它不是本项目的时长承诺。审计发现当前训练器的历史 batch_size=N 是 micro_batch_size=1 下串行 N 次 forward/backward; 若照抄 64, 每个 optimizer step 会执行 64 次视觉塔和 LLM 前后向, 3–6 s/step 与 2–4 h 估计均无效。新版训练器已改用 micro-batch、gradient accumulation、effective batch、examples seen 与 answer tokens 的明确计量, 并暂时拒绝伪造 micro_batch_size > 1。正式租卡前必须实现 padded multi-example forward, 在小主干上实测 micro batch 1/2/4 的吞吐与显存, 再由目标 examples/token 数反推 optimizer steps 和租时。

分辨率也从“写死”改为待证: 先跑训练 448/640 × 评测 448/640/1024 的固定子集矩阵, 只有在小字 OCR 收益、分布失配、视觉 token 数和吞吐都可接受时才采用训练 640/评测 1024。容量消融按相同 examples seen 比较 Qwen2.5 0.5B/1.5B/3B 纯文本主干; 随后才做 projector scratch/warm-start、顶

部 LoRA、blank/fixed/shuffle/patch-permutation 与 synthetic minimal-pair 控制。完整协议在仓库 docs/ablation-protocol.md。

停训判据不看 loss，看两条 gap：主判据是 benchmark 分数 - blind 分数的 gap 随 checkpoint 的曲线，平台即停；辅助判据是留出集 shuffle_delta > 0.1。参考锚点：projector-only 的 TextVQA 现实预期 20–30% (blind 约 10–15%，成熟 VLM 60+)；达到 GLM 社区实验同量级 (grounding parse 率 >80%、Acc@50 个位数) 即成功。

阶段	时长	说明
装机 + 下载权重	1–1.5 h	160 GB；好主机 1–2 GB/s
Gate D 判定	0.5–1 h	FP4 Dgrad 失败则当场退租（损失约 \$10），转情景 B
Stage 1 对齐训练	待租前实测	按 examples/token 预算与真实 micro-batch 吞吐反推；禁止用 64 次串行 forward 冒充 global batch 64
benchmark 全套	1.5–2 h	TextVQA 500 / DocVQA 200 / OCRBench 200 / ScreenSpot 200；训练 checkpoint × blind × 随机 projector 三组对照，机上完成
权重与结果回传	0.5 h	projector 约 134 MB + 评测 JSON 上传 HF
合计	暂不锁定	装机、Gate D、benchmark 与回传有时间盒；训练段待 batching/分辨率/容量消融后重新报价

若 FP4 Dgrad 不可用（情景 B）：权重解量化至 bf16（568 GB），需 8×A100 SXM（\$10.30/h），同编程时长大约 ×2–3，预算 \$300–500。

11 评测与验收计划

没有 benchmark 就无法回答“接上了没有”。评测口径对标 Baseten 社区 GLM-5.2V 实验（原文 baseten.co/blog/glm-52-with-vision,0xSero/fable-glm-vision 复现）：双方视觉塔都来自 Kimi 的 MoonViT3d 家族（他们从 Kimi K2.6 抽取，我们从 Kimi K3 抽取 MoonViT-V2，当前塔宽 1024），其标志性指标是 **MMMU-Pro**（原文声称 55%，约 Claude 4.5 Haiku 水平），因此我们的评测集在 TextVQA/DocVQA/OCRBench/ScreenSpot 之外加入 **MMMU-Pro（单图子集，exact match）**。所有数字必须与 blind baseline（同一模型、无图输入）一起报告：VQA 类基准有显著语言先验，无图基线把“模型本来就会答”与“图像带来了信息”分开。

社区配方还有两个直接影响数据计划的实测结论：其一，**grokking**——batch 64 / lr 5e-4 配短答案时 loss 平台数百步后骤降（原文约 step 900）完成对齐，**长描述性答案会阻止 grok**，因此对齐数据应以短 QA 为主、长 caption 为辅，而不是只用长 caption；其二，**warm start**——从已对齐 projector 初始化可跳过大半平台期，多阶段数据混训时应复用上一阶段 checkpoint 而不是重零开始。

训练数据泄露控制（2026-08-03 定稿，GUI 修订）：正式 mix 含 TextVQA train（34.6k）、DocVQA train（25k）、0xSero art 子集（约 10k）与 ShowUI-desktop（8k）四类短答案监督；GUI 数据按用户决定纳入以建立 computer-use 基础，答案统一为 0xSero 动作格式 click(start_box=[x,y])（0..999 尺度，评测 parser 原生兼容）。0xSero 自带的 screenshots/multistep 行不直接复用（图像改名无法回 join；multistep 为轨迹格式），改为从同源公开数据集自取。代价与处理：ScreenSpot 自此为**域内**基准，报告中必须标注；fetch 规格机械执行 max_answer_words ≤ 20；组装去重为三道独立机制（2026-08-03 评审加固）：感知 aHash（hamming ≤ 6，抓缩放/重压缩重复）+ 精确像素 sha256（抓跨容器同内容）+ 归一化问题文本近重复（--eval-jsonl 抓跨 split 文本泄露），各机制的丢弃数分别计入 decontamination_report.json 随数据发布。数据产物托管于 dataset repo cyjin-yl/moonvit-dsv4-data，含来源、固定 revision 与 sha256，租机上一

次下载即用 (上传通道已实测: 新 huggingface_hub 分块上传经代理约 2.6 MB/s, 全量数据约 1.5–2 h, 见变更日志)。

已实现的评测资产:

- moonvit_glue.metrics: 纯 Python 指标, 无 torch 依赖。exact match、soft VQA (官方 min(1, 同意人数/3))、ANLS、token-F1, 以及 grounding 的 parse/Acc@threshold/mean error。
- tools/eval_vlm.py: 生成式评分 (--blind 输出无图基线) 与 --shuffle-loss (真图 vs 随机图的 teacher-forced loss 差) 两种模式。shuffle-loss 是训练前最便宜的信号检验: projector 学到东西后, 真图 loss 应显著低于随机图。
- tools/fetch_eval_data.py: 固定来源拉取 TextVQA (soft VQA)、DocVQA (ANLS)、OCRBench (exact match)、ScreenSpot (in-box grounding)、MMMUI-Pro (单图子集, exact match), 落盘 JSONL 与 MANIFEST.json (resolved revision sha 与 JSONL sha256), 沿用“信任 manifest 而不是 tag”的纪律。

阶段	运行内容	通过判据
Gate A	指标单元测试; 小模型 shuffle-loss 管线	测试全绿; 管线可跑
Gate B	真实 MoonViT + 小 LM: 生成、评分、blind 对照; overfit 训练	端到端无报错; shuffle_delta = +0.343 (显著为正)
Gate C	训练前/后各一次: TextVQA、DocVQA、OCRBench、ScreenSpot 小子集	训练后显著高于训练前与 blind

预期锚点: 0xSero 的 GLM-5.2 projector-only checkpoint 报告坐标格式解析率 92%、Accuracy@50 4.3%、平均点击误差约 564/999。第一阶段的成功定义是 DeepSeek 路径达到同量级信号, 而不是成熟 VLM 水平; grounding 在 projector-only 阶段大概率仍很弱。

本地对照臂 (与租机训练并行, 不花租金钱): (1) MoonViT-V2 + 小型纯文本 LM (Gate B 各 checkpoint) 跑全套 1,400 例, 作为“胶水通路在小模型上的接口可学习性”读数; (2) 原生 4B VLM (官方权重、官方精度) 经独立适配脚本读同一 eval JSONL、输出同格式评分, 只作为评测阳性对照和成熟小 VLM 参照, 不作为映射/迁移证据; (3) 小模型 projector 不能直插 0731 (hidden 896/576 vs 4096), 合法对照臂是“小模型 trunk 热启动 (到 GELU 的 4,096 维) + V4 重训最后一层”, 与全程从零的 scratch 臂对比收敛速度。除非另有具体问题, 不再追加 9B/27B 原生 VLM 对照; 它们不会缩小 DeepSeek 证据缺口。

12 数据集挑选过程与构建管线

本章记录正式数据资产的挑选理由、排除项与现行构建做法 (2026-08-03 定稿)。所有产物托管于 dataset repo cyjin-yl/moonvit-dsv4-data, 来源、resolved revision 与逐片 sha256 随数据发布。

12.1 挑选原则

- 对标社区实验:** 评测集与训练集对齐 Baseten/0xSero 的 GLM-5.2V 配方——他们用的我们照用, 保证数字横向可比; 其标志指标 MMMUI-Pro 必须在内。
- 短答案优先:** 社区实测长描述性答案会阻止 grokking, 正式训练集全部为短答案监督 (fetch 机械执行 max_answer_words ≤ 20); 长 caption 只用于 Gate B 信号验证, 不进正式 mix。
- 视觉塔同源:** 视觉塔从 Kimi K3 抽取 (与 0xSero 从 K2.6 抽取同族); art 子集离线复刻 0xSero build_art_dataset.py 的 QA 模板与 schema (tools/fetch_art_data.py), 减少配方变量。
- 可复现优先:** 每个来源固定 resolved revision; 逐分片 sha256 对 LFS oid 校验; MANIFEST 随数据发布, 信任 manifest 而不是 tag。

12.2 评测集 (1,400 行)

数据集	来源 (HF)	行数	指标	挑选理由
-----	---------	----	----	------

TextVQA val	lmms-lab/textvqa	500	soft VQA	OCR-VQA 基本盘，社区通用口径
DocVQA val	lmms-lab/DocVQA	200	ANLS	文档理解，与训练同族任务的 held-out
OCRBench test	echo840/OCRBench	200	exact match	纯文字识别
ScreenSpot test	rootsautomation/ScreenSpot	200	in-box grounding	GUI 定位；ShowUI 进训练后为域内基准，报告中单独标注
MMMU-Pro test	MMMU/MMMU_Pro standard (10 options) 单图子集	300	exact match	社区实验标志指标（原文声称约 55%）

每行一图，图像落盘，JSONL 附 MANIFEST (resolved revision + 逐分片 sha256 + JSONL sha256)。评测纪律：分 selection/final 两半——checkpoint 选择只看 selection 半，final 半只对最终 checkpoint 跑一次，避免把 test 当训练集；域内 (ScreenSpot) /跨域/零样本三组分开报告，不混入一张表。

12.3 训练集（四类短答案监督）

来源	行数	答案形态	理由
lmms-lab/textvqa train	34,602	短答案	与评测同任务不同 split；组装时对 eval 做文本去重
lmms-lab/DocVQA train	约 25,000	短答案	文档 QA；12 个官方 train 分片离线抽取
showlab/ShowUI-desktop train	7,496	GUI 动作 click(start_box=[x,y]) (0..999 尺度)	用户决定纳入，建立 computer-use 基础；答案格式与评测 parser 原生兼容
Artificio/WikiArt_Full + benitomartin/fashion-product-images-small-384x512	池 71,780 + 2,220 val；mix 取约 10,000	短描述 QA	与五个评测集零交集；复刻 0xSero schema

12.4 排除项与理由

- **长 caption 数据** (flickr8k/COCO 类)：grokking 实证表明长答案阻止对齐；flickr8k 仅用于 Gate B 信号轨，不进正式 mix。
- **0xSero screenshots / multistep 行**：screenshots 图像经改名无法回 join；multistep 为轨迹格式，与单步 QA 合同不符。GUI 监督改从同源公开集 ShowUI-desktop 自取。
- **与评测集近重复的任何行**：见下方三道去重机制。
- **低于发布精度的量化对照**：对照组评测一律官方发布权重精度 + 官方 kernel；fp8 发布的模型升 bf16 无损可做，GGUF Q4/Q6 等降精度量化不做——量化损失会混进“模型能力”读数。本地 V100 跑不动全精度 27B 则放弃该臂，或挪入租机 benchmark 窗口。

12.5 下载与校验通道（现行做法）

十二种数据源、93 个正式分片全部落 staging，逐片 sha256 对 LFS oid 校验并打 .sha256ok 幂等标记，最终 0 mismatch。通道是实测淘汰出来的：

- hf transfer 在代理下 0 字节挂起；hf-mirror 限流；工作站 datasets+dill 无法 pickle pyarrow MonthDayNano（任何本地 parquet 都炸 load_dataset）→ fetch 全程 raw pyarrow 离线直读 (--data-files)。

- ModelScope 镜像境内直连可达 8.8 MB/s，但约 1.5 小时高强度拉取后被 CDN 按 IP 渐进限速至 0；Tailscale 中继 (RTT 3.7 s，聚合 250–400 KB/s) 与代理同速且挤占家庭带宽，应用户要求退役。
- 最终方案：工作站经 Clash 代理 aria2 预取 + 离线 fetch。代理上下行共享总带宽 (约 250 KB/s 封顶)，**上传与下载严禁并行**，HF 上传统一串行排在下载之后。
- **关键事故**：xet-bridge 签名 URL 按 range 签发，aria2 -x8 分段重试拿过期 URL 会读到错 range 的字节并写入错偏移——TLS 合法、文件尺寸正确、内容静默损坏 (25 片)。根因定位后改单连接 -x1 -s1 + 每片 sha256 校验，坏片全部重拉修复；另修 aria2 不认大写 HTTPS_PROXY 一处。

12.6 组装、去重与打包

1. tools/build_train_mix.py 按配额组装 (TextVQA train 全量 + DocVQA train 25k + ShowUI 8k + art 10k)，三道独立去重：感知 aHash (hamming ≤ 6，抓缩放/重压缩) + 精确像素 sha256 (抓跨容器同内容) + 归一化问题文本近重复 (对五份 eval 全量比对，抓跨 split 文本泄露)；各机制丢弃数分别计入 decontamination_report.json 随数据发布。
2. tools/pack_to_parquet.py 打包：union-keys schema (from_pylist 只按首行推断的坑已修，测试 6/6)；train 按 20,000 行分片，eval 五份各打一包。图像统一为 PNG 字节内嵌 parquet——付费服务器上顺序读、免密集小文件 IO，租机下载一次即用。
3. 串行上传 cyjin-yl/moonvit-dsv4-data (已传文件自动跳过)；README 记录来源、revision、sha256 与复现命令，原数据集协议随产物保留。

12.7 当前状态 (2026-08-04)

- eval_v1: 五个评测集 1,400 行 + 1,400 张图像 + MANIFEST，完成并已上传 cyjin-yl/moonvit-dsv4-data。
- train_v1: 59,198 行 mix (TextVQA 29,252 / DocVQA 17,351 / ShowUI 5,167 / art 7,428；三道去重合计丢弃 23%) 打包 3 片约 20 GB，完成并已上传。
- sft_art: 71,780 train / 2,220 val，完成并已上传。
- Gate B full-mix early alignment: 完成 (2000 optimizer steps、16,000 examples、约 0.27 epoch，历史 shuffle_delta +0.727)；五基准与 stock 4B 阳性对照均完成并发布。当前优先级转为 true batching 与容量/projector/LoRA/分辨率/因果诊断消融，租时暂不锁定。

13 变更日志

日期	变更
2026-08-02	建立通用 placeholder 扩展、PatchMerger、MoonViT wrapper 和 DeepSeek embedding hook。
2026-08-02	确认 0731 已有 < image > ID 129279，禁止扩 vocab。
2026-08-02	真实缩小 DeepSeek-V4 Hash-MoE 完成 backward。
2026-08-02	发现 Transformers 4.57.6 缺少 DeepSeek-V4；基线切换为 5.12+。
2026-08-02	完成 Vast on-demand 只读快照；未创建或租用实例。
2026-08-02	公开仓库 cyjin-yl/moonvit-deepseek-v4-glue 上线并推送。
2026-08-02	新增评测资产：metrics 指标库、eval_vlm 评分器 (含 blind 与 shuffle-loss 模式)、fetch_eval_data 数据清单；新增 generate() 生成路径。
2026-08-02	V100 工作站：torch 2.10.0+cu128 确认含 sm_70；26/26 测试通过；记录 NVML mismatch 与 Xet-over-proxy 挂起 (HF_HUB_DISABLE_XET=1 解决)。

2026-08-02	V100 完成真实 MoonViT smoke (fp32) 与评测管线端到端干跑；发现 MoonViT remote code 与 Transformers 5.x 两处不兼容并 shim；确认视觉 token 数可顶爆小模型上下文。
2026-08-02	Gate B 通过：V100 上冻结 MoonViT + SmolLM2-135M 只训 projector, 1000 步后 shuffle_delta = +0.343；生成随图变化、blind 恒定。数据路径修复为相对 JSONL。
2026-08-02	Gate B 第二 backbone 复测通过：Qwen2.5-0.5B 同条件 shuffle_delta = +0.282，确认信号与文本主干选型无关。
2026-08-02	Gate B 第三轨通过：flickr8k 1100 条 (jxie 开放镜像，离线 parquet 救援落盘)，Qwen2.5-0.5B 1500 步 shuffle_delta = +0.148；三轨全部通过。
2026-08-02	训练器支持流式 checkpoint：每 500 步保存 projector(fp32+bf16)+AdamW+RNG 的完整可续训单元，后台线程传 HF；--resume 可从任一 checkpoint 精确续训。
2026-08-02	对齐社区 GLM-5.2V 配方：确认其视觉塔同为 MoonViT、标志指标为 MMMU-Pro (加入评测集)；记录 grokking (短答案) 与 warm-start 两条训练结论；带宽速度与数据集流量成本计入预算。
2026-08-03	MoonViT-V2 移植验证：K3 视觉代码 vision-only 抽取并 vendor 进仓库 (去文本模型依赖)；随机权重前向输出 [G,4,1024] 符合 PatchMerger 合同；新增 sdpa varlen attention 并与 eager 数值一致；moonvit_v2 wrapper 复用 MoonViTEncoder 契约；34/34 测试通过。权重单分片 (802 MB/1.56 TB) 下载中，HF 写权限已验证。
2026-08-03	真实权重回归完成：shard 96 下载 (sha256 9d10c74f...) → 抽取 165 张量 strict-load 通过 → V100 真实前向 [1369,4,1024]@1024px、finite、逐位确定、eager/sdpa 差 3.1e-05 → 34/34 回归 → 产物 (含 sha256 MANIFEST) 上传 HF vision_tower_k3/；训练/评测支持 --vision-tower v2。
2026-08-03	推理集成文档重写为 MoonViT-V2 版：确认 vLLM/SGLang 均 Day-0 支持 K3 (含 MoonViT3d) 且均有 DeepSeek-V4 文本栈，patch 面收敛为 projector 模块 + placeholder 扩展 + Hash-MoE 路由检查；llama.cpp/fastllm patch 点记录在案但 v1 不做。新增 Gate D 风险清单 (R1-R11，每条带缓解与止损) 与三档最终账单 (情景 A \$55/\$75/\$110，预算 \$120；情景 A' B200 与情景 B 约 \$210-310；上限 \$350)；projector 合同更新为 V2 的 33,564,672 参数。
2026-08-03	下载通道定论：aria2 多连接预取 parquet + 离线 pyarrow fetch (--data-files)，绕开 hf_transfer 挂起、hf-mirror 限流与 datasets+dill 的 MonthDayNano pickle 崩溃；新增 prefetch_parquet 与 fetch_art_data (0xSero art 离线复刻)；MMMU-Pro config 修正为 standard (10 options)；62/62 测试通过。
2026-08-03	租前全链路彩排通过 (Gate B+)：V100 上 400 步训练 + checkpoint 流式上传 + 三组评测 + 聚合全部闭环并落 HF；训练组 gap +0.117 vs 随机对照 +0.019，管线可判别；作为正式训练的对照组基线。
2026-08-03	外部评审 (Max) 并入 runbook：Gate D 分阶段化 (含 gate_d_dgrad.py 单层 Dgrad reproducer、hook×梯度检查点数值一致性、device_map="auto" 步时定律)；版本固定 + pip freeze 随产物；视觉 token 预算写死 (训练 640 /

	评测 1024); 配方谦逊条款 (LR 探针兜底); 评测纪律 (selection/final 两半、域内/跨域/零样本三组、3 种子 shuffle 统计)。
2026-08-03	数据管线定稿并写入报告新章节: 评测 5 集 1,400 行 (TextVQA/DocVQA/OCRBench/ScreenSpot/MMMU-Pro) 与训练 4 类来源 (TextVQA train 34.6k、DocVQA train 25k、ShowUI-desktop 7.5k、art 池 71.8k 取 10k) 的挑选理由与排除项; 93 个正式分片 sha256 校验 0 mismatch; 三道去重、union-keys parquet 打包与串行上传纪律; DocVQA train 抽取收尾中。
2026-08-04	数据全链路闭合: train_v1 mix 59,198 行 (去重丢 23%) + eval_v1 + sft_art_v1 全部上传 cyjin-yl/moonvit-dsv4-data; 数据仓 README 记录来源、revision、sha256 与复现命令。
2026-08-04	Gate B 全量 mix 训练完成 (V100, Qwen2.5-0.5B + MoonViT-V2, 2000 步): loss 6.41→3.01, held-out shuffle_delta +0.727 , 全量数据上视觉对齐信号明确; 修复占位 token 双默认值不一致 bug (训练 Qwen < image_pad > vs 评测 DeepSeek < image >) 为候选自动探测, 85/85 测试; 4 个 checkpoint 因代理 SSL 抖动待手动补传。
2026-08-04	Gate B 五基准终表 (trained/random/blind): textvqa 0.081/0/0、docvqa 0.039/0/0、ocrbench 0/0/0 (地板)、screenspot 解析 0.51 精度 0.01、MMMU-Pro 0.073/0/0——判别力三条全成立, 绝对读数如实留存 (含坏结果)。误判审计: 判别器清白 (最宽提取 +1~2% 封顶); 抓到 MMMU 输入格式化两个 bug (选项字面量被逐字符拆行、缺字母标签), 修复后 2.0%→7.3%, 旧读数作废。
2026-08-04	原生 Qwen3.5-4B 阳性对照修复并跑完: 发现同字节数坏 shard (视觉塔全集所在分片)→SHA-256 manifest 校验、1024px 上限与指标化短输出约束。修复后 vision/blind: TextVQA 0.820/0.031、DocVQA 0.926/0.071、OCR-Bench 0.900/0、ScreenSpot acc 0.760/0.010、MMMU-Pro 0.300/0.280。用户指出并纠正证据边界: 该模型自带视觉塔与多模态对齐, 只验证评测器, 不证明 MoonViT-V2→DeepSeek; 训练器新增原生 VLM 拒绝保护, Gate D 才是目标能力证据。
2026-08-04	用户指出 0.5B 容量混杂: Qwen2.5-0.5B 虽为纯文本主干, 但会压低 OCR/推理/格式遵从上限, dense 小模型的收敛也不能预测 DeepSeek Hash-MoE。Gate B 正式降格为工程/信号闸门; 尚未完成的干净桥接对照定义为无 vision_config 的约 3B 纯文本主干, 在相同 mix、seen-record、分辨率、scratch projector 与 selection 评测下复测。
2026-08-04	训练计量审计: 历史 batch 8 是 micro-batch 1 下串行累积, full-mix Gate B 共见 16,000 样本、仅约 0.27 epoch, 故重命名为 early alignment, 低 benchmark 不作能力上限。训练器新增 examples/answer tokens/effective epochs 与显式 batch 语义、固定分层 validation manifest、10 组 derangement mean±std、多答案监督 provenance; 租前实验按容量→projector/LoRA→分辨率→因果/合成诊断排序, true batching 实测前暂停锁定租时。
2026-08-05	V100 包 3/4 完成 paired preference、checkpoint 轨迹、逐层 probe 与 activation patching: shape 在 step 1500 出现内容特异中层通路, tower/projector 保留完整线性信息, 训练后的语言上层把读出压回 chance。
2026-08-05	V100 包 5 等顺序适配诊断: 顶部 rank-8 LoRA 最佳 strict/generation paired 为 0.605/0.080; projector 续训仅见 400 个 shape 样本即达到

	1.000/1.000, vision-shuffle strict paired +0.820, 并把 final assistant probe/native head 恢复到 0.945/1.000。下一项转向六任务迁移与 balanced multi-task 最小训练。
2026-08-05	V100 包 6 零训练六任务迁移: shape strict paired preference 0.130→1.000、generation 0→1.000, 且 vision-shuffle 为 +0.820/+0.980; 其余五项没有通过配对 bootstrap 与视觉因果双门槛。shape-only continuation 被判定为窄任务映射, 下一项锁定 balanced 六任务 projector continuation。
2026-08-05	V100 包 7 完成一轮 true-batch 六任务均衡 projector 续训: step 100 时六项 strict paired preference 与 vision-shuffle 下界全部转正; 自由生成仅 shape/spatial 改善, 定位出四项明确的 teacher-forced/生成裂缝。下一项做等顺序额外 projector epoch 与顶部 LoRA screen。

14 下一位执行者的最短路径

先运行 `pytest` 和 `examples/smoke_tiny_text_lm.py`。然后在 V100 工作站使用机械盘作为 `HF_HOME`, 按 MANIFEST 校验并验证真实 MoonViT-V2。正式 0731 实验前不要写训练循环, 先证明目标 CUDA/量化 runtime 支持 input data-gradient。若失败, 优先评估 FP8 可微加载或定制 Dgrad, 不要改用 GGUF 假装完成训练链路。