

MoonViT 接入 DeepSeek-V4-Flash-0731

训练前架构审计、胶水原型与硬件计划

版本 0.2 · 2026-08-03

Contents

- 1 执行摘要 2
- 2 来源与可复现边界 2
- 3 权重与张量合同 2
- 4 DeepSeek-V4 特殊适配 2
- 5 已完成验证 3
- 6 MoonViT 尺寸与适配性 3
- 7 MoonViT-V2 (Kimi K3 视觉塔) 移植 3
- 8 本地与云端硬件计划 4
- 9 分阶段门槛 4
 - 9.1 Gate A: 无需大权重 4
 - 9.2 Gate B: V100 工作站 4
 - 9.3 Gate B 实测: projector overfit 实验 (2026-08-02) 5
 - 9.4 Gate C: Vast 只读调研 6
 - 9.4.1 最终账单 (含下载时间、网络、存储、装机余量) 7
 - 9.5 训练显存算术 (每卡, 权重张量并行切分, 视觉塔/projector 每卡复制) 7
 - 9.6 Gate D 风险清单 (租卡前预演) 8
 - 9.7 Gate D: 正式租卡前 9
 - 9.8 租期闭环排程 (2026-08-02 定价) 9
- 10 评测与验收计划 10
- 11 变更日志 11
- 12 下一位执行者的最短路径 12

1 执行摘要

本项目目标是给纯文本的 DeepSeek-V4-Flash-0731 接入 MoonViT 视觉编码器。第一阶段不训练视觉塔和语言模型，只训练一个 Kimi 风格 PatchMerger projector。当前结论是：架构合同成立，普通 causal LM 和 Transformers 的真实 DeepSeek-V4 Hash-MoE 缩小模型都已完成 loss/backward；正式 0731 大权重的 FP4/FP8 可微 kernel 是尚未消除的主要风险。

MoonViT 约 400M 参数，BF16 权重文件约 834 MB，相对于约 160 GB 级的 DeepSeek 混合精度权重很小。更大的资源变量是图像分辨率带来的视觉 token 数和冻结 LLM 反向所保留的激活，而不是视觉塔权重。

2 来源与可复现边界

- 社区 projector checkpoint: 0xSero/glm-local-vision-checkpoint。它证明了 projector-only 路线能把视觉信号接到 GLM-5.2，但公开 grounding 指标仍弱，不能等同于成熟 VLM。
- 社区复现记录: Giving a 753B Model Eyes。
- DeepSeek 权重: deepseek-ai/DeepSeek-V4-Flash-0731，MIT。
- 独立视觉塔: moonshotai/MoonViT-SO-400M，MIT。
- Kimi-K2.5 技术报告: Kimi K2.5: Visual Agentic Intelligence。
- Vast offer 搜索接口: Vast.ai Search Offers API。本文只调用搜索接口，不调用创建实例接口。

独立 MoonViT-SO-400M 来自 Kimi-VL；Kimi-K2.5/K2.6 使用演进后的 MoonViT-3D。两者输出形状兼容不代表特征分布相同。视觉塔 revision 是训练 provenance 的组成部分；更换视觉塔必须重训 projector。

3 权重与张量合同

组件	合同	状态
MoonViT-V2	[tokens, 4, 1024]	冻结
PatchMerger	LN(1024) → flatten → 4096 → GELU → 4096	训练
DeepSeek embedding	vocab → 4096	冻结
Placeholder	< image > / ID 129279	现有词表
Hash-MoE routing	扩展后的 placeholder IDs	冻结

V2 projector 精确参数量是 33,564,672 (fp32 约 134 MB，bf16 约 67 MB；配置见 configs/deepseek-v4-flash-0731-projector-moonvit-v2.json)。备选的 V1 塔 (MoonViT-SO-400M, 1152 维) projector 为 40,119,040 参数，两条配置不得混用。保存格式由 projector_config.json 与 projector.safetensors 组成，加载时使用 strict state-dict 校验。MoonViT、DeepSeek 与 projector 始终保留为三个可独立哈希和升级的来源，不把大权重复制到自有仓库。

4 DeepSeek-V4 特殊适配

DeepSeek-V4 的早期 Hash-MoE 通过 tid2eid[input_ids] 选 expert。只给 inputs_embeds 会丢失路由 IDs，而当前公共 forward 不允许同时给 input_ids 和 inputs_embeds。

原型保留扩展后的 placeholder IDs，并用仅在一次 forward 内生效的 embedding forward hook 替换查表输出。这样 Hash-MoE 看到合法 token IDs，Transformer 隐藏状态看到 projector embeddings，loss 仍可反向到 projector。hook 在 forward 结束后自动移除，不修改 Transformers 源码。

不得向 0731 tokenizer 增加 <image>：扩词表会同时要求修改输入 embedding、LM head 和 Hash-MoE 的 tid2eid 表。0731 已含多个视觉相关 token，因此没有必要承担该风险。

5 已完成验证

测试	结果	意义
Placeholder 可变长度扩展和 label mask	通过	序列/监督合同
Projector Safetensors round-trip	通过	权重可恢复
冻结普通 GPT-2 的 backward	通过	通用文本主干
真实 DeepseekV4ForCausalLM 1 层 Hash-MoE	通过	DeepSeek 路由合同
MoonViT 输出 shape/freeze 合同	通过	视觉边界
真实 MoonViT-SO-400M + 小 LM 前向/反向	通过	V100 CUDA fp32
eval_vlm 生成/blind/shuffle-loss 干跑	通过	评测管线端到端
generate(): generic 与 deepseek_v4 两种路径	通过	评测/推理前置
指标库 (VQA/ANLS/token-F1/grounding)	通过	纯 Python, 无 torch
完整测试集	34/34	Linux + torch 2.10.0+cu128

V100 实测: MoonViT-SO-400M 在 448px 输入下输出 [192,4,1152], 原生 640×480 下 [1064,4,1152], 符合合同; loss/backward 正常。评测管线用随机 projector + tiny-gpt2 干跑: 生成、评分、blind 基线与 shuffle-loss 全部端到端通过; shuffle-loss 在未训练 projector 上给出 mean_delta = 0.0 的正确零结果——训练后该值应当变正, 这是对信号最便宜的读数。

离线 smoke 结果: 输入 6 token 扩展为 8 token; projector 六组参数均获得梯度; 语言模型参数梯度数为 0。同一结果在 doesworkstation (V100) 上复现。

版本审计发现, 公开 PyPI Transformers 4.57.6 不含 deepseek_v4 模块; 真实 DeepSeek 类测试使用 Transformers 5.14.1。因此统一环境暂定 transformers>=5.12,<6, 不能盲从 checkpoint config 中的历史版本字符串。

6 MoonViT 尺寸与适配性

MoonViT 本身适合该任务: 27 层、hidden size 1152、16 heads、约 400M 参数, 原生分辨率和 NaViT packing 对 GUI、文档、截图有价值。它不会显著改变完整 0731 的权重门槛。

风险来自 token 数。patch size 为 14, 随后 2×2 合并。392×392 图像产生约 196 个合并 token; 896×896 产生约 1024 个。第一阶段应把每图上限锁在 1024; 更高分辨率必须以梯度激活显存实测决定。

7 MoonViT-V2 (Kimi K3 视觉塔) 移植

按项目决策, 视觉塔改为从 Kimi 直接抽取 (K3 优先, K2.6 备选), 与社区 GLM-5.2V 实验同源 (他们从 K2.6 抽)。Kimi-K3 仓库全量约 1.56 TB, 但其 safetensors index 显示全部 165 个 vision_tower.* 张量集中在单个分片 model-00096-of-000096.safetensors (约 802 MB)。抽取与验证全部在自有工作站完成, 不依赖租用机器; 租服务器时使用抽取后的独立视觉塔产物, 不触碰完整 K3 仓库。

K3 的 MoonViT3d(下称 MoonViT-V2)与 MoonViT-SO-400M 的合同差异: vision width 1152 → **1024** (27 层、12 头、qkv 1536、rmsnorm、无 attn bias、divided-fixed 位置插值); merge 方式 sd2_tpool, 单图 (t=1) 时时域池化为恒等, 输出仍是每图 [tokens, 4, 1024] 的特征组——与既有 PatchMerger 的 [G,4,C] 合同同构, 胶水层零改动, 仅 projector 的 vision_width 换为 1024 (flatten 维度 4096)。输入格式为 NaViT packing 的 [total_patches, 3, 14, 14] + grid_thws, 与 V1 的 flatten 格式不同, 由 processor 适配器统一。

移植方式：将 K3 仓库中视觉塔所需的最小代码集 vendor 进本仓库（src/moonvit_glue/vendor/kimi_k3/, Apache-2.0 + Kimi K3 License, 已附 LICENSE），删除文本模型依赖（modeling_kimi_linear 要求更新版 Transformers 的 OutputRecorder, 与本项目 5.12 基线冲突）与条件生成类；加载不再需要 trust_remote_code, 也不再需要下载完整 K3 仓库。moonvit_glue.moonvit_v2 复用既有 MoonViTEncoder 契约（freeze、形状校验、preprocess），新增 sdpa varlen attention（K3 代码只注册 flash-attention-2 与 eager；V100 等无 flash-attn 硬件用 eager/sdpa, 数值一致性有测试）。

已验证（工作站）：vision-only 模块独立实例化（真实配置 401.2M 参数）；前向输出 [G,4,1024] 符合合同；eager 与 sdpa 注意力数值一致；带/不带 vision_tower. 前缀的 state-dict 均 strict 加载；processor 适配器产出 pixel_values/image_grid_hws 合同键；完整测试集 34/34 通过。真实 shard 的 header 元数据与模型 state_dict 逐项比对：165/165 key、形状、dtype（全 BF16）完全一致，且该 shard 不含任何非视觉权重。**服务器端同样只需部分下载**：干净房间测试（PYTHONPATH 仅含本仓库、无 K3 staging）确认 vendored 代码只依赖 stdlib/torch/transformers/numpy/PIL, 租机时视觉塔侧只需 git 仓库 + 抽取产物（约 800 MB, 附 sha256 MANIFEST 供下载校验），完整 K3 仓库不进入训练链路。

真实权重回归（2026-08-03）：shard 下载完成（802,448,352 B, sha256 9d10c74f...），tools/extract_moonvit_v2.py 抽取 165 张量 / 401.2M 参数并 strict-load 通过，产物 moonvit_v2.safetensors（BF16, sha256 01436a95...）+ MANIFEST（双哈希）。V100 上真实权重前向：1024×1024 图像 → 5476 patches（74×74 grid）→ [1369,4,1024]，全部 finite，特征统计健康（mean 0.0003 / std 0.0511 / absmax 0.60, RMSNorm 后典型量级）；两次前向逐位一致（确定性）；eager 与 sdpa 在真实权重上最大绝对差 3.1e-05（fp32 累加顺序的正常量级）。抽取产物上传至项目 HF 仓库 vision_tower_k3/ 子目录，训练与评测经 --vision-tower v2 --moonvit-v2-weights 使用。

8 本地与云端硬件计划

目标	建议硬件	判断
胶水/单元测试	CPU 或任意 8 GB GPU	已完成
MoonViT + 0.5B–3B LM	12–24 GB GPU	适合本地开发
V100 32 GB	SM70、32 GB	可跑 MoonViT/小 LM；不能装完整 0731
完整 0731 推理验证	同机 4×48 GB 起步	上下文和 kernel 受限
projector-only 正式训练	4×H100 80 GB 或更高	先过单 batch backward
低风险首跑	4×H200/B200	更大激活余量

消费级单卡不能纯 GPU 运行完整 0731。110–192 GB 主机内存配合 3/4-bit CPU offload 可能极慢推理，但 GGUF/llama.cpp 不能作为当前 projector 训练路径。MoonViT 单独可在普通本地机器运行；完成后的完整组合能否“本地跑”，取决于本地是否具备多卡或大内存 offload 条件。

9 分阶段门槛

9.1 Gate A: 无需大权重

- 1. 固定 tokenizer/image token 合同。
- 2. 固定 MoonViT revision、processor 和输出 shape。
- 3. 小型纯文本 LM 完成 overfit 与保存/恢复。
- 4. 真实 DeepSeek-V4 缩小配置完成 Hash-MoE backward。

9.2 Gate B: V100 工作站

- 1. 在不占用现有 Qwen 优化任务的情况下盘点 CUDA/PyTorch/磁盘。✓ 已完成，并经 tmux 向 fastllm 任务留言协调。

- 2. 大文件仅写入 /run/media/ezra/13D010B6FDBC1A06/。✓ 已确认 /home 89% 占用，机械盘约 3.7 TB 可用。
- 3. 跑 MoonViT standalone 与小 LM；记录 SM70 fallback。✓ 真实 MoonViT-SO-400M 前向/反向与评测管线干跑均通过。torch 2.10.0+cu128 wheel 自带 sm_70，V100 matmul 与 26/26 测试通过，不需要旧版 PyTorch。
- 4. 不尝试加载完整 0731。✓ 保持该约束。
- 5. 小规模 overfit 训练验证信号。✓ 通过（见下节）。

9.3 Gate B 实测：projector overfit 实验 (2026-08-02)

数据：109 条 ComfyUI 产出图的英文描述性 caption (data/comfy_captions.jsonl，零下载，93 训练 + 16 评测)。设置：冻结 MoonViT-SO-400M (fp32) 与 SmolLM2-135M-Instruct (fp32)，只训 40.1M 参数 PatchMerger projector；placeholder 用现有 token <|endoftext|> (id 0)，不扩 vocab；--max-image-side 448 (每图 192 token)；batch 4，AdamW。

第一次跑 (200 步，lr 1e-3，约 8.6 epoch)：训练 loss 4.25 → 3.74，但 shuffle_delta 仅 +0.007，在噪声内——模型主要学到 caption 文体先验。第二次跑 (1000 步，lr 2e-3，约 43 epoch) 信号确立：

指标	数值
训练 loss (首窗 → 末窗)	4.303 → 3.338
评测真图 loss	3.300
评测打乱图 loss (16 样本 × 5 轮)	3.642
shuffle_delta	+0.343
训练耗时 (V100)	951 秒 (1000 步)

生成对照 (8 条评测样本，greedy 48 token)：有图输出随图变化且出现内容词 (“Korean dress”、“3D model”、“beard, pastel houses”，token-F1 0.112)；同一模型的 blind 无图输出 8 条逐字节相同 (“beautiful, serene landscape...” ， token-F1 0.082)。三项证据一致：loss 下降、shuffle_delta 显著为正、生成随图变化且 blind 恒定——projector 确实把图像信息送进了冻结 LM，训练合同在真实权重上成立。checkpoint 在 checkpoints/overfit-smolml135-1k。

注意：评测集 loss (3.30) 低于训练集末窗 (3.34)，且 43 epoch 已过拟合，shuffle_delta 部分来自对 93 张训练图的记忆；这一 gate 的目的是验证信号通路，不是产出可用 captioner。

第二个 backbone 复测 (同一数据与超参，placeholder 自动解析为 <|image_pad|>)：Qwen2.5-0.5B-Instruct 1000 步后训练 loss 3.898 → 3.160，评测真图 3.310 vs 打乱图 3.592，**shuffle_delta = +0.282**，耗时 1194 秒，checkpoint 在 checkpoints/overfit-qwen05-1k。两条 backbone 轨给出同量级正 delta，说明该信号来自胶水层与 projector 通路本身，与文本主干选型无关。

第三轨在更大更干净的数据上复测：flickr8k 训练分片 1100 条 (1036 训练 + 64 评测；jxie/flickr8k 镜像，nlphuji 原仓为 gated；因代理网络反复断流，最终直接从 HF 缓存的 train parquet 离线解出，MANIFEST 记录 resolved revision)。Qwen2.5-0.5B，1500 步、batch 8、lr 2e-3 (约 11.6 epoch，记忆成分远小于 comfy 小集)：训练 loss 3.091 → 2.435，评测真图 2.574 vs 打乱图 2.722 (64 样本 × 5 轮)，**shuffle_delta = +0.148**，耗时 2102 秒，checkpoint 在 checkpoints/overfit-qwen05-flickr8k。在 10 倍数据、1/4 epoch 数下 delta 仍显著为正——信号不依赖小集记忆。

该 checkpoint 的生成对照同样干净：8 条评测样本有图输出为正常 flickr8k 风格 caption (“A boy in a red shirt and blue shorts is holding a toy”， token-F1 **0.284**)；blind 无图输出全部退化为同一句拒绝话术 (“I’ m sorry, but you haven’ t provided an image...” ， token-F1 **0.0**)。

三轨汇总 (判据均为真图 vs 打乱图 teacher-forced loss 差)：

数据	文本主干	步数/epoch	delta	结论
----	------	----------	-------	----

comfy 109 条	SmolLM2-135M	1000 / 43	+0.343	通过
comfy 109 条	Qwen2.5-0.5B	1000 / 43	+0.282	通过
flickr8k 1100 条	Qwen2.5-0.5B	1500 / 11.6	+0.148	通过

Gate B 结论：胶水层 + projector 训练合同在真实权重、两个文本主干、两个数据集上全部成立，可以进入 Gate D（租卡验证 0731 大权重的 Dgrad 通路）。

工作站实测注意项：

- NVML 版本不匹配（内核模块 580.159.04 vs 用户态库 580.173）：nvidia-smi 不可用，但 CUDA 初始化与 kernel 运行正常。不要为修复它而重载驱动或重启——同机其他任务正在使用 GPU。
- MoonViT remote code 与 Transformers 5.x 有两处不兼容：缺 all_tied_weights_keys（已在 moonvit.py shim，ViT 无 tied weights，空映射语义正确）；bf16 下 remote code 内部存在 float32/bf16 混用的 layer_norm 调用，V100 上 MoonViT 以 fp32 运行（约 1.6 GB，可接受）。
- 小上下文文本模型装不下原生分辨率视觉 token：640×480 照片产生 1064 个合并 token，加 prompt 后超过 tiny-gpt2 的 1024 positions，表现为 scatter-gather device assert（异步报错会漂移到无关位置，需 CUDA_LAUNCH_BLOCKING=1 定位）。--max-image-side 控制 token 数；正式 0731 的 128k 上下文无此问题。
- HF 下载须走本机代理 127.0.0.1:7890（约 0.4–0.5 MB/s），且该仓库默认 Xet 传输在代理下会挂起，必须设 HF_HUB_DISABLE_XET=1。
- 复用现有 venv（torch 2.10.0+cu128 + transformers 5.12.1）；pytest 用 pip --target 装在独立目录，不改对方环境。
- 工作站负载高（其他 agent 编译/跑 inference server）时，机械盘上的 torch import 可达 90 秒以上；批处理脚本超时预算要放宽。

9.4 Gate C: Vast 只读调研

2026-08-02 12:23 (UTC+8) 用官方 Search Offers API 查询 verified、rentable、可靠度至少 0.98、至少 4 张卡、单卡至少 80 GB、总显存至少 320 GB 的 on-demand offer。市场是动态的，以下价格只用于预算，offer ID 不应写进自动租用脚本。

GPU	总显存	约美元/小时	判断
4×A100 PCIe 80 GB	320 GB	\$4.00	最便宜；无 NVLink，仅作兼容性/低价 smoke
4×A100 SXM4 80 GB	320 GB	\$6.94	300 GB/s NVLink；优先训练候选
4×H100 PCIe 80 GB	约 319 GB	\$8.00	新架构；仍需核验拓扑和 Dgrad
4×H100 SXM 80 GB	约 319 GB	\$10.75	性能优先候选
8×A100 SXM4 80 GB	640 GB	\$10.37	显存余量最大且价格低于当时 4×H100 SXM
4×H200 141 GB	约 562 GB	\$15.74	低 OOM 风险，成本高

正式候选还应要求 NVLink/P2P、至少 512 GB RAM、至少 1.5 TB 本地盘并现场复核 CUDA/驱动。查询结果中最低价 A100 PCIe 只有约 617 GB 可用盘，不满足完整缓存计划；A100 SXM4 候选有约 10 TB 盘。当前阶段只记录 offer，明确不创建实例。

当晚第二次查询（增加 RAM ≥500 GB、盘 ≥1.5 TB 过滤，33 个 offer）要点：4×A100 SXM4 降至 \$6.41/h（961 GB RAM、2 TB 盘，Gate D 首选）；4×H100 PCIe \$6.93/h（6392 GB 盘，性价比突出）；8×A100 SXM4 \$10.30/h（11 TB 盘，情景 B 兜底）；4×B200 \$21.25/h。新出现的 4×RTX PRO 6000 96 GB（Blackwell，原生 FP4）\$4.54/h 但总线无 NVLink 且 FP4 kernel 支持未验证，仅作参考。

架构修正：A100 为 Ampere，无 FP8/FP4 Tensor Core，0731 的 NVFP4 权重在 Ampere 上没有确认的内核路径，只能解量化至 bf16（568 GB），而 4×A100 的 320 GB 装不下——4×A100 实际上无法加载原生权重，Gate D 首选改为 **4×H100 PCIe**（Hopper FP8 + FP4 专用内核）。8×A100 SXM4（640 GB）仅作为解量化情景 B 的兜底。

9.4.1 最终账单（含下载时间、网络、存储、装机余量）

流量与存储用报价接口的真实计费字段核算：权重下载 160 GB，H100 PCIe 候选流量 \$13.33/TB 约 \$2.13（重传余量加倍 + 数据集/Docker 镜像约 \$1，共约 \$4）；上传仅约 134 MB projector + 800 MB 视觉塔（首次）+ JSON，约 \$0.01。存储按 storage_total_cost 约 \$0.001–0.005/h，租期内几分钱——**但实例 stop 后存储继续按 \$/GB/月计费（约 \$0.107/GB/月，2 TB 停一周约 \$53），结束必须 destroy 而不是 stop。** 装机与依赖调试按 +1.5 h GPU 时间计余量。

阶段（4×H100 PCIe，\$6.93/h）	乐观	基准	悲观
装机 + Docker + 环境调试余量	1 h	1.5 h	2.5 h
0731 权重下载 160 GB（27 分钟理论最优；断流重传见 R4）	0.7 h	1 h	2 h
MoonViT-V2 视觉塔下载 800 MB（sha256 校验）	约 0.05 h	约 0.05 h	0.2 h
训练与评测数据约 30 GB	0.3 h	0.5 h	1.5 h
Gate D 判定（加载→前向→单 batch backward→20 步）	0.5 h	1 h	1 h
对齐训练约 3000 步（checkpoint 随传）	3 h	4 h	5 h
机上 benchmark 三组对照	1.5 h	2 h	2.5 h
权重与结果回传	0.2 h	0.2 h	0.3 h
合计时	7.2 h ≈ \$50	10.2 h ≈ \$71	15 h ≈ \$104

流量费三档均约 \$4–5。**情景 A 最终账单：\$55（乐观） / \$75（基准） / \$110（悲观），按 \$120 预算。**

带宽与耗时已按报价接口的 inet_down 字段核算：H100 PCIe 候选实测下行 2217 Mbps（约 277 MB/s），理论 160 GB 约 10 分钟；考虑 HF CDN 单连接限速（40–100 MB/s）与断流重传（本地实测 802 MB 在慢代理下耗时 2h46m），基准按 1 h、悲观按 2 h 计，租机筛选条件要求 inet_down ≥ 1000 Mbps 并用 aria2/hf_transfer 多连接下载。checkpoint 上行流量每个约 300 MB（projector fp32+bf16+优化器），每 500 步一次，分钟级完成，不影响训练计费。训练日志（train.log）与 history.json 随 checkpoint 一并上传，社区可见完整训练过程。

情景 A'（R3 命中，H100 无法跑 FP4 前向）：转 4×B200（\$21.25/h），同排程基准 10 h ≈ \$213；B200 有原生 FP4 Tensor Core，Dgrad 通过率也更高。决策成本为已耗的装机+下载 1.5–2 h（约 \$10–14）。情景 B（FP4 不可反传且 B200 不可用）：8×A100 SXM4 \$10.30/h，权重解量化至 bf16（568 GB）转换 1–2 h 且训练约慢 3 倍，合计 20–30 h ≈ \$210–310（该候选流量 \$1.33/TB，网络几乎免费）。**建议总预算：\$120 起步（情景 A），预留 \$220（情景 A'/B），上限 \$350；预期实际花费 \$75–110。** 决策点在租后第 2–3 小时：Gate D 不通过即 destroy 止损，损失约 \$20。

9.5 训练显存算术（每卡，权重张量并行切分，视觉塔/projector 每卡复制）

冻结 LLM 与冻结视觉塔意味着：LLM 侧 **没有优化器状态、没有参数梯度**——AdamW 只挂在 projector 上（train_overfit.py 里 AdamW(projector.parameters())），LLM 与视觉塔 requires_grad_(False)，视觉塔前向在 no_grad 里，梯度只需以激活形式穿过 LLM 回到 projector，不需要对视觉塔反传）。优化器全套（权重 fp32 + m/v + 梯度）只有约 0.55 GB。真正的变量是 LLM 权重本体和 Dgrad 路径的激活。

组成 (每卡)	情景 A: 4×H100, FP4 权重 TP=4	情景 B: 8×A100, bf16 权重 TP=8
LLM 权重	160/4 = 40 GB	568/8 = 71 GB
LLM optimizer + 参数梯度	0 (冻结)	0 (冻结)
MoonViT-V2 权重 (bf16/fp32)	0.8–1.6 GB	0.8–1.6 GB
projector 权重 + AdamW + 梯度	约 0.55 GB	约 0.55 GB
LLM 激活 (grad ckpt, seq 约 600)	1–3 GB	1–2 GB
杂项 (CUDA ctx/碎片/通信 bucket)	5–10 GB	4–6 GB
合计 / 可用	约 47–55 / 80 GB	约 77–79 / 79.1 GB
判定	余量 25–32 GB, 健康	贴顶, 高风险

激活估算依据: 开 gradient checkpointing 后只存段边界 (61 层 × seq 600 × 4096 × bf16 约 0.3 GB) 加段内重算临时; micro-batch 4–16 线性放大。情景 A 的生命线是 FP4/FP8 原生加载成立 (R1–R3); 一旦需要 bf16, 4×H100/H200 都装不下 (568/4 = 142 GB > 80/141 GB), 只剩 8 卡。情景 B 在 8×A100 上余量不足 2 GB, 必须 micro-batch 1 + 更激进 checkpointing, 实测 OOM 即升 4×B200 (142 GB/卡, 余量约 50 GB, \$21.25/h, 账单已含)。

9.6 Gate D 风险清单 (租卡前预演)

不保证一次成功。下表是全部已识别坑点、概率判断与止损方案; 核心原则是**失败成本锁死在租后第 2–3 小时** (Gate D 判定, 损失约 \$20), 任何一项失败都有明确的下一步, 而不是现场想办法。

风险	概率	缓解 / 止损
R1 NVFP4 权重 Dgrad 不可用 (推理内核不支持对输入 embedding 求梯度)	中–高	核心风险。Gate D 单 batch backward 判定; 失败即退租转情景 B (解量化 bf16) 或情景 A' (B200 原生 FP4 内核重试)。
R2 Transformers 加载原生 0731 大权重失败 (quantization config 格式未被 5.x 支持)	中	Gate D 第一步即原生加载测试; 备选为 vLLM loader 导出 bf16 权重副本 (同时解决 R1)。
R3 H100 上 FP4 前向本身不可用 (官方 NVFP4 验证环境是 Blackwell)	中	情景 A 的直接死因; Gate D 前 30 分钟判定。转 4×B200 (\$21.25/h) 或情景 B。
R4 权重下载断流/限速	高	本地实测 802 MB 在慢代理下耗时 2h46m; 租机标称 2217 Mbps 但 HF CDN 单连接限速 40–100 MB/s, 160 GB 理论 27–67 分钟, 断流可拖至 2h+。用 aria2/hf_transfer 多连接 + 断点续传循环 (已验证的做法), 账单已含 0.5–2h 敏感性。
R5 marketplace 实例被中断	中	checkpoint 流式上传 (每 500 步, 含 optimizer/RNG, 28/28 测试); 中断后换机 --resume 精确续训, 损失不足 10 分钟训练。
R6 机器环境与宣传不符 (NVLink 拓扑、驱动、盘速)	低–中	开机 10 分钟内 nvidia-smi topo -m + 盘速快测, 不符当场退租换机, 损失不足 1h 租金。

R7 情景 B 显存算术 (bf16 568 GB vs 8×A100 640 GB)	低	冻结 LLM + activation checkpointing 下单 batch 激活很小, 72 GB 余量足够; 4×H200 (564 GB) 装不下, 明确排除。
R8 Hash-MoE tid2eid 在多卡张量并行下的分布行为	中	hook 方案已在真实 tiny DeepseekV4 类验证; Gate D 的单 batch backward 在大权重多卡下复验, 占位位置路由一致性有断言。
R9 训练数据下载 (约 30 GB) 经代理再耗 1–2 h	中	提前把训练数据镜像到项目 HF 仓库 (随 checkpoint 上行通道同路), 租机从 HF 直下; 计入装机时间。
R10 MoonViT-V2 bf16 与 fp32 参考的特征偏差	低	fp32 参考已锚定 (eager/sdpa 差 $3.1e-05$); Gate D 记录 bf16 实测差 (预期约 $1e-2$ 相对), 超差则视觉塔回 fp32 (仅多约 800 MB 显存)。
R11 租期内时间不够闭环	低–中	checkpoint 流式上传保证权重永不丢; benchmark 三组对照在机上跑但数据落盘 JSON 可增量上传; 最坏情况先公开 checkpoint + 部分指标。
R12 多卡分布策略与 PCIe 拓扑 (4×H100 PCIe 无 NVLink, TP=4 每层 all-reduce 走 PCIe)	中	训练吞吐的直接风险: 3–5 s/步 的估计在 PCIe + 重算下可能偏乐观。Gate D 实测单步耗时, >15 s/步 即换 NVLink 机型 (H100 SXM \$10.75/h) 或改流水线并行 (冻结 LLM 下 PP 通信最小, 但需 DeepSpeed/pippy, 工程复杂度上升); 账单按 5 h 悲观档已可吸收 2 倍减速。

9.7 Gate D: 正式租卡前

1. 原生 0731 权重加载成功。
2. 单图短序列 forward。
3. 单 batch backward, projector 梯度有限且非零。
4. LLM/MoonViT 无梯度。
5. 20 step 无 OOM/NaN。
6. 新进程恢复 projector 后输出一致。

9.8 租期闭环排程 (2026-08-02 定价)

核心约束: 租期一结束就没有机器能跑动 0731 做 benchmark 或回传权重, 因此训练、benchmark、上传必须同在一次租期内闭环。交付物只有 projector + 评测 JSON + 报告, 与 GLM 社区只发布 projector 一致, 不回传 160 GB 主干。checkpoint 发两个精度: fp32 master (约 134 MB, 复现/续训用) 与 bf16 serving (约 67 MB, 0731 激活为 bf16), 租期内由训练产物现场转换。推理侧接入 (vLLM/SGLang/llama.cpp/fastllm 补丁点、Hash-MoE 注意事项、验收检查) 已写成 docs/inference-integration.md (2026-08-03 重写为 MoonViT-V2 版), 作为后续给推理引擎提 PR 的合同文档; 要点: vLLM 与 SGLang 均已 Day-0 支持 Kimi-K3 (含 MoonViT3d 视觉塔) 且均有 DeepSeek-V4 文本栈, patch 面只剩 projector 模块、placeholder 扩展与 Hash-MoE 路由检查; placeholder 固定为现有 `<|image|>(id 129279)` 禁止扩 vocab, 合并只替换 embedding 向量、input_ids 保留 placeholder 供 Hash-MoE 路由。

训练量按 LLaVA 式对齐的标准做法定为 **1 个 epoch**: 15–30 万条 caption、global batch 64、约 2500–4500 步、lr $1e-3$ cosine, 每 500 步存 checkpoint 并立刻后台传 HF。checkpoint 是完整可续训单元 (projector fp32 + bf16、AdamW 状态、RNG、步数、loss 历史, 见 moonvit_glue.checkpointing): 实例中断不丢成果, 社区可实时看到训练曲线形成, 任何 checkpoint 可用 `--resume <repo-id>` 精确续训。4×H100 估 3–5 s/步 (13B 激活、seq 约 300–400、开 activation checkpointing), 训练段 2.5–6 h。多轮只会背诵 caption (43 epoch 的 +0.343 即过拟合态), 不加轮次。

停训判据不看 loss, 看两条 gap: 主判据是 benchmark 分数 – blind 分数的 gap 随 checkpoint 的曲线, 平台即停; 辅助判据是留出集 shuffle_delta > 0.1。参考锚点: projector-only 的 TextVQA 现实预期

20–30% (blind 约 10–15%, 成熟 VLM 60+); 达到 GLM 社区实验同量级 (grounding parse 率 >80%、Acc@50 个位数) 即成功。

阶段	时长	说明
装机 + 下载权重	1–1.5 h	160 GB; 好主机 1–2 GB/s
Gate D 判定	0.5–1 h	FP4 Dgrad 失败则当场退租 (损失约 \$10), 转情景 B
Stage 1 对齐训练	3–5 h	约 3000 步; checkpoint 随训随传
benchmark 全套	1.5–2 h	TextVQA 500 / DocVQA 200 / OCRBench 200 / ScreenSpot 200; 训练 checkpoint × blind × 随机 projector 三组对照, 机上完成
权重与结果回传	0.5 h	projector 约 134 MB + 评测 JSON 上传 HF
合计	7–10 h	4×H100 PCIe (\$6.93/h) 约 \$50–70; 含一次失败重试按 \$150 预算

若 FP4 Dgrad 不可用 (情景 B): 权重解量化至 bf16 (568 GB), 需 8×A100 SXM (\$10.30/h), 同编程时长大约 ×2–3, 预算 \$300–500。

10 评测与验收计划

没有 benchmark 就无法回答“接上了没有”。评测口径对标社区 GLM-5.2V 实验 (Harry Partridge 方法、0xSero/fable-glm-vision 复现): 视觉塔同为冻结 MoonViT (他们从 Kimi K2.6 抽取, 我们用官方独立仓 MoonViT-SO-400M, 同构 1152 维), 其标志性指标是 **MMMU-Pro** (原文声称 55%, 约 Claude 4.5 Haiku 水平), 因此我们的评测集在 TextVQA/DocVQA/OCRBench/ScreenSpot 之外加入 **MMMU-Pro (单图子集, exact match)**。所有数字必须与 blind baseline (同一模型、无图输入) 一起报告: VQA 类基准有显著语言先验, 无图基线把“模型本来就会答”与“图像带来了信息”分开。

社区配方还有两个直接影响数据计划的实测结论: 其一, **grokking**——batch 64 / lr 5e-4 配短答案时 loss 平台数百步后骤降 (原文约 step 900) 完成对齐, **长描述性答案会阻止 grok**, 因此对齐数据应以短 QA 为主、长 caption 为辅, 而不是只用长 caption; 其二, **warm start**——从已对齐 projector 初始化可跳过大半平台期, 多阶段数据混训时应复用上一阶段 checkpoint 而不是重零开始。

已实现的评测资产:

- moonvit_glue.metrics: 纯 Python 指标, 无 torch 依赖。exact match、soft VQA (官方 min(1, 同意人数/3))、ANLS、token-F1, 以及 grounding 的 parse/Acc@threshold/mean error。
- tools/eval_vlm.py: 生成式评分 (--blind 输出无图基线) 与 --shuffle-loss (真图 vs 随机图的 teacher-forced loss 差) 两种模式。shuffle-loss 是训练前最便宜的信号检验: projector 学到东西后, 真图 loss 应显著低于随机图。
- tools/fetch_eval_data.py: 固定来源拉取 TextVQA (soft VQA)、DocVQA (ANLS)、OCRBench (exact match)、ScreenSpot (in-box grounding)、MMMU-Pro (单图子集, exact match), 落盘 JSONL 与 MANIFEST.json (resolved revision sha 与 JSONL sha256), 沿用“信任 manifest 而不是 tag”的纪律。

阶段	运行内容	通过判据
Gate A	指标单元测试; 小模型 shuffle-loss 管线	测试全绿; 管线可跑
Gate B	真实 MoonViT + 小 LM: 生成、评分、blind 对照; overfit 训练	端到端无报错; shuffle_delta = +0.343 (显著为正)

Gate C	训练前/后各一次：TextVQA、DocVQA、OCRBench、ScreenSpot 小子集	训练后显著高于训练前与 blind
--------	---	-------------------

预期锚点：0xSero 的 GLM-5.2 projector-only checkpoint 报告坐标格式解析率 92%、Accuracy@50 4.3%、平均点击误差约 564/999。第一阶段的成功定义是 DeepSeek 路径达到同量级信号，而不是成熟 VLM 水平；grounding 在 projector-only 阶段大概率仍很弱。

11 变更日志

日期	变更
2026-08-02	建立通用 placeholder 扩展、PatchMerger、MoonViT wrapper 和 DeepSeek embedding hook。
2026-08-02	确认 0731 已有 < image > ID 129279，禁止扩 vocab。
2026-08-02	真实缩小 DeepSeek-V4 Hash-MoE 完成 backward。
2026-08-02	发现 Transformers 4.57.6 缺少 DeepSeek-V4；基线切换为 5.12+。
2026-08-02	完成 Vast on-demand 只读快照；未创建或租用实例。
2026-08-02	公开仓库 cyjin-yl/moonvit-deepseek-v4-glue 上线并推送。
2026-08-02	新增评测资产：metrics 指标库、eval_vlm 评分器 (含 blind 与 shuffle-loss 模式)、fetch_eval_data 数据清单；新增 generate() 生成路径。
2026-08-02	V100 工作站：torch 2.10.0+cu128 确认含 sm_70；26/26 测试通过；记录 NVML mismatch 与 Xet-over-proxy 挂起 (HF_HUB_DISABLE_XET=1 解决)。
2026-08-02	V100 完成真实 MoonViT smoke (fp32) 与评测管线端到端干跑；发现 MoonViT remote code 与 Transformers 5.x 两处不兼容并 shim；确认视觉 token 数可顶爆小模型上下文。
2026-08-02	Gate B 通过：V100 上冻结 MoonViT + SmolLM2-135M 只训 projector，1000 步后 shuffle_delta = +0.343；生成随图变化、blind 恒定。数据路径修复为相对 JSONL。
2026-08-02	Gate B 第二 backbone 复测通过：Qwen2.5-0.5B 同条件 shuffle_delta = +0.282，确认信号与文本主干选型无关。
2026-08-02	Gate B 第三轨通过：flickr8k 1100 条 (jxie 开放镜像，离线 parquet 救援落盘)，Qwen2.5-0.5B 1500 步 shuffle_delta = +0.148；三轨全部通过。
2026-08-02	训练器支持流式 checkpoint：每 500 步保存 projector(fp32+bf16)+AdamW+RNG 的完整可续训单元，后台线程传 HF；--resume 可从任一 checkpoint 精确续训。
2026-08-02	对齐社区 GLM-5.2V 配方：确认其视觉塔同为 MoonViT、标志指标为 MMMU-Pro (加入评测集)；记录 grokking (短答案) 与 warm-start 两条训练结论；带宽速度与数据集流量成本计入预算。
2026-08-03	MoonViT-V2 移植验证：K3 视觉代码 vision-only 抽取并 vendor 进仓库 (去文本模型依赖)；随机权重前向输出 [G,4,1024] 符合 PatchMerger 合同；新增 sdpa varlen attention 并与 eager 数值一致；moonvit_v2 wrapper 复用 MoonViTEncoder 契约；34/34 测试通过。权重单分片 (802 MB/1.56 TB) 下载中，HF 写权限已验证。

2026-08-03	真实权重回归完成: shard 96 下载 (sha256 9d10c74f...) → 抽取 165 张量 strict-load 通过 → V100 真实前向 [1369,4,1024]@1024px、finite、逐位确定、eager/sdpa 差 3.1e-05 → 34/34 回归 → 产物 (含 sha256 MANIFEST) 上传 HF vision_tower_k3/; 训练/评测支持 --vision-tower v2。
2026-08-03	推理集成文档重写为 MoonViT-V2 版: 确认 vLLM/SGLang 均 Day-0 支持 K3 (含 MoonViT3d) 且均有 DeepSeek-V4 文本栈, patch 面收敛为 projector 模块 + placeholder 扩展 + Hash-MoE 路由检查; llama.cpp/fastllm patch 点记录在案但 v1 不做。新增 Gate D 风险清单 (R1-R11, 每条带缓解与止损) 与三档最终账单 (情景 A \$55/\$75/\$110, 预算 \$120; 情景 A' B200 与情景 B 约 \$210-310; 上限 \$350); projector 合同更新为 V2 的 33,564,672 参数。

12 下一位执行者的最短路径

先运行 `pytest` 和 `examples/smoke_tiny_text_lm.py`。然后在 V100 工作站使用机械盘作为 `HF_HOME`, 验证真实 MoonViT。正式 0731 实验前不要写训练循环, 先证明目标 CUDA/量化 runtime 支持 `input data-gradient`。若失败, 优先评估 FP8 可微加载或定制 Dgrad, 不要改用 GGUF 假装完成训练链路。